Tampereen yliopisto

Noora Raudaskoski

MODERNIN TIETOVARASTON SUUNNITTELUPERIAATTEET

Diplomityö
Tekniikan ja luonnontieteiden tiedekunta
Samuli Pekkola
Kari Systä
Huhtikuu 2021

TIIVISTELMÄ

Noora Raudaskoski: Modernin tietovaraston suunnitteluperiaatteet
Diplomityö
Tampereen yliopisto
Tietojohtamisen diplomi-insinöörin tutkinto-ohjelma
Huhtikuu 2021

Datan hyödyntäminen liiketoiminnan päätöksenteossa kasvattaa rooliaan jatkuvasti. Yrityksissä kerätään yhä suurempia määriä liiketoimintaan liittyvää dataa, jota pitäisi pystyä hyödyntämään tehokkaasti osana liiketoimintaa. Tietovarastot on kehitetty vastaamaan tähän haasteeseen, mutta tietovarastojen suunnitteluun ei ole luotu yksiselitteisiä malleja, joiden avulla yritykset voisivat rakentaa itselleen toimivan tietovaraston. Tietovarastot nähdään usein kompleksisina järjestelminä, joita on vaikea toteuttaa. Yksi syy tähän on perinteiset ohjelmistokehityksen menetelmät, joiden pohjalta myös tietovarastoja on suunniteltu. Perinteisessä suunnittelussa ja kehityksessä heti projektin alussa tulisi määrittää kokonaiskuva liiketoiminnan tarpeista ja niiden pohjalta suunnitella tietovarasto kerroksittain edeten. Nykyään liiketoiminnan tarpeet muuttuvat hyvinkin nopeasti, mikä asettaa paineita tietovaraston suunnittelulle eivätkä perinteiset menetelmät ole tarpeeksi joustavia.

Tutkimuksessa selvitettiin modernin tietovaraston suunnitteluperiaatteet. Tutkimuksen tavoitteena oli selvittää, kuinka kohdeyrityksessä voidaan suunnitella moderni tietovarasto. Tutkimuksessa keskityttiin selvittämään usean lähdejärjestelmän dataa yhdistävän, koko yrityksen tiedot kattavan modernin tietovarastokokonaisuuden suunnitteluperiaatteet. Aluksi suoritettiin kirjallisuuskatsaus, jossa etsittiin tietoa tietovarastosta, sen komponenteista sekä suunnitteluprosessista. Kirjallisuuskatsauksen pohjalta luotiin modernin tietovaraston suunnitteluperiaatteiden malli, jonka toimivuutta testattiin empirian avulla. Empiirinen aineisto kerättiin teemahaastatteluilla. Aineisto analysoitiin temaattisella analyysilla ja yhdistettiin kirjallisuuskatsauksen tuloksiin. Empiirisen aineiston avulla mallia kehitettiin lopulliseen muotoonsa.

Tutkimuksessa saatiin selville, että modernin tietovaraston kehittäminen pohjautuu vahvasti liiketoiminnan tarpeisiin ja rakenteeseen. Onnistuneen modernin tietovaraston suunnittelun perusta on liiketoiminnalta tuleva tarve tietovarastoinnille sekä iteratiivinen kehittäminen. Moderni tietovarasto sisältää raakadatan latausalueen, joka mahdollistaa tietojen lataamisen ilman muokkaamista riippumatta niiden rakenteesta. Modernin tietovaraston rakenne pohjautuu yrityksen rakenteeseen mukaillen liiketoiminnan prosesseja ja tietojen mallinnuksessa käytetään liiketoiminnan määrittelemiä termejä. Tutkimuksen tuloksena muodostettiin iteratiivinen suunnitteluperiaatteiden malli, jonka avulla voidaan suunnitella moderni tietovarasto jatkuvasti muuttuviin liiketoiminnan tarpeisiin.

Avainsanat: moderni tietovarasto, tietovarastointi, tietovaraston suunnittelu, suunnitteluperiaatteet

Tämän julkaisun alkuperäisyys on tarkastettu Turnitin OriginalityCheck –ohjelmalla.

ABSTRACT

Noora Raudaskoski: Design principles of a modern data warehouse
Master of Science Thesis
Tampere University
Master's Degree Programme in Information & Knowledge Management
April 2021

Utilizing data in business decision-making is constantly increasing. Companies are collecting increasing amounts of business-related data that should be able to be utilized effectively as part of the business. Data warehouses have been developed to meet this challenge, but no unambiguous models have been created for data warehouse design that would allow companies to build a functioning data warehouse for themselves. Data warehouses are often seen as complex systems that are difficult to implement. One reason is the traditional software development methods. Data warehouses are also designed on these bases. In traditional planning and development at the beginning of the project, an overall picture of the business needs to be determined. This picture should be cornerstone of the data warehouse that should be designed in layers. Today, business needs change very rapidly, which puts pressure on data warehouse design and traditional methods are not flexible enough.

The study clarified the design principles of a modern data warehouse. The aim of the study was to find out how a modern data warehouse can be designed in a target company. The study focused on the design of a modern data warehouse that integrates data from several source systems and covers the entire company. Initially, a literature review was conducted to search for information about the data warehouse, its components, and the design process. On the basis of the literature review, a model of modern data warehouse design principles was screated, and the functionality was tested using empirical evidence. Empirical material was collected through thematic interviews. The material was analyzed by thematic analysis and combined with the results of the literature review. Using empirical data, the model was developed into its final form.

The study found that the development of a modern data warehouse is strongly based on business needs and structure. The basis of successful modern data warehouse design is the need for data storage from the business and iterative development. A modern data warehouse includes a raw data staging area that allows data to be downloaded regardless of its structure without modification. The structure of a modern data warehouse is based on the structures of the company, adapting business processes and uses business-defined terms. As a result of the research, an iterative model of design principles was formed, which can be used to design a modern data warehouse for constantly changing business needs.

Keywords: modern data warehouse, data warehousing, data warehouse design, design principles

The originality of this thesis has been checked using the Turnitin OriginalityCheck service.

ALKUSANAT

Tämän diplomityön aloittaminen sekä loppuun saattaminen venyi alkuperäisistä suunnitelmistani. Ajattelin aloittaessani kokopäiväisen työskentelyn tammikuussa 2020 suorittavani kevään aikana viimeiset kurssit pois alta ja aloittavani diplomityön kesällä. Sainkin aiheen valittua ja projektin aloitettua suunnitelmien mukaan heti kesän alussa, mutta kesä töissä ilman lomaa otti veronsa ja varsinaisen tutkimuksen aloittaminen venyi pitkälle syksyyn. Kun olin päässyt alkuun kirjoittamisessa, lähti työ etenemään hitaasti mutta varmasti. Alkukeväästä 2021 päätin ottaa loppukirin, jotta valmistuisin vielä saman lukuvuoden aikana. Lopulta työ valmistui juuri ajoissa ennen vappua, jota ei tänä vuonna valitettavasti päästä viettämään perinteisin tavoin koronan vuoksi. Tahtoisinkin kiittää työkavereitani ja muita haastateltavia, jotka suostuivat innokkaasti nopealla aikataululla haastateltavaksi, minkä ansiosta pystyin tekemään työn loppuun vauhdikkaasti.

Työn valmistumisesta pitkän prosessin päätteeksi tahtoisin kiittää erityisesti Timoa, joka on jaksanut tukea ja tsempata minua kärsivällisesti koko diplomityöni tekemisen ajan. Lisäksi tahtoisin kiittää ystäviäni Hannaa ja Tiiaa työn oikolukemisesta sekä vertaistuesta. Iso kiitos myös muille ystävilleni, jotka tekivät opiskeluvuosista ikimuistoisia ja olivat tukenani koko opiskelujen ajan. Ilman heitä en olisi nyt kirjoittamassa näitä alkusanoja valmiiseen diplomityöhöni. Lopuksi tahdon kiittää myös diplomityöohjaajaani Samuli Pekkolaa hyvistä neuvoista ja avusta työn eri vaiheissa.

Tampereella, 28.4.2021

Noora Raudaskoski

SISÄLLYSLUETTELO

1. JOHDANTO 1
    1.1 Tutkimuksen tausta 1
    1.2 Tutkimuksen tavoitteet ja rajaukset 2
    1.3 Tutkimusmetodologia 4
    1.4 Tutkimuksen rakenne 6
2. TIETOVARASTO 8
    2.1 Tietovarastointi yleisesti 8
    2.2 Tietovarasto vs. operatiivinen järjestelmä 10
    2.3 Tietovarastotyypit 12
        2.3.1 Keskitetty tietovarasto 12
        2.3.2 Data mart 13
        2.3.3 Data lake 14
    2.4 Tietovarastoinnin haasteet 14
3. TIETOVARASTON SUUNNITTELU 17
    3.1 Tietovarastoarkkitehtuuri 17
        3.1.1 Tietovaraston rakenne 17
        3.1.2 Erilaiset arkkitehtuurit 20
        3.1.3 Arkkitehtuurin valinta 22
    3.2 Tietomallit tietovarastoinnissa 24
        3.2.1 Tiedon mallinnuksen tasot 24
        3.2.2 Normalisoitu tietomalli 26
        3.2.3 Dimensionaalinen tietomalli 27
        3.2.4 Data vault 29
    3.3 Tietovaraston suunnittelu prosessina 31
        3.3.1 Lähestymistapa tietovaraston suunnitteluun 32
        3.3.2 Suunnittelun vaiheet 33
        3.3.3 Projektin suunnittelu 35
        3.3.4 Vaatimusten määrittely 36
        3.3.5 Suunnittelu ja toteutus 38
    3.4 Modernin tietovaraston suunnittelu 41
        3.4.1 Projektin suunnittelu ja vaatimusten määrittely 41
        3.4.2 Tekninen suunnittelu 43
        3.4.3 Tietomallin suunnittelu 45
        3.4.4 Informaation toimituksen suunnittelu 46
4. EMPIRIAN TOTEUTUS 48
    4.1 Haastattelututkimuksen toteutus 48
    4.2 Haastattelujen toteutus 49
    4.3 Aineiston analysointi 50
5. EMPIRIAN TULOKSET 53
    5.1 Tietovarastoprojektin suunnittelu 53
        5.1.1 Projektin suunnittelu 53

5.1.2 Liiketoiminnan vaatimusten kerääminen 55
5.1.3 Lähdedata 56
5.2 Tietovaraston rakenteellinen suunnittelu 57
5.2.1 Arkkitehtuuri 57
5.2.2 Teknologiat 60
5.2.3 Tietojen mallinnus 61
5.2.4 Informaation toimitus 62
6. MODERNIN TIETOVARASTON SUUNNITTELUPERIAATTEET 65
6.1 Tietovarastoprojektin aloitus ja suunnittelu 65
6.2 Liiketoiminnan tietotarpeiden määrittely ja lähdedata 66
6.3 Tietovarastoarkkitehtuurin suunnittelu 68
6.4 Teknologioiden valinta 70
6.5 Tietomallin suunnittelu 72
6.6 Informaation toimituskerroksen suunnittelu 73
7. YHTEENVETO 75
7.1 Tulosten yhteenveto 75
7.2 Tutkimuskysymyksiin vastaaminen 77
7.3 Tutkimuksen arviointi 79
7.4 Tutkimuksen rajoitteet ja jatkotutkimusaiheet 82
LÄHTEET 83

KUVALUETTELO

Kuva 1. Tutkimuskysymykset 3
Kuva 2. Tutkimusmetodologiset valinnat 4
Kuva 3. Tutkimuksen rakenne 6
Kuva 4. Tietovaraston komponentit (mukaillen Vaisman 2014) 18
Kuva 5. Tietovarastoarkkitehtuurimallit (mukaillen Sen & Sinha 2005; Ariyachandra & Watson 2010; Blazic et al. 2017) 21
Kuva 6. Tiedonmallinnustasot (mukaillen Inmon 2005; Haq 2016; Inmon et al. 2019) 25
Kuva 7. Tähtimallin mukainen rakenne (mukaillen Rahim et al. 2013) 28
Kuva 8. Lumihiutalemallin mukainen rakenne (mukaillen Li et al. 2010) 29
Kuva 9. Yksinkertaistettu esimerkki data vault tietomallista (mukaillen Olschimke & Linstedt 2016) 30
Kuva 10. Kimballin elinkaarimalli (mukaillen Kimball et al. 2011) 33
Kuva 11. Optimaalinen tietovaraston suunnitteluprosessi (mukaillen Reeves 2009) 34
Kuva 12. Tietovaraston vaatimustenkeräysprosessi (mukaillen Reeves 2009) 37
Kuva 13. Esimerkkikysymyksiä liiketoiminnan vaatimusten määrittelyyn (mukaillen Reeves 2009) 42
Kuva 14. Moderni tietovarasto (mukaillen Vaisman 2014; Chawla & Khattar 2020; Oksanen et al. 2020) 44
Kuva 15. Esimerkkejä tietovaraston informaation toimituskerroksen työkaluista (mukaillen van der Lans 2012) 46
Kuva 16. Yhteenveto modernin tietovaraston suunnitteluperiaatteista 47
Kuva 17. Temaattisen analyysin vaiheet (mukaillen Braun & Clarke 2006; Vaismoradi et al. 2013; Nowell et al. 2017) 51
Kuva 18. Modernin tietovarastoarkkitehtuurin keskeiset ominaisuudet 68
Kuva 19. Teknologian valintaan vaikuttavat tekijät 70
Kuva 20. Loppukäyttäjien vaatimukset informaation toimituskerrokselle 73
Kuva 21. Modernin tietovaraston suunnitteluperiaatteet prosessina 76

TAULUKKOLUETTELO

Taulukko 1. Operatiivisen järjestelmän ja tietovaraston keskeisimmät eroavuudet (mukaillen Reeves 2009) 11
Taulukko 2. Tietovarastoarkkitehtuurien vertailu parametrien avulla (mukaillen Hajmoosaei et al. 2011) 23
Taulukko 3. Haastateltavat 50
Taulukko 4. Teoriasta ja empiriasta tunnistetut teemat 52

LYHENTEET JA TERMIT

BI	Liiketoimintatiedon hallinta (engl. *business intelligence)*
EDW	Yrityksen keskitetty tietovarasto (engl. *enterprise data warehouse*)
ETL	Tietojen poiminta-, muokkaus- ja latausprosessi (*engl. extract, transform and load*)
OLTP	Transaktiopohjainen operatiivinen tietojärjestelmä (*engl. online transaction processing*)
SQL	Relaatiotietokantojen käyttämä standardoitu kyselykieli (*engl. structured query language*)
Tietovarasto	Integroitu ja keskitetty tietokanta sekä siihen liittyvät ohjelmistot, joiden tarkoituksena on tukea yrityksen liiketoimintatiedon hallintaa (Reeves 2009; Hughes 2016).
Tietovarastointi	Operatiiviset poiminta-, puhdistus-, muunnos- ja latausprosessit sekä niihin liittyvät ohjausprosessit, joilla ylläpidetään tietovaraston tietoja. Sisältää myös tietovaraston suunnitteluun liittyvät työvaiheet. (Brackett 2011; Hughes 2016)

1. JOHDANTO

1.1 Tutkimuksen tausta

Lisääntynyt tiedon määrä on ollut yritysten haasteena aina ensimmäisten tietojärjestelmien kehittämisestä saakka. Nykyään yrityksillä on monia erilaisia tietojärjestelmiä, jotka tallentavat dataa liiketoiminnan operatiivisesta toiminnasta. Yritykset myös tahtovat yhä enemmän hyödyntää tallennettua dataa liiketoiminnan kehittämiseen ja päätösten tukemiseen. (Reeves 2009) Tietojen hyödyntäminen sellaisenaan ei kuitenkaan ole aivan yksinkertaista. Usein liiketoiminnasta kertynyt data on tallennettuna useisiin heterogeenisiin tietokantoihin eikä niiden yhdistäminen ole mahdollista, ainakaan helposti. Tähän avuksi on kehitetty liiketoimintatiedon hallinta (*engl. business intelligence*), jonka avulla tietokantoihin tallennettu raakadata voidaan jalostaa merkitykselliseksi tietokokonaisuudeksi. Tätä kokonaisuutta kutsutaan tietovarastoksi. (Yessad & Labiod 2016)

Tietovarastoinnin avulla pyritään mahdollistamaan datan hyödyntäminen liiketoiminnan ja päätöksenteon tukena. Se ei ole uusi asia, vaan siihen on suurimmissa yrityksissä investoitu jo vuosia. Nykyään tietovarastoinnin hyödyntäminen on yleistynyt merkittävästi ja yhä pienemmissä yrityksissä on ymmärretty datan hyödyntämisen arvo. Tietovarastoinnin avulla yritys voi tehdä toiminnastaan kannattavampaa, tehokkaampaa sekä vastata nykypäivän markkinoiden kasvaviin vaatimuksiin. (Reeves 2009)

Tietovarastoinnissa operatiivisista tietokannoista kerätyt tiedot jalostetaan hyödyllisempään muotoon eri käyttötarkoituksia varten, esimerkiksi raportoinnin taustalle (Hossain et al. 2009). Riippumatta käyttötarkoituksesta, tietovarastojen perustana ovat samat yleiset tietovarastoinnin käsitteet ja tekniikat. Tietovarastojen rakenteet ja muotoilut ovat samankaltaisia, minkä vuoksi ne poikkeavat monista operatiivisten järjestelmien tietokannoista, joiden rakenteet voivat olla hyvinkin toisistaan poikkeavia. (How 2020) Tämän vuoksi tietovarastoille voidaan määrittää suunnitteluperiaatteet, joita voidaan noudattaa useissa erilaisissa tilanteissa. Tietovaraston rakentaminen edellyttää mallintamista, joka ottaa huomioon kaikki kehityksen näkökulmat, kuten tietojen mallinnuksen, projektinhallinnan, riskien hallinnan, käyttöönoton sekä monia muita olennaisia näkökohtia. (Yessad & Labiod 2016)

Tietovarastointi voi onnistuessaan luoda yritykselle merkittävän kilpailuedun, mutta epäonnistuessaan se voi aiheuttaa vaikeuksia. Tietovarastointia pidetään nykyään jopa niin

tuttuna asiana, ettei perusasioihin välttämättä perehdytä riittävän hyvin ja tästä aiheutuu epäonnistumisia, kuten epäjohdonmukaisuuksia raporteilla tai virheellistä datojen yhdistämistä. (Reeves 2009) Tietovarastointiprojektin alussa olisikin varmistettava, että perusasiat ovat hallussa ja projektin tavoitteet ovat selvillä kaikille osapuolille. On siis varmistuttava, että tiedetään liiketoiminnalliset tarpeet ja samaan aikaan hallitaan tietovarastoinnin tekniseen toteutukseen tarvittavat asiat.

Vaikka tietovarastointi on kehittynyt, kohtaavat yritykset edelleen useita haasteita perusasioissakin. Monissa yrityksissä kamppaillaan paikallisten tietovarastojen kanssa, joissa tieto on hajallaan tallennettuna useissa eri tietokannoissa ja niiden yhdistäminen on hankalaa. (How 2020) Tällaisessa tilanteessa eri lähdedatojen analysointi samalla raportilla voi olla vaikeaa tai jopa mahdotonta, mutta liiketoiminnan kehittämisen näkökulmasta erittäin arvokasta. Tietojen hajanaisuus voi aiheuttaa myös tietojen vertailukelvottomuutta, kun eri tietovarastoissa on käytetty erilaisia laskukaavoja. Lisäksi tietojen laadussa voi olla ongelmia eikä niihin voida luottaa kaikissa tapauksissa. (Reeves 2009)

Tutkimuksen kohdeyrityksessä on havaittu edellä mainittuja ongelmia. Eri palveluista kertyvä data on talletettuna erillisiin tietovarastoihin, minkä vuoksi tietojen yhdistäminen samoille raporteille on vaikeaa eikä raporttien luotettavuus ole hyvä. Nykyiset tietovarastoratkaisut eivät ole enää ajantasaisia ja niiden ylläpitäminen on haastavaa, joten on tunnistettu tarve uuden tietovaraston suunnittelulle. Kohdeyrityksessä on tarve suunnitella moderni tietovarasto, johon voitaisiin tallettaa kaikkien palveluiden tuottamaa dataa yhteen paikkaan. Tästä tarpeesta johtuen tässä tutkimuksessa selvitetään, millaisia suunnitteluperiaatteita modernin tietovaraston suunnitteluun liittyy. Tutkimuksen tarkoituksena on kehittää malli, jonka avulla kohdeyritys voi suunnitella uuden modernin tietovaraston vastaamaan liiketoiminnan vaatimuksiin.

1.2 Tutkimuksen tavoitteet ja rajaukset

Tutkimuksen tavoitteena on luoda kohdeyritykselle malli modernin tietovaraston suunnitteluperiaatteista. Tämän tavoitteen saavuttamiseksi selvitetään, mikä on tietovarasto, kuinka se suunnitellaan ja mitkä ovat modernin tietovarastoinnin suunnitteluperiaatteet. Tutkimuksessa hyödynnetään sekä teoreettista kirjallisuustutkimusta että tapaustutkimusta.

Teoriaosuudessa selvitetään, miksi tietovarastointia tehdään yrityksissä ja millaisia haasteita siihen liittyy. Kirjallisuuskatsauksen avulla pyritään luomaan kokonaiskuva siitä, millainen prosessi datan siirtäminen useista eri lähdejärjestelmistä yhteen tietova-

rastoon on ja mitä teknologioita siihen tarvitaan. Lisäksi tutustutaan erilaisiin tietovarastoarkkitehtuureihin ja tapoihin mallintaa tietovarastoja. Kirjallisuuskatsauksesta saatujen tietojen perusteella muodostetaan ensimmäinen versio modernin tietovaraston suunnitteluperiaatteista ja tämän mallin pohjalta toteutetaan tutkimuksen empiirinen osuus. Empiriassa selvitetään mallin mielekkyyttä kohdeyrityksen näkökulmasta ja empirian tulosten perusteella kehitetään mallia toimivammaksi.

Tutkimus toteutetaan kohdeyritykselle, jossa on tunnistettu tarve uudelle, modernimmalle tietovarastolle, joka pystyisi vastaamaan aiempia tietovarastoratkaisuja paremmin liiketoiminnan jatkuvasti muuttuviin tarpeisiin. Tavoitteena on muodostaa uuden tietovaraston suunnittelun tueksi malli, jonka avulla kohdeyrityksessä voidaan suunnitella moderni tietovarasto. Modernissa tietovarastossa tulisi pystyä yhdistämään helposti eri lähdejärjestelmien tietoja toisiinsa ja saada näin parempi näkyvyys yrityksen palveluiden kokonaistilanteeseen niin sisäisille kuin ulkoisille sidosryhmille.

Tutkimuksen avulla tuetaan kohdeyrityksen onnistumista uuden tietovaraston suunnittelussa ja siinä, että tietovarasto vastaa oikeasti niin sisäisten kuin ulkoistenkin sidosryhmien tarpeisiin. Nämä tarpeet ovat usein hyvin nopeasti muuttuvia, joten on tärkeää, että uusi tietovarasto mahdollistaa ketterän muutoksiin reagoimisen. Tutkimuksen päämääränä on löytää sopivat tietovaraston suunnitteluperiaatteet ja luoda malli, jonka avulla kohdeyritys pystyy suunnittelemaan modernin tietovaraston. Tavoitteen saavuttamiseksi tutkimukselle on asetettu päätutkimuskysymys *Mitä ovat modernin tietovarastoinnin suunnitteluperiaatteet?* Päätutkimuskysymyksen laajuuden vuoksi se on jaettu kolmeen alatutkimuskysymykseen, jotka ovat esitettyinä kuvassa 1.

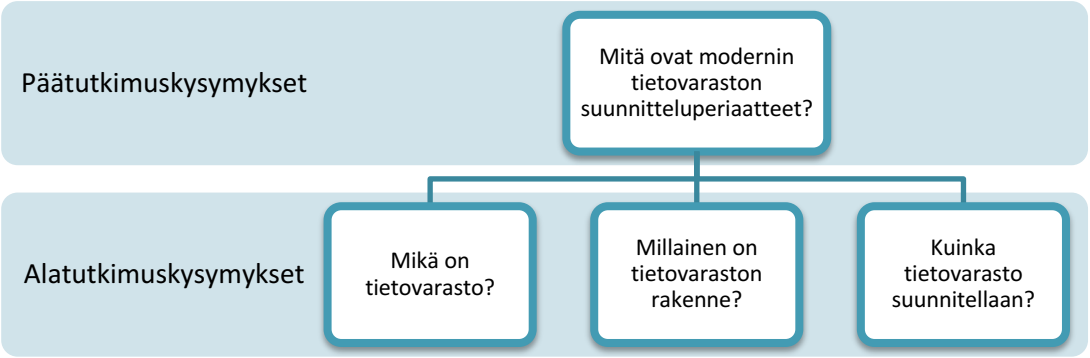

Kuva 1. Tutkimuskysymykset

Alatutkimuskysymysten avulla tutkimuksessa etsitään vastauksia pienempiin kokonaisuuksiin, joiden pohjalta muodostetaan vastaus päätutkimuskysymykseen. Kirjallisuuskatsauksen avulla etsitään ensimmäiseksi vastaus kysymykseen *mikä on tietovarasto*. Tämän kysymyksen avulla määritetään, mitä tässä tutkimuksessa tarkoitetaan tietovarastolla. Toisena selvitetään *millainen on tietovaraston rakenne*, eli millaisista

komponenteista tietovarasto koostuu ja kuinka nämä komponentit voidaan järjestellä, jotta saadaan rakennettua yrityksen tarpeisiin sopiva tietovarasto. Kolmantena selvitetään *kuinka tietovarasto suunnitellaan* eli mitä vaiheita tietovaraston suunnittelussa on ja mitä asioita sen suunnittelussa tulee ottaa huomioon. Kirjallisuuskatsauksessa saatuja tuloksia testataan empiriassa haastatteluiden avulla ja näiden tuloksista muodostetaan synteesi, joka vastaa päätutkimuskysymykseen.

1.3 Tutkimusmetodologia

Tutkimuksessa käytettävää tutkimusmetodologiaa tarkastellaan tutkimusfilosofian, lähestymistavan, strategian ja tutkimusotteen kautta. (Saunders et al. 2019) Tutkimusmetodologioita on lukuisia erilaisia ja niistä tulee valita tutkimuksen luonteeseen parhaiten sopiva. Tämän tutkimuksen metodologiset valinnat on esitelty kuvassa 2.

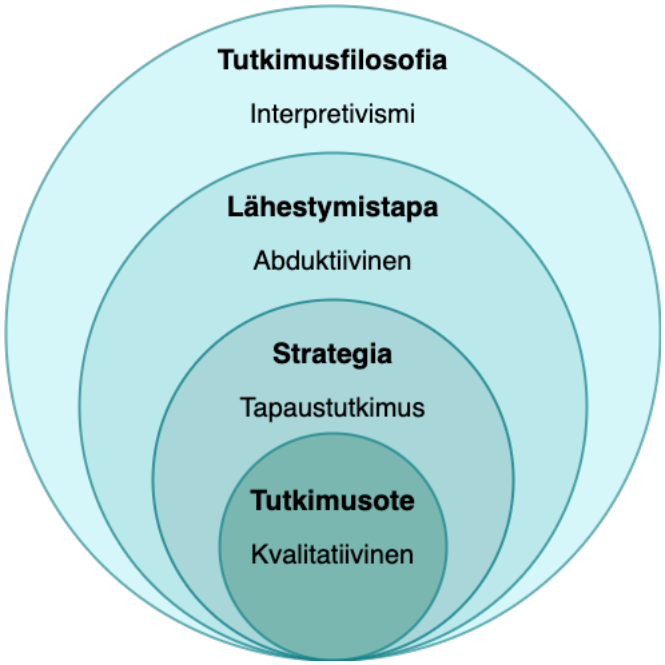

Kuva 2. Tutkimusmetodologiset valinnat

Tutkimusfilosofialla kuvataan tietämyksen syntymistä, kehittymistä ja luonnetta. Saunders et al. (2019) esittelevät viisi tutkimusfilosofiaa: positivismi, kriittinen realismi, interpretivismi, postmodernismi ja pragmatismi. Myös O'Gorman ja MacIntosh (2015) esittelevät positivismin, kriittisen realismin ja interpretivismin. Heidän mukaansa positivismi ja interpretivismi voidaan nähdä vastakkaisina tutkimusfilosofioina. Positivismi asettaa ja selittää periaatteita ja pyrkii havainnoimaan tutkimuskohteena olevaa ilmiötä objektiivisesti hyödyntäen kvantitatiivisia tutkimusmetodeja. Interpretivismi puolestaan pyrkii ymmärtämään ja tulkitsemaan tekijöitä ja niiden välisiä suhteita. (O'Gorman & MacIntosh

2016) Se korostaa subjektiivisten tulkintojen merkitystä tutkimuskohteiden ja tiedon rakentumisessa. Interpretivismi on tyypillinen tutkimusfilosofia laadullisessa tutkimuksessa. (Saunders et al. 2019) Tässä tutkimuksessa pyritään kuvailemaan ja luomaan kokonaisvaltainen ymmärrys tutkimuksen aiheesta eli tutkimuksessa tunnistetaan tutkimuskohteen subjektiivisuus sekä tulkintojen merkitys tulosten muodostamisessa. Siten tämän tutkimuksen taustalla tutkimusfilosofiana vaikuttaa interpretivismi.

Tutkimuksella on yleensä induktiivinen, deduktiivinen tai näiden ominaisuuksia yhdistelevä, abduktiivinen, lähestymistapa. Deduktiivisessa lähestymistavassa tutkimus aloitetaan teorian kokoamisella, jonka jälkeen siirrytään empiiriseen osuuteen. Induktiivinen tutkimus toimii päinvastoin eli liikkeelle lähdetään empiirisestä tutkimuksesta, jota täydennetään teorialla. (Eriksson & Kovalainen 2016; Saunders et al. 2019) Abduktiivinen lähestymistapa yhdistelee molempia edellä mainittuja. Tutkimus perustuu empiriaan, mutta teoriaa hyödynnetään koko tutkimuksen ajan eri tilanteissa. Näin pystytään tekemään laajempia päätelmiä aiheesta. (Walton 2014)

Tässä tutkimuksessa käytetään abduktiivista lähestymistapaa. Tutkimuksessa etsitään kirjallisuuskatsauksen avulla tietoa tutkittavasta aiheesta. Tämän jälkeen suoritetaan haastattelut, jonka teemat pohjautuvat teoriaosuudessa tehtyihin havaintoihin, mutta ei testata olemassa olevaa teoriaa. Empiriasta saadut tulokset yhdistetään teoriaosuuden tuloksiin ja vertaillaan niitä keskenään.

Tutkimukselle valitaan filosofian ja lähestymistavan lisäksi tutkimusstrategia. Tutkimusstrategia määrittelee, millaista dataa tutkimuksessa kerätään ja miten. Tässä tutkimuksessa tutkimusstrategiana toimii tapaustutkimus. Tapaustutkimuksessa aihetta tai ilmiötä tutkitaan todellisessa ympäristössä, joka voi olla esimerkiksi yritys, kuten tässä tutkimuksessa. Tapaustutkimus vastaa kysymyksiin ”miten” ja ”miksi”. (Yin 2014; Saunders et al. 2019) Tapaustutkimuksen avulla tutkittavaa ilmiötä voidaan tarkastella oikeassa kontekstissa ja kerätä aineistoa ympäristössä, jossa tutkittava ilmiö todellisuudessa tapahtuu. Näin saadaan arvokasta tietoa reaalimaailmasta, eikä tutkimus pohjaudu pelkkiin olettamuksiin. (Farquhar 2012) Tässä tutkimuksessa pyritään selvittämään, miten suunnitellaan moderni tietovarasto ja ilmiötä tarkastellaan kohdeyrityksessä. Tapaustutkimuksen avulla pyritään lisäämään ymmärrystä tutkittavasta ilmiöstä (Yin 2014), kuten myös tässä tutkimuksessa pyritään luomaan kohdeyrityksen tarvetta varten syvällinen ymmärrys modernin tietovaraston suunnitteluperiaatteista.

Lopuksi valitaan tutkimusote. Tutkimusotteella tarkoitetaan sekä tapaa, jolla tutkimuksen empiirinen aineisto kerätään, että kerätyn tiedon laatua. Tietoa voidaan kerätä kvalitatii-

visella, kvantitatiivisella tai yhdistetyllä menetelmällä. Kvalitatiivisia eli laadullisia aineistonkeruumenetelmiä ovat esimerkiksi haastattelut tai tarkkailu. Kvantitatiivinen eli määrällinen aineisto mielletään usein numeraaliseksi. Esimerkiksi erilaisia asioiden välisiä suhteita pyritään kuvaamaan numeraalisella asteikolla. Kvantitatiivisia aineistonkeruumenetelmiä ovat esimerkiksi mittaaminen ja kyselytutkimus. (Saunders et al. 2019) Tässä tutkimuksessa empiirinen aineisto tullaan keräämään teemahaastatteluilla, joten aineisto tulee olemaan kvalitatiivista. Täten tutkimusote on laadullinen tässä tutkimuksessa.

1.4 Tutkimuksen rakenne

Tutkimus etenee loogisesti teoriasta empirian kautta tulosten analysointiin ja päätelmiin. Teorian jälkeen luodaan ensimmäinen versio tietokannan suunnitteluperiaatteista, jonka toimivuutta tutkitaan empiirisessä osuudessa. Empirian ja teorian tuloksista muodostetaan synteesi ja luodaan tarkennettu malli suunnitteluperiaatteista. Lopuksi tarkastellaan tutkimuksen tavoitteiden saavuttamista ja jatkotutkimusaiheita. Tutkimuksen rakenne on esitelty tarkemmin kuvassa 3.

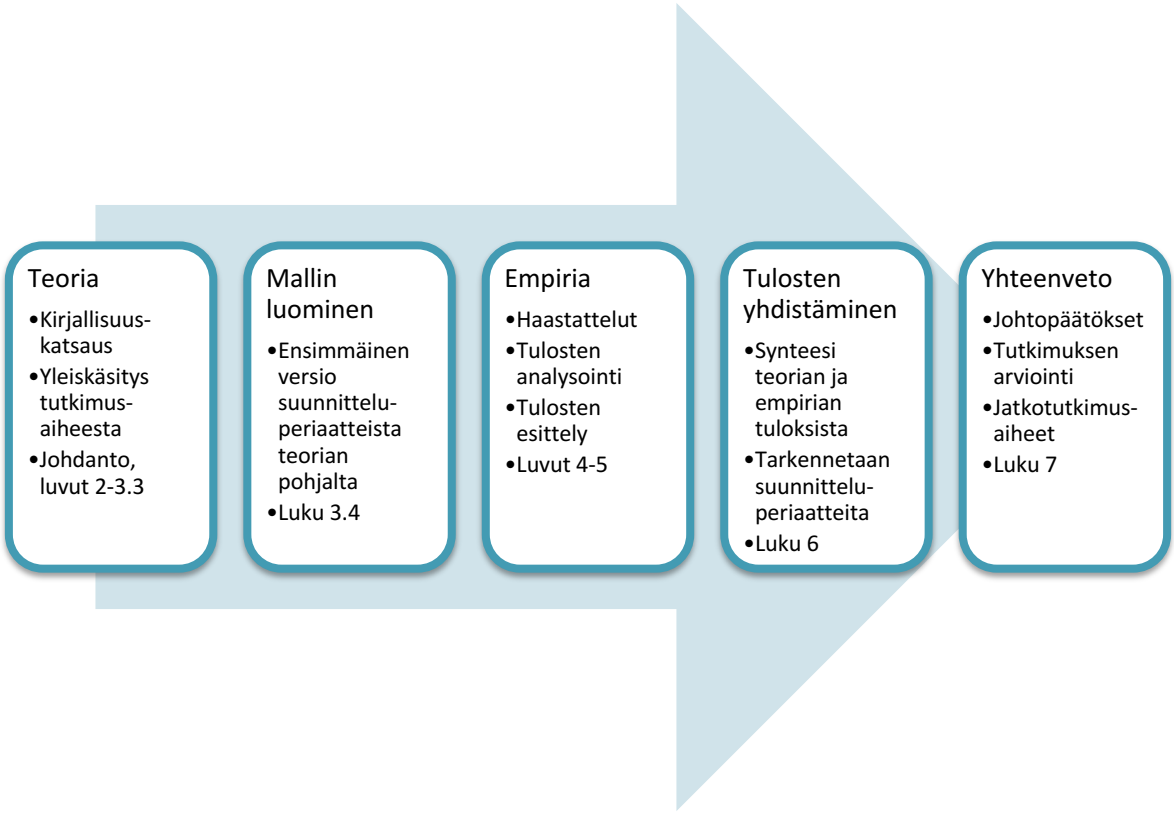

Kuva 3. Tutkimuksen rakenne

Luvussa 2 käsitellään tietovarastoa yleisesti ja sen merkitystä yritysten liiketoiminnalle. Lisäksi tarkastellaan, miten operatiiviset järjestelmät eroavat tietovarastosta. Luvussa

esitellään myös eri tietovarastotyyppejä ja lopuksi käsitellään tietovarastointiin liittyviä haasteita. Luvussa 3 käsitellään tietovaraston suunnittelua käyden läpi, millaisista komponenteista tietovarasto koostuu, kuinka komponentit voidaan organisoida erilaisilla tietovarastoarkkitehtuurimalleilla sekä mitä pitää ottaa huomiin arkkitehtuurimallin valinnassa. Tämän jälkeen tutustutaan tiedon mallinnukseen ja esitellään tietomallinnuksen tasot sekä yleisimmät tiedonmallinnuksen tavat. Lisäksi käsitellään tietovaraston suunnitteluprosessin vaiheita aina projektin suunnittelusta tietovaraston suunnittelu- ja toteutusvaiheeseen. Luvun loppuun muodostetaan synteesi teorialukujen sisällöstä ja luodaan ensimmäinen versio suunnitteluperiaatteiden mallista.

Mallin luomisen jälkeen toteutetaan empiriaosuus eli asiantuntijahaastattelut. Luvussa 4 kerrotaan haastattelujen suorittamisesta ja empiirisen aineiston analysoinnista. Luvussa 5 esitellään empiriasta saadut tulokset. Luvussa 6 empirian tulokset yhdistetään teoriaosuuden tuloksiin. Luvussa 7 esitetään yhteenveto tutkimuksen tuloksista ja vastataan tutkimuskysymyksiin. Lopuksi arvioidaan tutkimusta ja pohditaan jatkotutkimusaiheita.

2. TIETOVARASTO

Tietovarasto on useista lähdejärjestelmistä integroitu vakaa ja ajantasainen tietokokoelma, jonka tarkoituksena on tukea yrityksen johdon päätöksentekoa. (Mundy et al. 2006; Bimonte et al. 2019) Tässä luvussa tutustutaan tietovarastointiin yleisesti sekä käydään läpi tietovaraston ja operatiivisten järjestelmien tärkeimmät eroavuudet. Tämän jälkeen esitellään yleisimpiä tietovarastotyyppejä ja lopuksi perehdytään vielä tietovarastointiin liittyviin haasteisiin.

2.1 Tietovarastointi yleisesti

Nykypäivänä yrityksen liiketoiminta mahdollistetaan erilaisilla järjestelmillä, joita kutsutaan yleisesti operatiivisiksi järjestelmiksi. Operatiivista järjestelmistä kertyy tietoa, jota tallennetaan operatiivisiin tietokantoihin. Tämä tieto on liiketoiminnan kannalta elintärkeää, mutta sen hyödyntäminen liiketoiminnan päätöksenteon tukena suoraan operatiivisista järjestelmistä on vaikeaa ja usein jopa mahdotonta. (Vitt et al. 2008) Tiedot voivat olla väärässä muodossa, liian siiloutuneita tai turhan monimuotoista, jotta niistä voitaisiin muodostaa esimerkiksi analyysejä liiketoiminnan kehittämiseen. Toisaalta myös datojen kysely suoraan operatiivisesta tietokannasta kuormittaisi niitä, jolloin operatiivinen toiminta voi hidastua. Tämän vuoksi tietojen hyödyntämiseen on kehitetty tietovarastot. (Ponniah 2010)

Tietovarastojen avulla voidaan tallentaa operatiivista tietoa useista eri tietolähteistä yhteen paikkaan ja toimittaa ne käyttäjille ennalta sovitussa muodossa analysointia varten (Kimball & Ross 2013; Yessad & Labiod 2016; Santoso & Yulia 2017). Lisäksi tietovarastossa voidaan ylläpitää pitkältäkin ajalta useista tietolähteistä kerättyä historiadataa. Tietovarastossa tiedot on muokattu ja järjestetty analysointia helpottavaan ja helposti ymmärrettävään muotoon, jotta niiden avulla voidaan tukea mahdollisimman tehokkaasti liiketoiminnan päätöksentekoa. (Bojičić et al. 2016)

Tietovarasto on siis järjestelmä, johon kootaan eri lähdejärjestelmien dataa. Data voidaan mallintaa tietovarastoon hyödyntämällä erilaisia datan mallinnustapoja, esimerkiksi dimensionaalista mallinnusta tai Data vaultia. (Vitt et al. 2008; Santoso & Yulia 2017). Eri mallinnustapoihin tutustutaan tarkemmin luvussa 3. Tietovarastointi puolestaan kuvastaa koko prosessia, jossa lähdejärjestelmien data tuodaan tietoa tarvitsevien sovellusten ja käyttäjien saataville (Watson 2002). Tietovarasto on liiketoiminnan näkökulmasta päätöksentekoa tukeva järjestelmä, joka mahdollistaa yrityksen omistaman tiedon

jalostamisen analyyseihin ja raportteihin. Jotta sen tietoja voidaan jalostaa ja hyödyntää liiketoiminnan päätöksenteon tukena, tulee tietovaraston rakenteen olla riittävän yksinkertainen ja suunnattu selkeästi liiketoiminnan tarpeisiin. (Mundy et al. 2006; Kimball & Ross 2013; Bojičić et al. 2016)

Kimball (2008) kuvaa yrityksen keskitettyä tietovarastoa (EDW) täydelliseksi liiketoimintatiedon hallinta- ja tietovarastojärjestelmäksi, sillä hyvä liiketoimintatiedon hallinta vaatii tietovarastointia ja hyvä tietovarasto tukee liiketoimintatiedon hallintaa. (Kimball et al. 2011) Inmon (2005) puolestaan kuvaa tietovarastoa kokoelmana integroituja aihekohtaisia tietokantoja. Nämä tietokannat on suunniteltu tukemaan päätöksentekojärjestelmiä, joissa jokainen tietoyksikkö on tärkeä tiettynä ajanhetkenä. Tietovarastot sisältävät atomista dataa sekä yksinkertaisia laskettuja yhteenvetoja. (Inmon 2005) Imhoff et al. (2003) täydentävät Inmonin (2005) näkemystä tietovarastoista, sillä heidän mukaansa tietovarasto on liiketoimintatiedon integroinnin keskipiste ja tietolähde data marteille eli paikallisille tietovarastoille, jotka esitellään tarkemmin luvussa 2.3.2. Näin ollen tietovarasto tarjoaa kokonaisvaltaisen näkemyksen yrityksen tiedoista. (Imhoff et al. 2003)

Tietovarastoon tallennettavien tietojen tulisi olla liiketoiminnan edustajien näkökulmasta intuitiivisia. Tällä tarkoitetaan sitä, että tiedot tallennetaan liiketoiminnan mallien mukaisesti käyttäen liiketoiminnan sanastoa. Tämä mahdollistaa liiketoiminnan edustajien itsenäisen tiedon hyödyntämisen esimerkiksi liiketoimintatiedon hallinta - eli BI-työkaluilla. (Reeves 2009; Kimball & Ross 2013) Liiketoiminnan edustajan tietotekninen osaaminen on usein heikompaa kuin tietovarastokehittäjillä, minkä vuoksi tietovarastosta tulisi pystyä muodostamaan raportteja ilman syvempää kyselykielen, kuten SQL:n, osaamista. Tämän vuoksi esimerkiksi juuri BI-työkalut ovat tärkeä osa tietovarastokokonaisuutta.

Tietovaraston tulisi tarjota yrityksen tiedoista ”yksi totuus” ja mahdollistaa tietojen käyttö aina kun sille on tarvetta. ”Yhden totuuden” tarjoaminen tarkoittaa, että eri raporteilla käytetään samaa dataa, jolloin luvut ovat samalla tavalla laskettuja kaikkialla eikä näin synny raporttien välisiä eroavaisuuksia. (Reeves 2009) Tämä vaatii onnistuneen tietovarastoinnin lisäksi myös yhteisesti sovittuja pelisääntöjä, jotta raporttien tekijät sekä käyttäjät tietävät miten luvut muodostuvat ja mitä eri käsitteet tarkoittavat.

Tietovarastointi kokonaisuutena on paljon enemmän kuin yksittäisen raportin toimittaminen oikeaan aikaan. Tietovarastoinnin avulla voidaan seurata yrityksen keskeisiä suorituskyvyn indikaattoreita ja trendejä, sillä tietovarasto voi tarjota raportteja, jotka osoittavat, mitkä tuotelinjat ovat suosittuja eri alueilla, mitkä työntekijät ovat tuottaneet eniten myyntiä tai ovatko tietyt mainoskampanjat korreloineet onnistuneen myynnin kanssa.

(Reeves 2009) Tämän vuoksi tietovarastoa ei tule ajatella yksittäisenä yritykseen ostettavana tietojärjestelmänä, vaan käyttäjäkeskeisenä kokonaisuutena, jonka avulla käyttäjillä on suora kosketuspinta yrityksen tietoihin (Ponniah 2010).

2.2 Tietovarasto vs. operatiivinen järjestelmä

Tietovarastot pyrkivät tarjoamaan käyttäjilleen kokonaisvaltaisen kuvan yrityksen nykytilasta ja historiasta (Mundy et al. 2006; Ponniah 2010). Tavoitteena on tukea päätöksentekoa kokonaiskuvan pohjalta. Tietovarastoon kohdistuvat kyselyt ovat usein hyvin monimutkaisia, joissa suoritetaan arvojen summausta ja taulujen yhdistämistä (Marotta & Ruggia 2002). Tällaiset kyselyt tarvitsevat suoritustehoa, jotta vasteajat saadaan pidettyä maltillisina. Tietovarastot ovatkin optimoitu suorittamaan suurempaa laskentaa kuin operatiiviset tietokannat sekä rakentamaan analyyttisia malleja (Munawar et al. 2011). Lisäksi tietovarastot ovat usein erotettu fyysisesti yrityksen operatiivisista järjestelmistä, jotta tietovarastoon tehdyt raskaat kyselyt eivät kuormittaisi operatiivisia järjestelmiä (Chaudhuri & Dayal 1997).

Yrityksen operatiiviset järjestelmät perustuvat ajantasaiseen tapahtumien käsittelyyn, jonka vuoksi niitä kutsutaan OLTP-järjestelmiksi (*engl. online transaction processing*). OLTP-järjestelmät ovat suunnattu erilaisten liiketoiminnan transaktioiden suorittamiseen ja tallentamiseen. Näiden järjestelmien on varmistettava tapahtumien tehokas ja tarkka käsittely. (Reeves 2009) Operatiivisten järjestelmien tietokantoihin kohdistuu strukturoituja ja usein toistuvia operaatioita, jotka ovat lyhyitä ja atomisia. Tietokantojen kriittisiä ominaisuuksia ovat niiden kyky toipua virhetilanteista sekä hallita samanaikaisia transaktioita. Niiden tehtävänä on varmistaa operatiivisen järjestelmän nopea ja virheetön toiminta. (Chaudhuri & Dayal 1997) Lisäksi erona tietovarastoihin operatiivisten järjestelmien tietokantoihin suoritetaan lukuoperaatioiden ohella myös kirjoitus- ja päivitysoperaatioita (Ponniah 2010).

Tietovarastoinnin avulla tiedot pyritään tallentamaan sellaisessa formaatissa, että tietovaraston käyttäjiltä ei vaadita yhtä syvällistä tietokantaosaamista kuin operatiivisen järjestelmän tietojen ymmärtämiseen ja käyttöön. Tietovarasto mahdollistaa myös tietojen historioinnin, joten sen avulla voidaan tarkastella yrityksen tietoja eri ajanjaksoina sekä löytää esimerkiksi erilaisia trendejä asiakkaiden käyttäytymisessä. (Mundy et al. 2006; Reeves 2009) Tietojen historiointi onkin järkevämpää toteuttaa tietovarastoon kuin operatiivisiin järjestelmiin, jotta voidaan varmistua järjestelmien tehokkaasta suorituskyvystä (Kimball & Ross 2013).

Lyhyesti tiivistettynä voidaankin ajatella, että operatiivisiin tietokantoihin tallentuu kaikki yrityksen liiketoiminnasta muodostuva data, joka lopulta saadaan ulos käyttöä varten tietovarastosta. Operatiivisten tietokantojen avulla voidaan jälkeenpäin tarkastella liiketoimintaan liittyviä tietoja ja tietovaraston avulla voidaan luoda raportteja ja analyysejä liiketoiminnallisten päätösten teon tueksi. (Mundy et al. 2006; Kimball & Ross 2013; Bojičić et al. 2016) Taulukossa 1 esitetään keskeisimmät eroavuudet operatiivisten järjestelmien ja tietovaraston välillä.

Taulukko 1. Operatiivisen järjestelmän ja tietovaraston keskeisimmät eroavuudet (mukaillen Reeves 2009)

	Operatiivinen järjestelmä	Tietovarasto
Käyttötarkoitus	Operatiivisten prosessien tukeminen	Strategisen analysoinnin, suorituskyvyn arvioinnin ja raportoinnin mahdollistaminen
Datan käyttö	Tietojen tallentaminen ja ylläpito	Tietojen hyödyntäminen
Tietojen validointi	Tiedot todennetaan transaktion yhteydessä	Tiedot todennetaan transaktion jälkeen
Päivitystiheys	Transaktion yhteydessä	Ajastettu
Historiatietojen vaatimus	Ajantasainen	Historiadataa usean vuoden ajalta
Tietojen integrointi	Tiedot yhdenmukaisia kyseisen järjestelmän puitteissa	Tiedot integroitu ja yhdenmukaistettu eri lähdejärjestelmistä

Operatiivisten järjestelmien tärkein tehtävä on tukea liiketoiminnan operatiivisia prosesseja, kun taas tietovarastoinnilla pyritään tukemaan yrityksen strategisia prosesseja, kuten päätöksentekoa. Operatiivisissa järjestelmissä tallennetaan ja ylläpidetään tietoja, joita hyödynnetään tietovaraston avulla. (Mundy et al. 2006; Kimball & Ross 2013) Operatiiviset järjestelmät tukevat vain ennalta määritettyjä toimintoja. Tietovarastot puolestaan on suunniteltu vastaamaan ad hoc -kyselyihin ja tietojen analysointiin. (Harkal 2019) Taulukon 1 mukaisesti myös tietojen validointitapa eroaa näiden kahden järjestelmän välillä. Operatiivisessa järjestelmässä tiedot todennetaan tapahtuman yhteydessä, kun taas tietovarastoinnissa tietojen oikeellisuus tarkastetaan vasta tapahtuman jälkeen, kun tietoja tallennetaan tietovarastoon. (Reeves 2009)

Yksi oleellinen ero operatiivisen järjestelmän ja tietovaraston välillä on niiden päivitystiheys, kuten taulukosta 1 ilmenee. Operatiivisessa järjestelmässä tiedot päivittyvät suoritettaessa jokin transaktio, esimerkiksi kun verkkokaupassa uusi tilaus syötetään järjestelmään. (Reeves 2009) Näin ollen operatiivisissa järjestelmissä tiedot ovat aina ajan tasalla. Tietovarastoon tiedot ajetaan ajastetusti eräajoina esimerkiksi kerran vuorokaudessa, yleensä yöaikaan, jolloin ajosta koituu mahdollisimman vähän kuormitusta operatiiviselle toiminnalle. Tietovarastossa loppukäyttäjän suorittamat kyselyt eivät siis yleensä aiheuta tietojen päivittymistä. (Harkal 2019)

Tietovarastoon voidaan tallentaa historiatietoja kuukausien ja jopa useiden vuosien ajalta. Operatiivisissa järjestelmissä sen sijaan säilytetään vain järjestelmän toiminnan kannalta välttämätön historia, jotta niiden suorituskyky ei heikkene turhaan tallennettujen tietojen vuoksi. (Harkal 2019) Operatiivisessa järjestelmässä käsitellään vain kyseisen järjestelmän tietoja, kun taas tietovarastoon usein integroidaan tietoja useista lähteistä, jolloin tiedot täytyy yhdenmukaistaa. (Reeves 2009; Kimball & Ross 2013).

2.3 Tietovarastotyypit

Liiketoiminnan tarpeisiin voidaan rakentaa erityyppisiä tietovarastoja. Tietovarasto voi tyypistä riippuen olla joko yrityksen kaiken tiedon kattava keskitetty tietovarasto tai paikallisiin tietovarastoihin jaettu kokonaisuus. Tässä luvussa tarkastellaan tarkemmin keskitettyä tietovarastoa sekä paikallisia tietovarastoja, sillä ne tunnistetaan olevan yleisimmät tietovarastotyypit. (Hovi 2001) Lisäksi tarkastellaan data lakea eli tietoallasta, jota käytetään raakatiedon tallentamiseen.

2.3.1 Keskitetty tietovarasto

Yrityksen keskitetty tietovarasto (*engl. enterprise data warehouse*) eli EDW on koko yrityksen kattava tietovarasto, joka sisältää eri liiketoiminta-alueiden tietoja. Sen tavoitteena on kerätä ja integroida eri liiketoimintojen tiedot yhteen isoon tietokantaan. (Hovi 2001) EDW on luotu vastaamaan yritysten monipuolistuneisiin tietotarpeisiin, joihin vastaaminen edellyttää eri lähdedatojen yhdistelemistä. Erityisesti suuryrityksillä, mutta nykyään myös yhä kasvavissa määrin pienillä yrityksillä, on käytössään useita eri tietojärjestelmiä. Jokaisella järjestelmällä on omat sidosryhmänsä ja ne tarjoavat erilaisen näkökulman yrityksen toimintaan ja tulevaisuuteen. (Hughes 2016)

Erilaisten käyttökohteiden vuoksi järjestelmiin tallennetut tiedot voivat olla rakenteeltaan merkittävästi toisistaan poikkeavia, jolloin niiden hyödyntäminen yhdessä on vaikeaa.

Jotta eri järjestelmistä voitaisiin yhdistellä tietoja esimerkiksi raportointia varten, on tietomalleja ja -rakenteita yhtenäistettävä. (Hughes 2016) Tähän tarjoaa ratkaisun keskitetty tietovarasto. EDW:ssä käytetään integraatiokerrosta, jossa luodaan yhtenäinen tietomalli tietojen yhdistämiseksi eri lähteistä. Yhteisen tietomallin avulla varmistetaan, että kaikilla osapuolilla on yhteinen ymmärrys tiedon sisällöstä ja voidaan tarjota loppukäyttäjille riittävä tarkkuus tietojen hakemiseen. (Haarbrandt et al. 2016)

Keskitettyyn tietovarastoon kerättyjä tietoja voidaan käyttää esimerkiksi raportoinnissa ja analysoinnissa erilaisten näkymien tai esimerkiksi seuraavassa luvussa esiteltävien data marttien kautta. (Haarbrandt et al. 2016) Data martit ovat EDW:stä johdettuja pienempiä kokonaisuuksia, joista tiedot haetaan raporteille. Ne ovat tietokantoja, joihin tiedot tallennetaan liiketoimintaa tukevassa muodossa, eli niiden sisältämien tietojen pohjalta voidaan helposti luoda raportteja erilaisiin liiketoiminnan tarpeisiin. (Hovi 2009)

2.3.2 Data mart

Inmon et al. (2002) mukaan data martit ovat tietovaraston osajoukkoja, jotka ovat rakennettu vastaamaan eri liiketoimintojen tarpeisiin. Data mart voi olla myös itsenäinen paikallistietovarasto, joka sisältää yrityksen yksittäiselle osastolle tai liiketoiminnolle ominaisia tietoja (Vitt el al. 2008). Edellä esitelty keskitetty tietovarasto pystyy puolestaan vastaamaan koko yrityksen tietotarpeisiin. Tässä kontekstissa data martteja voidaankin pitää helposti rakennettavina kokonaisuuksina, joiden luomiseen ja ylläpitoon tarvittavat resurssit ovat merkittävästi vähäisemmät kuin keskitetyssä tietovarastossa. (Hajmoosaei et al. 2011; Ţole 2016)

Käyttämällä yksistään paikallisia data martteja on haastavaa saavuttaa aiemmin luvussa 2.1 tietovaraston tavoitteeksi määriteltyä ”yhtä totuutta” yrityksen tiedoista (Ariyachandra & Watson 2010). Tietojen yhdenmukaisuutta pyritään kuitenkin ylläpitämään huolehtimalla siitä, että eri data martteihin lasketuissa tunnusluvuissa käytetään yhteisesti sovittuja laskukaavoja. Tämän avulla voidaan varmistaa, että tiedoista tehdyt analyysit ovat vertailukelpoisia myös eri data marttien välillä. (Hovi 2009; Reeves 2009) Kuitenkin kokonaiskuvan luominen yksittäisissä data marteissa sijaitsevista tiedoista on hankalampaa kuin keskitetyssä tietovarastossa.

Data martit voivat sijaita samalla palvelimella tai lokaatiossa kuin EDW, mutta tämä ei ole välttämätöntä (Imhoff et al. 2003). Ne voidaan sitoa toisiinsa myös esimerkiksi loogisesti liitosavainten avulla tai data martit voivat olla kokonaan itsenäisiä, toisistaan riippumattomia tietovarastoja (Blazic et al. 2017). Data martit voivat olla myös integroituna keskitettyyn tietovarastoon tai niihin voidaan valuttaa tietoa keskitetystä tietovarastosta

(Yessad & Labiod 2016; Blazic et al. 2017). Eri tietovarastotyyppien välisiin suhteisiin tutustutaan tarkemmin luvussa 3.1, jossa käsitellään tietovarastoarkkitehtuureja.

2.3.3 Data lake

Data lake on raakatietovarasto, johon voidaan tallentaa ja arkistoida kaikki tarpeellinen yrityksen tuottama data käsittelyä ja analysointia varten. Sinne voidaan ladata dataa useista eri lähteistä alkuperäisessä muodossa riippumatta siitä, onko data strukturoitua vai strukturoimatonta. (John et al. 2017; Llave 2018) Strukturoimattoman datan tallentaminen on hyvin merkityksellistä datan hyödyntämisen kannalta, sillä usein vain suurin osa yrityksen datasta on strukturoidussa muodossa. Tämän vuoksi on tärkeää, että tietovarastoon voidaan tallentaa kaikki tarpeellinen data riippumatta sen muodosta. (Inmon et al. 2019). Data laken kaltaisen raakatietovaraston avulla dataa voidaan tallentaa tietovarastoon ilman muokkaamista ja muokkaaminen voidaan tehdä, kun tietotarpeet on selvillä.

Datan tallentaminen data lakeen ei vaadi yhtä paljon suunnittelua ja työtä kuin perinteisempi ETL-prosessin mukainen tietojen lataaminen, eikä tietotarpeita ole tarpeen määritellä ennen tietojen lataamista. (Llave 2018) Raakatietovaraston avulla voidaan vähentää myös datan lataamisesta aiheutuvia kustannuksia. Dataa ei tarvitse mallintaa lataamista varten, vaan se on tarpeellista vasta kun liiketoiminnalta tulee tarve datan hyödyntämiseen. (Laurent et al. 2020) Näin vältytään oletusten ja arvailujen pohjalta tehdyn mallinnuksen aiheuttamilta ongelmilta ja tietojen uudelleen mallintamiselta.

Data lake ei yleensä ole itsenäinen erillinen tietovarasto, vaan osa tietovaraston kokonaisarkkitehtuuria. Data lakeen tallennetut datat muokataan yhteensopiviksi ja käyttötarpeisiin sopivaksi ja ladataan sen jälkeen varsinaiseen tietovarastoon. (Howson 2008; Ranjan 2008; Chaudhuri et al. 2011) Data laken käytössä pitää kuitenkin muistaa se, että jos sinne ladattuja datoja hyödynnetään tietovarastossa, ei niitä voida poistaa. Data lakeen ladattujen tietojen poistaminen tuleekin tehdä suunnitellusti ja varmistaen, ettei poistettavaa dataa käytetä muualla tietovarastokokonaisuudessa. Tästä johtuen dataa kertyy data lakeen hyvin suuria määriä, joten sen on oltava rakenteeltaan hyvin skaalautuva ja joustava. (Gupta & Giri 2018)

2.4 Tietovarastoinnin haasteet

Tietovarastointiin liittyy usein myös erilaisia haasteita. Ne voivat olla esimerkiksi tekniseen toteutukseen, liiketoiminnan tarpeiden tunnistamiseen tai tietovaraston käyttöön liittyviä. Kirjallisuudesta nousi esiin, että varsinkin perinteisillä menetelmillä kehitettäessä

tietovarastoprojektit epäonnistuvat useammin kuin onnistuvat. Epäonnistumisen riskiä voidaan kuitenkin lieventää käyttämällä iteratiivisia kehitysmenetelmiä. (Hughes 2016) Reevesin (2009) mukaan tärkein tekijä tietovarastoprojektin onnistumisen kannalta on vahva kumppanuusside liiketoiminnan ja tietohallinnon edustajien välillä. Lisäksi tulee varmistaa, että tietovarastoprojekti perustuu todellisiin, liiketoiminnasta esiin nousseisiin, vaatimuksiin ja tarpeisiin (Reeves 2009).

Yksi tärkeimmistä vaiheista tietovarastointiprojektissa on liiketoiminnan tarpeiden selvittäminen. Yksi yleinen ongelmia aiheuttava tekijä on tietotarpeiden määrittelyyn valittu lähestymistapa. Tietovaraston tarpeiden määrittely eroaa merkittävästi operatiivisten järjestelmien määrittelystä, eikä siihen sovellu välttämättä samat menetelmät. Operatiivisia järjestelmiä suunniteltaessa vaatimusten tulee olla tarkasti ja yksityiskohtaisesti määriteltyjä, jotta toiminnot suoritetaan varmasti oikein. Sen sijaan tietovarastointiin liittyvät tarpeet ovat paljon yleisemmällä tasolla määriteltyjä ja nopeammin muuttuvia. (Reeves 2009) Tietovarastoprojektissa onkin tärkeää pitää kaikki määrittelyyn osallistuvat sidosryhmät mukana koko projektin ajan ja kerätä heiltä jatkuvasti palautetta. Palautteen avulla voidaan varmistua, että projekti kulkee toivottua päämäärää kohti ja mahdollisiin muutostarpeisiin voidaan reagoida nopeasti. (Hughes 2016)

Vääränlaisen lähestymistavan valinnasta voi aiheutua viestintäkuilu tietovarastokehittäjien ja liiketoiminnan edustajien välille. Kehittäjien mielestä liiketoiminnan edustajat eivät osaa sanoittaa tarpeeksi tarkasti omia tarpeitaan ja liiketoiminnan edustajien mielestä kehittäjät eivät tuota heille sitä, mitä he tarvitsevat. (Reeves 2009) Tämän vuoksi on tärkeää varmistaa, että kaikkien sidosryhmien välillä on hyvä keskusteluyhteys ja palautteen antaminen on tehty riittävän helpoksi, jotta sitä voidaan antaa kaikkiin suuntiin matalalla kynnyksellä. Näin parannetaan määrittelyiden laatua sekä suorituskykyä. (Hughes 2016)

Jotta tietovarasto pystyy vastaamaan yrityksen analysointi- ja raportointivaatimuksiin, tulee tiedot mallintaa liiketoiminnan mukaisesti. Standardoidun tietovaraston suunnittelumenetelmän puuttuminen aiheuttaa usein ongelmia tietojen mallinnuksessa. Tietomallin on oltava riittävän yleisellä tasolla, jotta se pystyy mallintamaan kaiken yrityksen tarvitseman tiedon eri lähteistä. (Bojičić et al. 2016) Tietomalli olisi hyvä mallintaa aluksi alhaisimmalla mahdollisella granulariteetti- eli tarkkuustasolla. Myöhemmässä vaiheessa voidaan muodostaa summattuja tauluja tarpeen mukaan. Alhaisella tarkkuustasolla mahdollistetaan ad hoc-kyselyt sekä tietoihin porautuminen. Jos tietovarastossa on tallennettu pelkästään summatut tiedot, ei niiden taustalla olevien tietojen tarkasteleminen ole mahdollista ja tämä voi aiheuttaa ongelmia esimerkiksi tiedon luotettavuuden tarkistamisessa. (Kimball & Ross 2013)

Oikean tietomallin valitsemiseksi yrityksellä on oltava riittävä ymmärrys eri mallien välisistä eroavuuksista ja niiden ominaisuuksista. Näiden tietojen pohjalta on mietittävä mikä on omaan liiketoimintaan parhaiten soveltuva menetelmä. Tietoja mallintaessa on myös ymmärrettävä, ettei suora kopio operatiivisesta järjestelmästä ole tehokas ja pitkällä aikavälillä järkevä ratkaisu, vaikka se juuri sillä hetkellä olisikin riittävä. (Kimball & Ross 2013) Tietojen mallinnuksessa tulee huolehtia myös tietojen yhdenmukaisuudesta. Esimerkiksi laskukaavat tulisi olla yhteisesti määriteltyjä ja käytettävät termit linjassa koko tietomallin alueella. (Hovi 2009; Reeves 2009)

Tietovarasto tulee rakentaa niin, että se on käyttäjilleen intuitiivinen ja miellyttävä käyttää. Tätä edesauttaa se, että tietomallia rakennettaessa on otettu huomioon liiketoiminnan rakenteet ja tarpeet sekä yhteisesti määriteltyjen laskukaavojen ja termien käyttö. (Hovi 2009; Reeves 2009) Kun liiketoiminnan edustajat kokevat tietovaraston olevan heille suunniteltu ja vastaavan heidän tarpeisiinsa, saadaan heidät sitoutettua sen käyttöön tehokkaammin. Tietovaraston tulee olla luotettava tietolähde päätöksentekoon, mutta samalla riittävän yksinkertainen käyttäjän näkökulmasta, jotta sen käyttäminen on mielekästä. (Kimball & Ross 2013) Usein käyttäjien vastarintaa tietovarastoa kohtaan voidaan ehkäistä erilaisilla sovelluksilla ja raportointityökaluilla, jolloin liiketoiminnan edustajat eivät ole suoraan yhteydessä tietovarastoon, vaan he tarkastelevat tietoja heille valmiiksi räätälöityjen raporttien kautta.

3. TIETOVARASTON SUUNNITTELU

Tässä luvussa käsitellään tietovaraston suunnitteluun liittyviä aihekokonaisuuksia. Ensin tarkastellaan tietovaraston rakennetta ja arkkitehtuurimalleja sekä asioita, joita pitää ottaa huomioon sopivan arkkitehtuurin valinnassa. Tämän jälkeen tutustutaan tietojen mallinnukseen ja sen eri tasoihin sekä esitellään yleisimpiä tiedonmallinnukseen käytettyjä malleja. Lopuksi käsitellään vielä tietovaraston suunnittelua prosessina ja käydään läpi prosessin eri vaiheet erityispiirteineen.

3.1 Tietovarastoarkkitehtuuri

Tässä alaluvussa tutustutaan tietovaraston rakenteeseen. Ensin käsitellään komponentteja, joista tietovarastointiympäristö koostuu. Sen jälkeen esitellään erityyppisiä tietovarastoarkkitehtuureja, eli malleja, joilla tietovarastointiympäristön komponentit voidaan järjestää. Lopuksi esitellään kriteerejä, joiden avulla voidaan vertailla eri arkkitehtuurien sopivuutta liiketoiminnan tarpeisiin.

3.1.1 Tietovaraston rakenne

Tietovarastointi voidaan jakaa kolmeen pääkokonaisuuteen, joista tietovarastoarkkitehtuuri koostuu. Nämä ovat datan hakeminen lähdejärjestelmistä, datan varastointi sekä informaation toimittaminen liiketoiminnan tarpeisiin. (Vaisman 2014) Nämä kokonaisuudet koostuvat pienemmistä osista, joita kutsutaan tässä yhteydessä tietovaraston komponenteiksi. Keskeisimmät komponentit ovat datalähteet, datan lastaus *(engl. staging),* datan varastointi, metadata ja informaation toimitus. (Ponniah 2010) Tietovaraston rakenne komponentteineen on esitetty kuvassa 4.

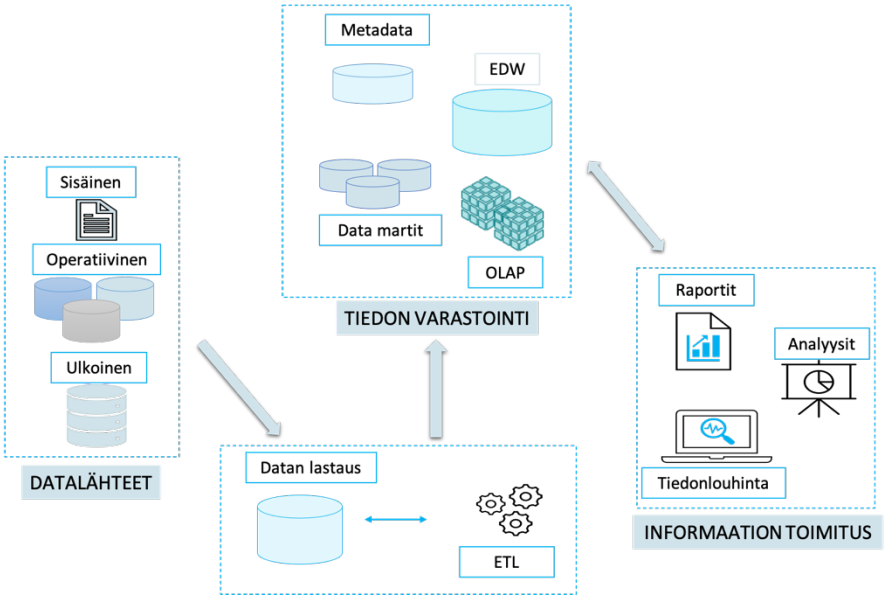

Kuva 4. Tietovaraston komponentit (mukaillen Vaisman 2014)

Datalähteet voidaan jakaa kolmeen kategoriaan kuvan 4 mukaisesti. Datalähteenä voivat olla operatiiviset järjestelmät, muut sisäiset lähteet sekä ulkoiset lähteet. Operatiivisista järjestelmistä saadaan yrityksen liiketoiminnasta muodostuvaa dataa, esimerkiksi transaktiodataa. Muut sisäiset lähteet voivat olla pieniä tietokantoja tai yksittäisiä tiedostoja, jotka sisältävät esimerkiksi laskentataulukoita. (Ponniah 2010) Ulkoiset tietolähteet ovat yrityksen ulkopuolisen toimijan tuottamaa dataa. Ne voivat sisältää esimerkiksi markkinatietoja, kuten talousennusteita tai väestötietoja. Ulkoista tietoa voidaan hyödyntää yhdistämällä sitä yrityksen omaan dataan ja näin luoda parempaa informaatiota johdon päätöksenteon tueksi. (Strand et al. 2003)

Tietojen saamiseksi useista lähdejärjestelmistä yhteen tietovarastoon täytyy tiedot ensin poimia *(engl. extract)* lähdejärjestelmistä, muokata *(engl. transform)* sopivaan esitysmuotoon sekä lopuksi vielä ladata *(engl. load)* tietovarastoon. Tätä kutsutaan ETL-prosessiksi, jonka nimitys tulee edellä mainittujen toimintojen englanninkielisistä nimityksistä. (Chen et al. 2016) Tietojen kokoamiseen datalähteistä liittyy myös erillinen lastausalue *(engl. staging area)*. Ensimmäisessä ETL-prosessin vaiheessa tiedot poimitaan lähdejärjestelmistä. Lähdejärjestelmästä valitaan tarpeelliset tiedot, jotka kopioidaan lastausalueelle odottamaan prosessin seuraavia vaiheita. Lastausalue on välitietovarasto, jossa tiedot odottavat jatkokäsittelyä. (Kimball & Ross 2013)

ETL-prosessin toisessa vaiheessa eli muokkausvaiheessa tiedot muokataan tietovarastoon siirtämistä varten yhdenmukaisiksi oikeaan muotoon. Tiedot voivat olla eri lähdejärjestelmissä hyvinkin toisistaan poikkeavissa formaateissa, joten niiden yhdistämiseksi niitä täytyy ensin muokata. Tiedot puhdistetaan, validoidaan ja tarvittaessa uudelleen

järjestellään. Näiden muokkaustoimenpiteiden avulla pyritään tuottamaan lisäarvoa tekemällä datasta selkeämpää ja puhtaampaa. (Reeves 2009; Kimball & Ross 2013; Chen et al. 2016) Tietoja voidaan esimerkiksi täydentää puuttuvilla oletusarvoilla, korjata kirjoitusvirheitä sekä poistaa mahdollisia duplikaatteja. Tässä vaiheessa voidaan myös laskea ennalta määritettyjä summia tietovarastoon, esimerkiksi yleisesti raporteilla käytettyjä arvoja. (Ponniah 2010)

Kolmas ja viimeinen vaihe prosessissa on tietojen lataaminen tietovarastoon. Tiedot ladataan tietovarastoon valitun tietomallin mukaisesti. Tietomalleja käsitellään tarkemmin luvussa 3.2. Tiedot jäsennetään ja ladataan fyysisesti tietovarastoon varmistaen, että tiedot tulevat järjestelmään oikeassa muodossa. (Kimball & Ross 2013) ETL-prosessin tehtävänä on siis poimia tiedot heterogeenisistä lähdejärjestelmistä ja muokata ne käyttökelpoiseen muotoon lopulta siirtäen ne liiketoiminnan hyödynnettäväksi tietovarastoon (Chen et al. 2016).

Tiedon varastointi on tietovarastoarkkitehtuurin keskeisin rakennusosa. Nykyään suurin osa tietovarastototeutuksista perustuu relaatiotietokantojen tekniikkaan, sillä ne on todettu tehokkaiksi, helppokäyttöisiksi ja joustaviksi. (Ponniah 2010) Tiedon varastointi voidaan mieltää hieman erilaisena kokonaisuutena riippuen valitusta arkkitehtuurista, joihin tutustutaan tarkemmin luvussa 3.1.2. Kuvassa 4 on kuvattu malli, joka sisältää erillisen yrityksen kattavan tietovaraston (EDW) ja data martit ovat oma erillinen kokonaisuutensa.

Yksi keskeinen tiedon varastointiin kuuluva komponentti on metadata. Metadatalla tarkoitetaan tietoa tiedoista. Metadata voidaan luokitella tekniseen ja liiketoiminnalliseen tietoon. Liiketoiminnallinen metadata kuvastaa tietojen merkitystä ja kertoo tietoon liittyvistä yrityksen säännöistä, käytännöistä ja rajoituksista. Tekninen metadata puolestaan kertoo datan rakenteen ja kuinka se on tallennettu tietovarastoon. Tietovarastokontekstissa metadata voidaan jakaa kolmeen osaan: lähdejärjestelmiin, tietovarastoon ja ETL-prosessiin. (Vaisman 2014) Metadata sisältää siis tietoa, joka kuvaa tietovaraston ja -mallien rakenteita sekä tietolähteitä sisältäen skeemat, omistajuustiedot, päivitystiheydet sekä rajoitukset. ETL-prosessien metadata sisältää tiedot tietojen poiminnasta, muokkauksista sääntöineen sekä päivityssäännöistä. (Gardner 1998; Ponniah 2010)

Viimeisenä kokonaisuutena tietovarastointiarkkitehtuurissa on informaation toimitus, joka sisältää erilaiset työkalut, joilla käyttäjät voivat hyödyntää tietovaraston tietoja. Raportointityökaluilla voidaan muodostaa raportteja ja toimittaa ne käyttäjille. (Vaisman 2014) BI-työkaluilla voidaan tuottaa interaktiivisia raportteja, joiden avulla käyttäjä voi

tarkastella saman raportin avulla eri valinnoilla suodatettua dataa (Reeves 2009). Raporttien lisäksi dataa voidaan hyödyntää tilastollisilla työkaluilla analysointia ja visualisointia varten. Tiedonlouhintatyökaluilla käyttäjät voivat luoda laajempia analyysejä ja etsiä erilaisia trendejä datasta. (Vaisman 2014) Esimerkiksi voidaan luoda ennusteita asiakkaiden käyttäytymisestä perustuen historiadataan tai tarkastella vuodenaikojen vaikutusta kokonaismyyntiin.

3.1.2 Erilaiset arkkitehtuurit

Kaikki yritykset ovat keskenään erilaisia ja niillä on erilaiset tarpeet tietovarastoinnille. Tästä syystä tietovarastoarkkitehtuurille ei ole olemassa yhtä oikeaa tapaa, vaan on olemassa useampi arkkitehtuurimalli, joiden pohjalta yritys voi lähteä rakentamaan omaa tietovarastoaan. Tietovarastoarkkitehtuurin valinta tulee tehdä huolellisesti, jotta tietovarastosta tulee toimiva ja se vastaa yrityksen tarpeisiin. (Blazic et al. 2017) Tietovarastoarkkitehtuuri on määritelty rakenne, jota käytetään mallina tietovaraston luomisessa. Erilaisia arkkitehtuurimalleja on useita ja tässä työssä esitellään kirjallisuudesta löytyneet viisi arkkitehtuurimallia:

- Itsenäisten data marttien arkkitehtuuri *(engl. independent data marts architecture)*
- Väyläarkkitehtuuri *(engl. data mart bus architecture)*
- ”Hub and spoke” -arkkitehtuuri *(engl. Hub-And-Spoke architecture)*
- Keskitetty EDW -arkkitehtuuri *(engl. enterprise data warehousing architecture)*
- Hajautettu arkkitehtuuri *(engl. distributed architecture)* (Sen & Sinha 2005; Ariyachandra & Watson 2010; Blazic et al. 2017).

Suurimmat erot arkkitehtuurien välillä löytyy tietojen varastoinnin organisoinnista. Edellä mainitut viisi arkkitehtuurimallia on esitelty kuvassa 5 luvussa 3.3.1 kuvatun tietovaraston rakenteen mukaisesti.

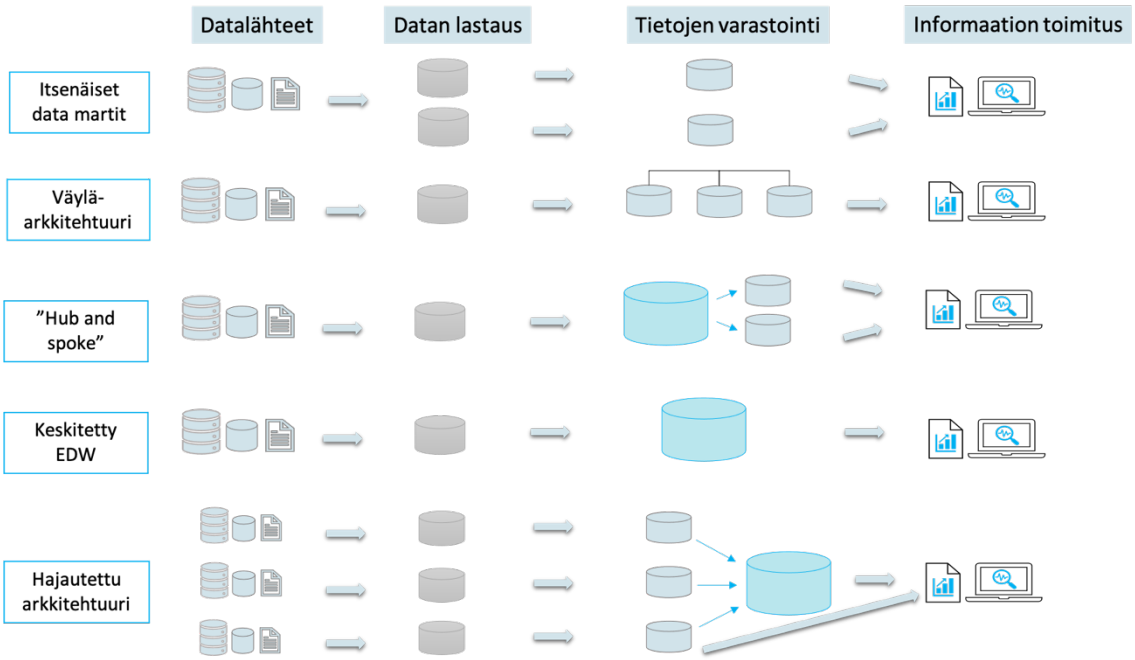

Kuva 5. Tietovarastoarkkitehtuurimallit (mukaillen Sen & Sinha 2005; Ariyachandra & Watson 2010; Blazic et al. 2017)

Itsenäisten data marttien arkkitehtuurimallissa tietovarastointiympäristö koostuu useista data marteista, jotka on suunniteltu ja toteutettu itsenäisiksi kokonaisuuksiksi. Kuvan 5 mukaisesti data ladataan samoista tietolähteistä, mutta datan lastausprosessit ovat erilliset. Yksittäiset data martit ovat suunniteltu yrityksen eri toimintojen tarpeisiin ja voivat sisältää toisistaan hyvinkin poikkeavia tietorakenteita, jolloin tietojen yhteinen analysoiminen hankaloituu. (Ponniah 2010; Blazic et al. 2017) Data marttien eriytyneisyyden vuoksi niiden avulla ei saavuteta ”yhtä totuutta” yrityksestä. Siksi tämän arkkitehtuurin käyttö on nykypäivänä jäänyt vähemmälle ja sen mukaisista tietovarastoratkaisuista on pyritty pääsemään eroon rakentamalla uusia, yhtenäisempiä tietovarastointeja. (Ariyachandra & Watson 2010)

Toinen tapa rakentaa tietovarastoja on väyläarkkitehtuuri. Väyläarkkitehtuurissa tietovaraston kehittäminen alkaa tietyn liiketoimintaprosessin, kuten tilausten, liiketoiminnallisten vaatimusten tunnistamisesta. (Ariyachandra & Watson 2010) Kuvan 5 mukaisesti datan lastaus tapahtuu itsenäisten data marttien arkkitehtuurista poiketen yhteisellä prosessilla. Väyläarkkitehtuurissa datan lastauksen jälkeen ensimmäiseen data marttiin luodaan dimensiot, joita myöhemmin kehitettävien data marttien faktataulut voivat hyödyntää. Näitä kutsutaan mukautetuiksi dimensioiksi, jotka muodostavat arkkitehtuurin nimen mukaisesti väylän itsenäisten data marttien välille. Näin data martit luovat loogisen kokonaisuuden, jonka avulla voidaan saavuttaa ”yksi totuus” yrityksestä. (Ariyachandra & Watson 2010; Ponniah 2010; Kimball & Ross 2013)

”Hub and spoke” -arkkitehtuurissa yritykselle muodostetaan kuvan 5 mukaisesti keskitetty tietovarasto *(engl. Hub)*, josta tieto valuu erillisiin data martteihin *(engl. Spoke).* Data ladataan yrityksen keskitettyyn tietovarastoon tietämättä etukäteen liiketoiminnan tarpeita. Tätä kutsutaan datapohjaiseksi lähestymistavaksi. (Yessad & Labiod 2016) Data tallennetaan keskitettyyn tietovarastoon normalisoidussa muodossa. Keskitetystä tietovarastosta tiedot ladataan erillisiin data martteihin eri liiketoimintojen tarpeiden mukaisesti. Tällä arkkitehtuurimallilla pyritään rakentamaan skaalautuva ja helposti laajennettavissa oleva tietovarasto, josta voidaan hakea suuriakin määriä tietoa analysoitavaksi. (Blazic et al. 2017)

Keskitetyn tietovaraston arkkitehtuurissa tiedot varastoidaan nimensä mukaisesti yhteen, koko yrityksen kattavaan tietovarastoon. Tässä arkkitehtuurimallissa pyritään huomioimaan koko yrityksen vaatimukset ja liiketoiminnalliset tietotarpeet. Erityisen tärkeää on kiinnittää huomiota infrastruktuurin skaalautuvuuteen, jotta voidaan reagoida yritystason muuttuviin vaatimuksiin. (Ariyachandra & Watson 2010) ”Hub and spoke” -arkkitehtuurista poiketen tässä arkkitehtuurimallissa ei rakenneta erillisiä data martteja, vaan kaikki tieto varastoidaan keskitettyyn tietovarastoon, joka voi sisältää integroituja data martteja eri analysointitarpeita varten. (Blazic et al. 2017)

Hajautettua arkkitehtuuria käytetään tilanteissa, joissa olemassa olevia tietovarastoja halutaan integroida analyysitarpeita varten. Erilliset tietovarastot yhdistetään loogisesti tai fyysisesti käyttämällä esimerkiksi liitosavaimia, jaettuja kyselyitä tai globaaleja metatietoja. (Blazic et al. 2017) Tässä arkkitehtuurimallissa informaation toimitus voi tapahtua sekä suoraan erillisistä tietovarastoista että loogisesti tai fyysisesti integroidusta tietovarastosta (Sen & Sinha 2005).

3.1.3 Arkkitehtuurin valinta

Tietovarastoarkkitehtuurin valinta on tärkeä päätös yrityksen strategisten tavoitteiden saavuttamiseksi. Asianmukaisella arkkitehtuurin valinnalla on merkitystä muun muassa tietovarastosta syntyviin kustannuksiin ja mahdollisuuksiin hyödyntää erilaisia BI-sovelluksia liiketoiminnan tukemisessa. Arkkitehtuurilla voidaan mahdollistaa myös tietojen liikkuminen yritysten välillä saumattomasti virtuaaliympäristössä. (Zandi 2014) Tämä on tärkeää etenkin konserneissa, jotka koostuvat useista yrityksistä. Näille yrityksille on liiketoiminnan kannalta merkityksellistä päästä hyödyntämään helposti muiden konsernin yritysten dataa.

Ei ole olemassa valmista ohjetta siihen, mikä arkkitehtuuri on paras valinta, vaan jokaisen tietovarastointiprojektin alussa tulee määrittää kyseiselle tietovarastolle tavoitteet,

joiden pohjalta voidaan arvioida eri arkkitehtuurien sopivuutta. Hajmoosaei et al. (2011) esittelevät 18 parametria, jotka kuvaavat optimaalista arkkitehtuuria. Parametrien avulla voidaan vertailla eri arkkitehtuurien soveltuvuutta yrityksen tarpeisiin. Nämä parametrit ovat esitelty taulukossa 2. Lisäksi taulukossa on esimerkinomaisesti arvioitu aiemmin luvussa 3.1.2 esitellyt keskitetty EDW-arkkitehtuuri sekä itsenäisten data marttien arkkitehtuuri. (Hajmoosaei et al. 2011)

Taulukko 2. Tietovarastoarkkitehtuurien vertailu parametrien avulla (mukaillen Hajmoosaei et al. 2011)

Parametrit	**EDW**	**Data mart**
Paikallinen riippumattomuus	korkea	korkea
Korkea tehokkuus	keskiverto	korkea
Lyhytaikainen toteutus	matala	keskiverto
Varhainen sijoitetun pääoman tuotto	matala	keskiverto
Matala riski	matala	korkea
Joustavuus paikallisissa ja globaaleissa muutoksissa	matala	korkea
Matalat toteutuskustannukset	matala	keskiverto
Matalat hallinta- ja ylläpitokustannukset	matala	korkea
Matalat viestintäkustannukset lokaaleille kyselyille	matala	korkea
Integroitu visio (tietojen eheys)	korkea	korkea
Korkea sietokyky järjestelmävikoja vastaan	matala	korkea
Datamalleja/metatietoja ei tarvitse säätää tietomallin/yleisten metatietojen kanssa	-	matala
Matala verkkoliikenne globaaleille kyselyille	korkea	korkea
Ei tarvetta nopeille, vakaille ja turvallisille verkkoyhteyksille	korkea	korkea
Ei sisällä tarpeettomuuksia	korkea	matala
Ei varastotilan rajoituksia	matala	korkea
Ei ristiriitoja paikallisten ja globaalien kyselyjen välillä	matala	korkea
Tietolähteen ja tietovaraston välinen matala etäisyys	matala	matala

Taulukossa 2 on kuvattu tietovarastoarkkitehtuurien toimintaa ja tietovaraston tarpeita optimaalisissa olosuhteissa, eikä sitä pidä hyödyntää sellaisenaan arkkitehtuurin valinnassa. Näistä parametreista voi kuitenkin ottaa mallia ja määrittää jokaiselle tietovarastoprojektille omat parametrit, joilla vertaillaan eri tietovarastoarkkitehtuureja. Parametrien avulla eri arkkitehtuurien vertailu helpottuu ja valinta pystytään perustelemaan paremmin.

3.2 Tietomallit tietovarastoinnissa

Lähtökohtana tietovaraston suunnittelulle toimii yrityksen tietomalli. Tietomalli on abstrakti kuvaus yksittäisten tieto-objektien yhdistymisestä toisiinsa. (Reeves 2009) Tietomalli voidaan nähdä suuntaa antavana tiekarttana (*engl. roadmap*) tietovarastolle. Sen avulla pysytään selvillä siitä, mitä dataa lopulliseen tietovarastoon tulee ja mistä se löytyy. (Inmon et al. 2019) Tietomalli on mekanismi tietokannan rakenteen dokumentoimiseen ja ymmärtämiseen. Tietomallinnustyyppejä on monia ja niillä on kaikilla omat tavoitteet ja käyttötarkoitukset. (Reeves 2009) Tässä luvussa tutustutaan tietomallinnuksen tasoihin sekä erilaisiin menetelmiin mallintaa tietoa.

3.2.1 Tiedon mallinnuksen tasot

Suunnitellessa tietovarastoa tietoja mallinnetaan eri tasoilla. Korkeimman tason mallit ovat abstrakteja ja enemmänkin vain suuntaa antavia, kun taas tarkimman tason mallit esittävät tiedot hyvin yksityiskohtaisesti. Nämä tiedonmallinnuksen tasot on esitelty kuvassa 6.

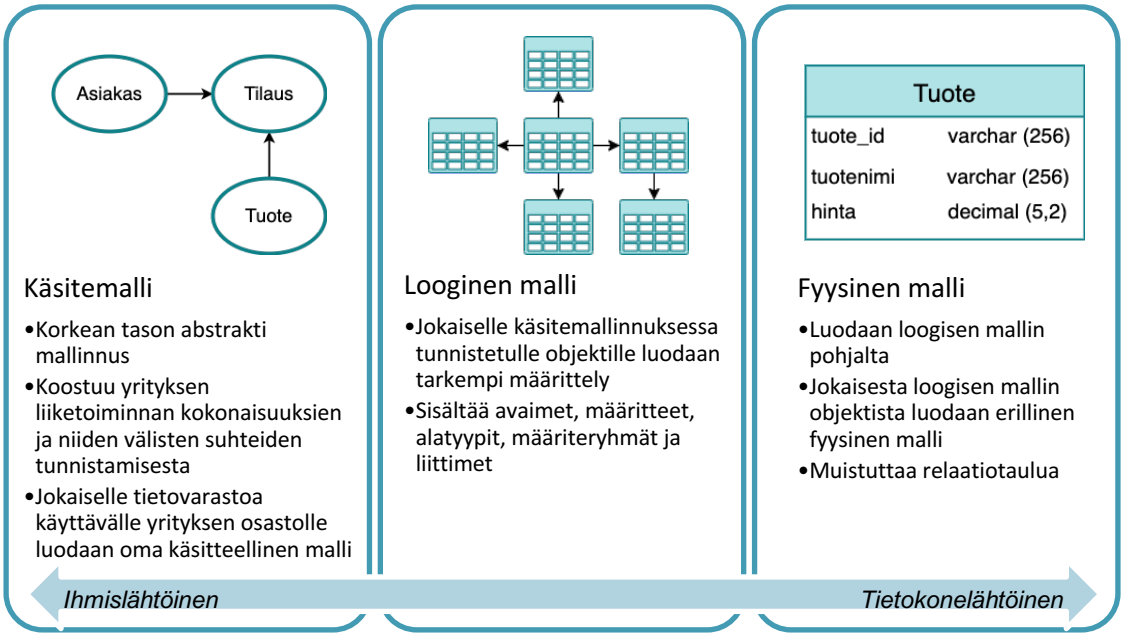

Kuva 6. Tiedonmallinnustasot (mukaillen Inmon 2005; Haq 2016; Inmon et al. 2019)

Tietovaraston suunnittelussa ensimmäisenä mallinnetaan tosielämän objektit korkean tason käsitteiksi. Tästä syntyy käsitemalli, joka on yleensä hyvin abstrakti, mutta voi myös sisältää jo joitain tarkempia yksityiskohtia objekteista. (Haq 2016) Käsitemallin tavoitteena on kuvata yritystä kiinnostavia asioita, joihin liittyviä tietoja halutaan tallentaa tietovarastoon. Malli itsessään kuvaa näiden objektien välisiä suhteita. (Gordon 2017) Kuvan 6 mukaisesti mallinnettava tosielämän objekti voi olla esimerkiksi *asiakas.* Tällöin yrityksen asiakkaat muodostavat kokonaisuuden, joiden tietoja halutaan tarkastella. Mallinnuksessa objekteja kuvataan hyvin yleisellä tasolla ja saman ominaisuuden omaavat objektit muodostavat ryhmiä eli kokonaisuuksia. (Gordon 2017; Inmon et al. 2019)

Mallinnuksen toinen taso on käsitemallia merkittävästi yksityiskohtaisempi. Käsitemalli on ikään kuin karkea luonnos tietomallista, joka sisältää vain objektien perustiedot ja tiedon siitä, kuinka ne ovat vuorovaikutuksessa toisiinsa. Tämän luonnoksen pohjalta lähdetään tarkentamaan mallia seuraavalle tasolle, jota kutsutaan loogiseksi malliksi. (Lee Allen 2005) Kuten kuvasta 6 nähdään, jokaiselle käsitemallissa kuvatulle objektille luodaan oma looginen malli, jossa tunnistetaan loogiset entiteetit ja lisätään niille määrittelevät attribuutit kuten avaimet ja määritteet. (Haq 2016)

Mallinnuksen tarkin taso on fyysinen mallinnus, joka luodaan loogisen mallin pohjalta. Jokainen loogisen mallin attribuutti on kuvattuna ja mallinnuksessa otetaan huomioon lähdedatan fyysinen rakenne. Kuvassa 6 on esitettynä esimerkki yhden taulun fyysisestä tietomallista. Malliin kirjataan muun muassa avaimien sekä indeksien määrittelyt. (Inmon

et al. 2019) Fyysinen tietomalli käyttää oikeaa lähdedataa ja huomioi liiketoiminnan vaatimukset. Fyysisessä tietomallissa voidaan yhdistää entiteettejä tai laskea attribuutteja sekä poistaa vaatimusten näkökulmasta tarpeettomat entiteetit tai attribuutit. (Haq 2016) Fyysisen tietomallin pohjalta tietovaraston luominen on helppoa, sillä tietovaraston taulujen rakenne ja suhteet toisiinsa on kuvattuna mallissa.

3.2.2 Normalisoitu tietomalli

Normalisoitu tietomalli on yksi vanhimmista tavoista mallintaa tietoa. Ensimmäiset sitä käsittelevät artikkelit julkaistiin jo 1970-luvun alussa. (van der Lans 2012) Normalisoidun tietovaraston suunnittelu vastaa operatiivisten järjestelmien tietokantojen suunnittelua. Tämän vuoksi normalisoituja tietovarastoja on rakennettu varsinkin tietovarastojen alkuaikoina. (Sen & Sinha 2005)

Normalisoiduista tietomalleista käytetään yleensä kolmannessa normaalimuodossa olevaa mallia. Se sopii erityisesti keskitettyihin yritystason tietovarastoihin, jotka vaativat suurien tietomäärien yhdistämistä eri lähteistä sekä monimutkaisia liiketoimintakyselyjä. (Haq 2016) Normalisoinnissa taulujen sarakkeet asetetaan siten, että jokainen liiketoiminnan tieto tallennetaan vain kerran tietovarastoon. Tällä pyritään minimoimaan tietovaraston redundanssi eli tietojen toistuminen tietovarastossa. Päällekkäisten tietojen minimoimisella pyritään välttämään tietovaraston epäjohdonmukaisuutta. (van der Lans 2012)

Kolmannen normaalimuodon tietomallissa jokaisella taululla on oltava ensisijainen avain eli rivin yksilöivä tunniste. (Haq 2016) Ensisijaisella avaimella tarkoitetaan relaation valittua tunnistetta, joka voi muodostua yhdestä tai useammasta attribuutista. Taulut yhdistetään toisiinsa käyttämällä vierasavaimia, jotka viittaavat jonkin toisen taulun ensisijaiseen avaimeen. Myös vierasavain voi olla yhdistelmä eri attribuuteista. (Bojičić et al. 2016) Normalisoidussa tietomallissa jokaisen sarakkeen, joka ei ole osa ensisijaista avainta, tulee olla riippuvainen koko avaimesta mutta ei mistään muusta kuin avaimesta. Toisin sanoen kahden sarakkeen, jotka eivät ole osa ensisijaista avainta, välillä ei ole relaatiota toisiinsa. (van der Lans 2012)

Normalisoidussa tietomallissa tieto on atomista eli yksittäistä. Inmonin (2005) mukaan tietojen atomisuus mahdollistaa tietovaraston laajemman hyödyntämisen. Sen avulla voidaan muodostaa äärettömästi eri yhdistelmiä ja näin ollen dataa voidaan analysoida laajemmin. Tämä tukee myös tulevaisuudessa ilmeneviä tietotarpeita ja käyttökohteita, mikä on yksi tietovaraston keskeisiä tarkoituksia. Tästä johtuen malli sopii juuri yritystason tietovarastoihin, sillä sen avulla kyetään palvelemaan laajempaa käyttäjäkuntaa.

(Inmon 2005) Tietojen atomisuus takaa myös minimaalisen redundanssin eikä poikkeukset vaikuta relaatioiden laatuun (Bojičić et al. 2016). Kun tietovarastossa ei ole päällekkäisyyksiä, on tietojen lisääminen, päivittäminen ja poistaminen helpompaa. Tieto on tallennettuna vain yhteen paikkaan, joten jokainen muokkausoperaatio sisältää vain yhden muokattavan rivin. Näin ollen tietovarasto pysyy varmemmin ajan tasalla, kun muokkausta ei tarvitse suorittaa useaan paikkaan. (van der Lans 2012)

3.2.3 Dimensionaalinen tietomalli

Dimensionaalinen mallinnus on muodollinen tekniikka tietomallinnukseen, joka on kehitetty erityisesti vastaamaan liiketoiminnan tarpeisiin. Tekniikkaa on sovellettu tietovarastoinnissa jo usean vuosikymmenen ajan ja sitä tukee laaja valikoima erilaisia tietokantaalustoja ja -työkaluja. (Reeves 2009; Ramachandran et al. 2010) Dimensionaalista mallinnusta voidaan käyttää tietojen järjestämiseen sekä esittämiseen raportointi- ja analysointikäytössä. Mallin painopiste on tietojen esittämisessä liiketoiminnan näkökulmasta. Dimensionaalisen mallinnuksen päätavoitteet ovatkin varmistaa tietovaraston helppokäyttöisyys tarjoten yrityskäyttäjille ymmärrettävää tietoa sekä kyselyjen suorituskyvyn varmistaminen. (Reeves 2009; Kimball & Ross 2013)

Dimensionaalisessa mallissa on kaksi perusosaa: dimensiot ja faktat. Dimensiot ovat liiketoiminnan tärkeimpien tekijöiden pohjalta muodostettuja tieto-objektien ryhmiä. (van der Lans 2012; Kimball & Ross 2013) Dimensioita voivat olla esimerkiksi asiakkaat, tuotteet, päivämäärät ja toimittajat. Yksittäistä tieto-objektia kutsutaan dimensionaaliseksi attribuutiksi tai viitetiedoksi. Viitetietoja käytetään raporttien rivi- ja sarakeotsikoina ja niiden suhteet luovat porautumisreittejä sekä mahdollistavat hierarkioiden määrittelyn raporteilla. (Reeves 2009)

Faktat ovat liiketoiminnan tapahtumien mittareita ja jokainen faktarivi tietovarastossa vastaa yhtä reaalimaailman mittaustapahtumaa. Faktat ovat tyypillisesti määriä ja lukuja, jotka näkyvät raporteilla kokonaisuuksina. Niitä käytetään kaikkien laskelmien perustana. (Hanlin et al. 2012; Kimball & Ross 2013) Faktoja voivat olla esimerkiksi tehdyt tilaukset ja myyntihinnat. Ne ovat liiketoiminnan tekijöitä, joita yrityksessä halutaan seurata. (van der Lans 2012; Yessad & Labiod 2016).

Faktat ovat mielenkiintoisia oikeassa kontekstissa, joka saadaan yhdistämällä ne dimensioihin (Reeves 2009). Esimerkiksi myyntimääristä tulee liiketoiminnan näkökulmasta kiinnostavia vasta, kun ne voidaan liittää esimerkiksi johonkin ajankohtaan tai maantieteelliseen alueeseen. Dimensiot tarjoavat faktoille analyyseihin ja raportteihin akselin, jolla niitä voidaan tutkia ja käyttää apuna päätöksenteossa (van der Lans 2012; Yessad

& Labiod 2016). Dimensiot ovat siis määritteitä, joiden avulla faktoja voidaan ryhmitellä ja tarkastella tietyssä kontekstissa (Hanlin et al. 2012; van der Lans 2012).

Dimensioiden tarve tunnistetaan usein liiketoiminnan vaatimuksista. Mikäli tarvitaan raportteja esimerkiksi myynnistä alueellisesti, viikoittain tai toimistoittain, on näiden kategorioiden oltava dimensioina tietovarastossa. (Reeves 2009) Kaikki liiketoiminnan kannalta merkittävät selitteet ja termit tulee tallentaa dimensioiksi tietovarastoon, jotta raporteista saadaan yhdenmukaisia. Muuten on riskinä, että eri tekijöiden raporteilla käytetään toisistaan poikkeavia termejä, jolloin raporttien vertailu vaikeutuu ja väärien tulkintojen riski kasvaa. (Kimball & Ross 2013)

Tähtimalli (*engl. star schema)* on yksi yleisesti käytetyistä dimensionaalisista suunnittelumenetelmistä. Tähtimalli perustuu relaatiotietokantaan, joka on yleisin tapa kuvata dimensionaalista mallia. (Reeves 2009) Tyypillisesti tähtimalli koostuu faktatauluista, jotka linkittyvät dimensiotauluihin liitosavaimien avulla. (Kimball & Ross 2013) Tähtimallin nimi juontuu sen rakenteesta, joka muistuttaa tähteä. Mallissa faktataulu sijoittuu keskelle ja siihen linkittyy useita dimensiotauluja (van der Lans 2012; Rahim et al. 2013). Tähtimalli tukee hyvin moniulotteista sekä numeerista tietoa ja sopii näin ollen hyvin erilaisiin liiketoiminnan raportointi- ja analytiikkatarpeisiin. (Hovi 2009) Kuvassa 7 on yksinkertaistettu esimerkkikuvaus tähtimallin mukaisesta tietovarastorakenteesta.

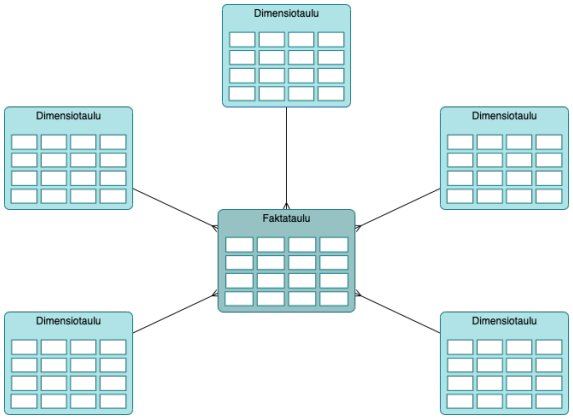

Kuva 7. Tähtimallin mukainen rakenne (mukaillen Rahim et al. 2013)

Tähtimallin etuja ovat ennustettavuus sekä standardoitu rakenne. Monet erilaiset BI- ja kyselytyökalut tukevat sitä. (Hovi 2011) Tähtimallin mukainen tietojen mallinnus vähentää kyselyissä tarvittavien liitosten määrää, mikä parantaa niiden suorituskykyä. Myös kyselyjen muodostaminen on helpompaa, kun taulujen liitoksia on vähemmän ja kyselyt yksinkertaisempia. (van der Lans 2012) Tästä syystä tähtimallin mukaista tietovarastoa on helppo rakentaa, käyttää ja ylläpitää. Tähtimalli on myös joustava ja mahdollistaa liiketoiminnan muuttuviin tarpeisiin vastaamisen sekä tietojen historioinnin. (Hovi 2011; Kimball & Ross 2013) Tähtimallissa faktataulut ovat normalisoituja eli niissä olevat tiedot

esiintyvät vain kerran taulussa. Dimensiotaulut puolestaan ovat denormalisoituja, jolloin sama tieto voi toistua useilla riveillä. (Hovi 2005; van der Lans 2012; Rahim et al. 2013)

Lumihiutalemalli (*engl. snowlake schema)* on toinen yleisesti käytetty dimensionaalinen malli. Malli voidaan nähdä laajennettuna versiona tähtimallista, jossa tähtimallin dimensiotauluja on edelleen jaettu yksityiskohtaisempiin, luokiteltuihin tauluihin. (Ramachandran et al. 2010) Lumihiutalemallissa myös dimensionaaliset taulut voivat olla normalisoituja, mikä erottaa sen tähtimallista. (van der Lans 2012). Lumihiutalemallin yksinkertaistettu esimerkkirakenne on kuvattuna seuraan sivun kuvassa 8.

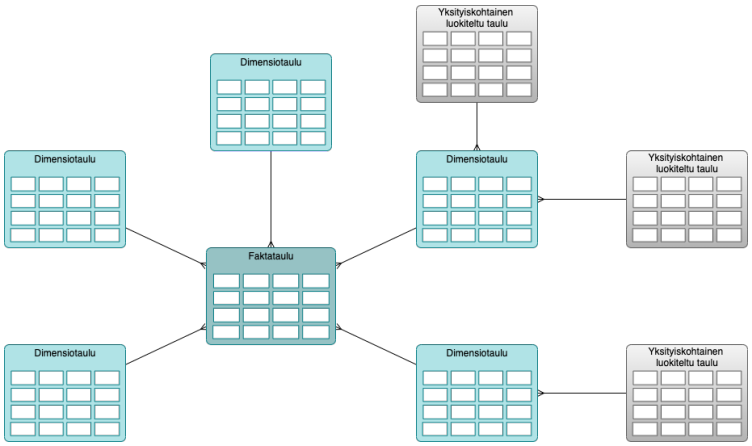

Kuva 8. Lumihiutalemallin mukainen rakenne (mukaillen Li et al. 2010)

Lumihiutalemallissa dimensiotaulut jakautuvat peräkkäisiksi dimensioiksi normalisoinnin seurauksena. Eli tähtimallista poiketen myös dimensiotaulut voivat olla relaatiossa toisiinsa. (van der Lans 2012) Dimensiotaulut voidaan jakaa esimerkiksi hierarkkisiksi tauluiksi, jolloin taulujen vierasavaimet osoittavat taulujen välisen hierarkian (Li et al. 2010). Lumihiutalemalli lisää kyselyissä tarvittavien liitosten määrää, mikä voi heikentää sen suorituskykyä verrattuna tähtimalliin. Kuitenkin erityisesti todella suurien dimensiotaulujen kohdalla lumihiutalemalli on usein suorituskykyisempi. (Ramachandran et al. 2010) Lumihiutalemallissa taulut sisältävät vähemmän duplikoitunutta tietoa hierarkioiden johdosta. Lisäksi malli mahdollistaa tietojen tallentamisen alemmalla tarkkuustasolla verrattuna tähtimalliin, jolloin niitä on mahdollista analysoida ja raportoida tarkemmin. (van der Lans 2012)

3.2.4 Data vault

Data vault on empiriaan pohjautuva tietomalli, jota käytetään tietovaraston mallintamiseen. Malli pyrkii tarjoamaan tiedoille täyden jäljitettävyyden sekä paremman skaalautuvuuden ja mukautuvuuden verrattuna aiemmin esiteltyihin tietomalleihin. Joustavuus lisää myös tietovarastojen tuottavuutta. (Bojičić et al. 2016; Yessad & Labiod 2016) Mallin

suunnittelijan Lindstedtin (2016) mukaan data vault on yksityiskohtainen, historiaa seuraava ja ainutlaatuisella tavalla linkitetty joukko normalisoituja tauluja, jotka tukevat useaa funktionaalista liiketoiminnan aluetta. Data vault on eräänlainen hybriditoteutus kolmannen normaalimuodon ja tähtimallin väliltä. (Olschimke & Linstedt 2016)

Malli pohjautuu havaintoon liiketoimintajärjestelmien objektien muuttumattomista ja yksilöivistä tunnisteista (Linstedt & Graziano 2011b). Objektit määritellään mallissa kahden käsitteen, entiteetti ja attribuutit, avulla. Entiteetti sisältää objektin yksilöivän tunnisteen ja attribuutit kuvaavat entiteettejä. (Bojičić et al. 2016) Data vault voidaan nähdä liiketoimintalähtöisenä tietomallina. Malli kuvaa liiketoimintaprosesseja ja kytkeytyy liiketoimintaan liiketoiminta-avaimien *(engl. business keys)* kautta. (Olschimke & Linstedt 2016)

Liiketoiminta-avaimet ovat tieto-objektien yksilöiviä tunnisteita eli entiteettejä, jotka ovat luonnollinen osa liiketoimintaa. Esimerkiksi asiakasnumero, jolla pystytään tunnistamaan yksittäinen asiakas, voi olla liiketoiminta-avain. Liiketoiminta-avaimet ovat tärkeä ominaisuus data vaultissa, sillä ne osoittavat, kuinka yritykset integroivat, yhdistävät ja käyttävät tietoja järjestelmissään. Liiketoiminta-avaimet mahdollistavat prosessien toteuttamisen tietovarastossa samalla tavalla kuin liiketoiminnan operatiivisessa toiminnassa. (Olschimke & Linstedt 2016) Liiketoiminta-avainten muuttumattomuus mahdollistaa tietojen yksilöimisen myös historiadatassa (Bojičić et al. 2016).

Data vault koostuu kolmesta pääkäsitteestä: **hubit**, **satelliitit** ja **linkit** (Bojičić et al. 2016; Olschimke & Linstedt 2016). Kuvassa 9 on kuvattu yksinkertaistetun esimerkin avulla näiden kolmen pääkäsitteen välisiä suhteita ja rooleja tietomallissa.

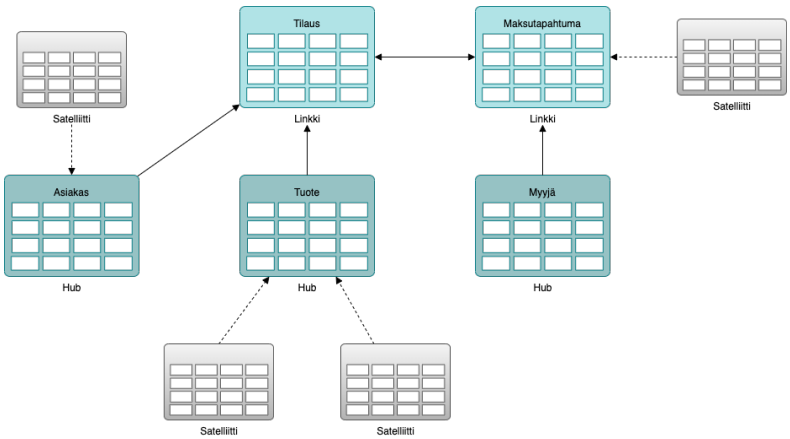

Kuva 9. Yksinkertaistettu esimerkki data vault tietomallista (mukaillen Olschimke & Linstedt 2016)

Hubit edustavat kuvan 9 mukaisesti joukkoa liiketoiminnan järjestelmän objekteja, jotka voidaan yksilöidä liiketoiminta-avaimella. Avainten avulla tietoja voidaan seurata ja tunnistaa läpi historian. Esimerkkejä hubeista ovat asiakas ja tuote. (Bojičić et al. 2016;

Yessad & Labiod 2016) Hubin rakennetta kuvataan yhden tai useamman satelliitin avulla. Hubien ominaisuudet voidaan jakaa satelliitteihin useilla eri kriteereillä, kuten lähdejärjestelmän, muutosnopeuden tai tietotyypin perusteella. Hubit voivat liittyä toisiinsa erilaisilla relaatioilla, joita kuvataan linkeillä. (Linstedt & Graziano 2011b; Bojičić et al. 2016)

Linkit ovat objekteja, jotka yhdistävät hubit toisiinsa. Kuvan 9 mukaisesti myös linkkien väliset suhteet ovat mahdollisia. Linkki luodaan aina, kun uusi objektien välinen yhteys määritetään tietomallissa. Linkit ovat data vaultin joustavia komponentteja ja ne luodaan, kun objektit ovat keskinäisessä vuorovaikutuksessa. Linkit eivät sisällä muita objekteja kuvailevia tietoja. (Linstedt & Graziano 2011a; Hultgren 2012) Linkin tarkoituksena on tallettaa tietoelementtien menneisyyden, nykyisyyden ja tulevaisuuden relaatiot. Tämä mahdollistaa data vault mallin joustavuuden ja skaalautuvuuden sallimalla muutoksien tekemisen tietovaraston rakenteeseen menettämättä tietojen auditoitavuutta eli niiden merkityksellisyyden arvioitavuutta. (Linstedt & Graziano 2011a; Adriano 2013)

Satelliitit ovat aikaulotteisia tauluja, jotka sisältävät yksityiskohtaisia kuvaavia tietoja hubien ja linkkien sisältämistä tiedoista. Ne antavat kontekstin objektien liiketoimintaavaimille. (Yessad & Labiod 2016) Satelliiteilla voi olla vain yksi emotaulu, jota ne kuvaavat, mutta yhtä hubia tai linkkiä voi kuvata useampi satelliitti kuvan 9 mukaisesti. Satelliittien suunnitteluun ja rakentamiseen voidaan käyttää useita lähestymistapoja, mutta yleisimpiä tapoja järjestellä tietoja ovat esimerkiksi aihealueittain, tietotyypin tai -luokituksen mukaan sekä aiemmin mainitut lähdejärjestelmä tai tietojen muutosnopeus. Satelliitit eivät sisällä omaa sekvenssitunnistetta eivätkä ne voi sisältää vierasavaimia lukuun ottamatta hubeja tai linkkejä, joihin ne on liitetty. Satelliitin pakolliset attribuutit ovat hubin tai linkin sekvenssitunniste, latausaikaleima ja tietolähde. (Linstedt & Graziano 2011a) Latausaikaleimojen perusteella voidaan jäljittää, milloin hubien tai linkkien sisältämät tiedot ovat muuttuneet.

3.3 Tietovaraston suunnittelu prosessina

Tietovaraston suunnittelu ja kehittäminen on tarkkuutta ja aikaa vaativa prosessi, jossa tulee edetä järjestelmällisesti, jotta saadaan rakennettua toimiva tietovarasto vastaamaan yrityksen liiketoiminnan tarpeita. Tietovaraston kehitysprosessi mukailee perinteistä ohjelmiston kehitysprosessia, johon kuuluvia vaiheita ovat vaatimusten määrittely, suunnittelu ja toteutus. Ohjelmistokehityksestä on kirjoitettu useita tieteellisiä julkaisuja, mutta harvat niistä käsittelevät pelkästään tietovaraston kehittämistä. Nämä julkaisut ovat useimmiten käytännön kokemuksiin pohjautuvia ja perustuvat kirjoittajien omiin ko-

kemuksiin tietovaraston kehityksestä. Tieteellisesti on esitelty muutamia lähestymistapoja tietovaraston kehitykseen, mutta usein nämä menetelmät ovat olleet liian monimutkaisia, jotta niitä voitaisiin käyttää oikeassa liiketoimintaympäristössä. (Malinowski & Zimányi 2008) Tässä tutkimuksessa pyritään esittelemään yleisimmät ominaisuudet käytetyimmistä menetelmistä sen sijaan, että pyrittäisiin vertailemaan kaikki mahdolliset kirjallisuudesta löytyneet viitekehykset ja etsimään niistä paras vaihtoehto.

Tässä luvussa tutustutaan tarkemmin erilaisiin lähestymistapoihin, joilla tietovarastoa voidaan lähteä suunnittelemaan. Tämän jälkeen esitellään tietovaraston suunnittelun vaiheet, joihin lopuksi syvennytään vielä tarkemmin.

3.3.1 Lähestymistapa tietovaraston suunnitteluun

Ponniahin (2010) mukaan tietovaraston suunnittelua voidaan lähestyä kahdesta erilaisesta näkökulmasta, bottom-up tai top-down lähestymistavalla. Bottom-up lähestymistavassa otetaan tarkasteluun yksittäinen kokonaisuus yrityksestä. Aluksi rakennetaan erillisiä data martteja tarkasteltavan kokonaisuuden tarpeisiin. Tarpeen tullen data martteja voidaan myöhemmässä vaiheessa yhdistää toisiinsa. (Ponniah 2010) Aiemmin tarkastelluista arkkitehtuurimalleista esimerkiksi väyläarkkitehtuuri noudattaa tätä lähestymistapaa (Sen & Sinha 2005; Ariyachandra & Watson 2010; Kimball & Ross 2013).

Top-down lähestymistapa puolestaan keskittyy luomaan kokonaiskuvan yrityksestä. Siinä kerätään vaatimuksia koko yritykseltä ja pyritään luomaan tietovarasto, joka vastaa kaikkien käyttäjien tarpeisiin. (Malinowski & Zimányi 2008) Vaikka tavoitteena on luoda koko yrityksen kattava tietovarasto, ei sitä ole tarpeen rakentaa kerralla. Kehittäminen voidaan tehdä paloissa, joista muodostuu vähitellen koko yrityksen kattava kokonaisuus. (Inmon 2005). Arkkitehtuurimalleista esimerkiksi hub-and-spoke – arkkitehtuuri lähestyy tietovaraston suunnittelua tästä näkökulmasta (Inmon 2005; Sen & Sinha 2005; Ariyachandra & Watson 2010)

Koko yrityksen kattava tietovaraston suunnittelu ja toteuttaminen top-down lähestymistavalla on monille yrityksille suuri ponnistus niin kustannuksiltaan kuin kestoltaan. Siksi monesti päädytään yksinkertaisempaan bottom-up lähestymistapaan. (Malinowski & Zimányi 2008) Inmonin (2005) mukaan suuri resurssitarve on yksi merkittävimmistä syistä siihen, miksi esimerkiksi itsenäisten data marttien arkkitehtuuri on niin suosittu, vaikka niiden avulla ei välttämättä saavuteta tahdottua koko yrityksen kattavaa tietovarastoa ja ”yhtä totuutta”. Koko yrityksen kattava tietovarasto on kuitenkin mahdollista saavuttaa ilman suuria alkuinvestointeja yhdistämällä näiden kahden lähestymistavan

ominaisuuksia. Ponniah (2010) on esitellyt yhdistetyn tavan suunnitella tietovarasto käyttämällä pohjana top-down lähestymistapaa, jossa luodaan kokonaiskuva yrityksestä ja kerätään vaatimukset koko yrityksen laajuudelta. Niiden pohjalta valitaan tietovaraston arkkitehtuuri ja määritellään yksittäisten data marttien rakenne. Lopuksi data martteja kehitetään yksitellen huolellisesti tehdyn suunnitelman perusteella. (Ponniah 2010)

3.3.2 Suunnittelun vaiheet

Kimball et al. (2011) mukaan tietovarastoprojekti voidaan jaotella ohjelmistokehityksestä tutun elinkaarimallin mukaisesti kuuteen eri vaiheeseen: projektin suunnittelu, vaatimusten määrittely, suunnittelu, toteutus, käyttöönotto ja ylläpito. Ponniahin (2010) mukaan merkittävin ero perinteiseen ohjelmistoprojektiin on suunnittelu- ja toteutusvaiheen jakautuminen kolmeen toisistaan erilliseen prosessiin. Kimballin elinkaarimalli tietovaraston kehittämiseen on esitelty kuvassa 10.

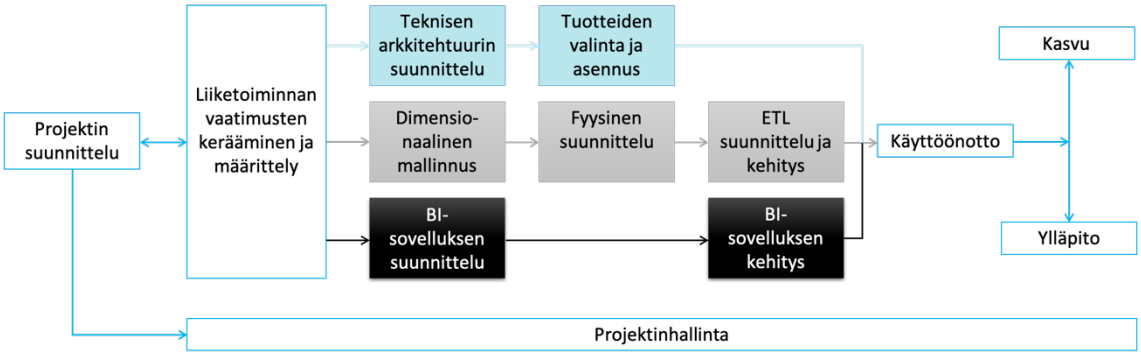

Kuva 10. Kimballin elinkaarimalli (mukaillen Kimball et al. 2011)

Elinkaarimalli kuvaa tietovarastoprojektiin kuuluvat komponentit ja niiden väliset suhteet, jotka ovat tärkeitä projektin onnistumiseksi. Käytössä olevat teknologiat eivät yksistään riitä takaamaan onnistumista, vaan tarvitaan eri tehtävien oikea-aikaista suorittamista oikeassa järjestyksessä. (Kimball et al. 2011) Kimballin elinkaarimallin jakoa rinnakkaisiin prosesseihin tukee myös Ponniahin (2010) tietovarastoarkkitehtuurin jako kolmeen osa-alueeseen: datan hakeminen, varastointi ja informaation toimitus (Ponniah 2010). Kimballin elinkaarimallissa nämä rinnakkaiset prosessit on nimetty data-, teknologia- ja liiketoimintatiedon hallintasovellusten radaksi. Lisäksi elinkaarimalliin kuuluu projektinhallinta omana kokonaisuutenaan, joka kulkee kuvassa 10 prosessin alapuolella koko projektin ajan. (Kimball et al. 2011)

Ylimpänä kuvan 10 elinkaarimallissa kulkee teknologiarata. Sen tavoitteena on suunnitella tietovarastoinnissa käytettävä tekninen arkkitehtuuri eli teknologiat ja tuotteet. Keskimmäisenä kulkeva datarata puolestaan tähtää tiedon fyysiseen mallinnukseen käsit-

teellisen mallin pohjalta ja lähdejärjestelmien datan poimimiseen. Alimpana kulkeva liiketoimintatiedon hallintasovellusten rata keskittyy valitsemaan työkalut, joita käytetään informaation toimittamiseen ja analysointiin. (Kimball et al. 2011) Tässä tutkimuksessa keskitytään elinkaarimallin vaiheisiin ennen käyttöönottoa eli nimenomaan tietovaraston suunnitteluun.

Reeves (2009) esittelee optimaalisen prosessin tietovaraston suunnittelulle. Se pohjautuu liiketoiminnan vaatimusten selvittämiseen kuten aiemmin esitelty top-down lähestymistapa. Malli muistuttaa Kimballin elinkaarimallia, mutta siinä ei ole eritelty vaiheita niin yksityiskohtaisesti. Tämä optimaalinen tietovaraston suunnitteluprosessi esitelty kuvassa 11.

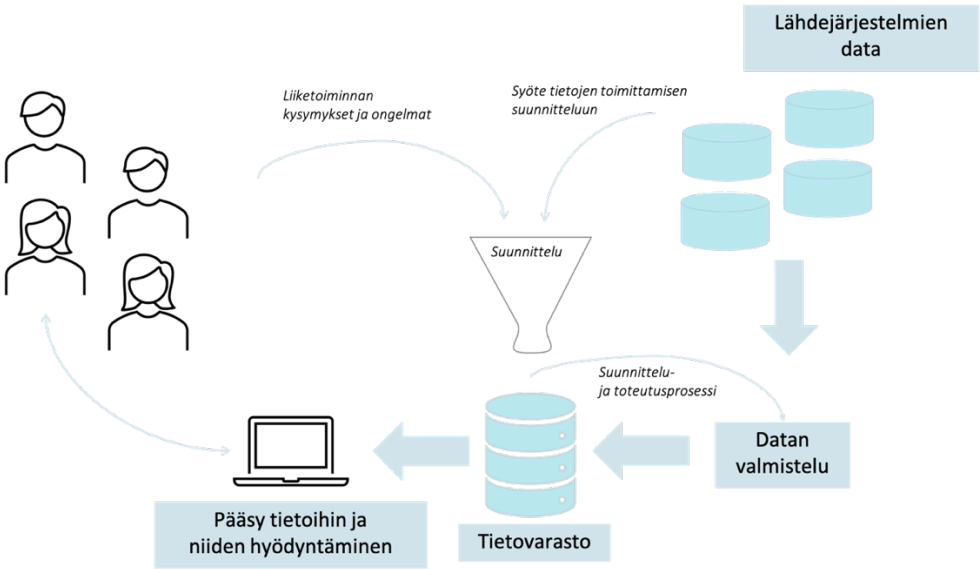

Kuva 11. Optimaalinen tietovaraston suunnitteluprosessi (mukaillen Reeves 2009)

Optimaalinen tietovaraston suunnitteluprosessi lähtee liikkeelle liiketoiminnan tarpeista ja toiveista, aivan kuten Kimballin elinkaarimallikin. Toimivan tietovaraston rakentaminen edellyttää liiketoiminnan perusteiden ja tarpeiden ymmärtämistä. Tietovarastokehittäjien täytyy muodostaa kokonaiskuva liiketoiminnasta ja olla tietoisia yrityksen haasteista sekä strategisista suunnitelmista, joilla liiketoimintaa kehitetään. (Reeves 2009; Kimball et al. 2011) Määritellyt vaatimukset vaikuttavat tietovarastoon koko sen elinkaaren ajan, joten on tärkeää, että ne tehdään huolellisesti. Vaatimukset vaikuttavat muun muassa siihen, millaisia teknologioita, tietomalleja ja arkkitehtuureja tietovarastolle valitaan. (Kimball et al. 2011) Liiketoiminnan vaatimusten keräämiseen syvennytään tarkemmin luvussa 3.3.4.

3.3.3 Projektin suunnittelu

Kimballin elinkaarimallin ensimmäinen vaihe on projektin suunnittelu. Projektilla Kimball et al. (2011) viittaa iteraatioihin elinkaarimallin alusta loppuun eli vaatimusten määrittelystä käyttöönottoon. Projektin suunnittelu sisältää kolme vaihetta: määrittelyn, suunnittelun ja hallinnan. Tietovaraston suunnittelu ei poikkea juurikaan perinteisestä ohjelmistokehitysestä projektin suunnittelun ja -hallinnan näkökulmasta. Merkittävin ero tavalliseen ohjelmistokehitykseen on projektissa mukana olevat sidosryhmät, kuten liiketoiminnan edustajat, ja heidän roolinsa. Monialaiset sidosryhmät tuovat lisävaatimuksia projektin seurannalle, dokumentoinnille sekä kommunikaatiolle, mikä täytyy ottaa huomioon jo projektin suunnitteluvaiheessa. (Kimball et al. 2011)

Projektin määrittelyn ensimmäinen vaihe on arvioida projektitiimin valmiudet kehittää tietovarasto. Kimball et al. (2011) määrittelevät kolme tärkeintä kriteeriä, joiden on oltava kunnossa ennen projektin aloittamista. Ensimmäinen kriteeri on projektin liiketoimintasponsori. Tietovarastohankkeella on oltava vahva tuki liiketoiminnan puolelta. Liiketoimintasponsorin tehtävänä on määritellä visio tietovaraston hyödyntämiselle sekä auttaa muita yrityksessä ymmärtämään tietovaraston tärkeys ja merkitys liiketoiminnan näkökulmasta. (Kimball et al. 2011) Jokaisella projektin sidosryhmällä tulee olla ymmärrys siitä, miksi tietovarastoa ollaan kehittämässä. Syyt tietovaraston tarpeellisuudelle voivat olla hyvinkin yksinkertaisia ja abstrakteja, kuten johtajien päätöksenteon tukeminen, mutta ne täytyy olla kaikkien tiedossa. (Gucer et al. 2005)

Toisena vaatimuksena projektin aloittamiselle on tietovaraston hyväksyminen liiketoiminnan työkaluksi. Mikäli liiketoiminta ei ole omaksunut ajatusta tietovaraston hyödyntämisestä osana päätöksentekoa, on sen rakentaminen resurssien tuhlaamista. Kolmas kriteeri on tietovaraston toteutettavuus. (Kimball et al. 2011) Ennen projektin aloittamista tulee varmistaa, onko dataa saatavilla tietovarastointiin sopivassa muodossa ja onko se tarpeeksi puhdasta. Dataa voidaan puhdistaa tietovarastointia tehdessä, mutta jos lähdedata on liian virheellistä ja puutteellista, ei sitä voida välttämättä puhdistaa riittävästi, jotta siitä saataisiin analysointikelpoista (Squire 2015). Mikäli data ei täytä näitä vaatimuksia, on usein edessä vaativia toimenpiteitä, ennen kuin tietovaraston rakentaminen on kannattavaa (Kimball et al. 2011).

Kun tietovarastoprojektille asetetut kriteerit on täytetty, on seuraavaksi määriteltävä projektin laajuus. Tietovarastoprojekti voi olla lyhyen aikavälin ratkaisu yksittäiseen tarpeeseen tai pidemmän aikavälin projektina toteutettava koko yrityksen kattava tietovarastoratkaisu. Laajuus riippuu myös valitusta lähestymistavasta, top-down lähestymistavalla laajuus on suurempi kuin bottom-up lähestymistavalla toteutettavissa projekteissa.

(Kimball et al. 2011) Kaikilla projektin sidosryhmillä tulee olla riittävä ymmärrys projektin laajuudesta, jotta voidaan ymmärtää projektin merkityksellisyys ja ennakoida tilannetta, jossa projektista on ilmennyt pelkkiä kuluja ilman mitään konkreettisia tuloksia. Mikäli on valittu pitkän aikavälin lähestymistapa, on hyväksyttävä, että tulokset näkyvät vasta pitkän ajan päästä. (Gucer et al. 2005)

Seuraavaksi on projektin suunnittelun vuoro. Tässä vaiheessa määritellään projektin roolit. Tietovarastoprojekti vaatii useita erilaisia rooleja niin liiketoiminnan kuin IT:nkin puolelta. Kimball et al. (2011) jakaa roolit seuraavasti: liiketoiminnan tukijat, valmentajat, kehitystiimi, erikoistiimi ja lisäksi joukko sekalaisia rooleja, kuten mahdolliset konsultit. Tietovaraston kehittäminen vaatii osaamista laaja-alaisesti, joten tiimien on oltava lähes poikkeuksetta monialaisia. Tämä onkin yksi merkittävä ero tavalliseen ohjelmistoprojektiin ja se on otettava huomioon projektin suunnittelussa. (Ponniah 2010)

Lopuksi laaditaan konkreettinen projekti- ja kommunikointisuunnitelma. Projektisuunnitelmaan määritellään projektin aikaiset tehtävät riittävän tarkasti ja kommunikointisuunnitelman avulla luodaan käytännöt eri sidosryhmien väliselle kommunikaatiolle, jotta projektipäällikkö on ajan tasalla kaikkien tarpeista. (Kimball et al. 2011) Kimballin elinkaarimallin (kuva 10) mukaisesti projektin suunnittelu ja liiketoiminnan vaatimusten määrittely voivat olla osittain rinnakkaisia. Kun liiketoiminnan vaatimukset tarkentuvat määrittelyn aikana, voi olla tarpeen palata tarkastamaan projektisuunnitelmaa, jotta se vastaa tarkentuneisiin liiketoiminnan vaatimuksiin. (Kimball & Ross 2013)

3.3.4 Vaatimusten määrittely

Projektin suunnittelun jälkeen on aika siirtyä määrittelemään liiketoiminnan vaatimuksia. Kuten aiemmin jo todettiin, voivat projektin suunnittelu ja liiketoiminnan vaatimusten määrittely olla osittain päällekkäisiä, sillä joskus voi olla tarpeen tarkentaa projektisuunnitelmaa vielä liiketoiminnan tarpeiden määrittelyn jälkeen. Liiketoiminnan vaatimuksia voidaan kerätä karkeasti jaoteltuna kolmella tavalla: datavetoisesti, tavoitevetoisesti ja käyttäjävetoisesti. Datavetoisessa lähestymistavassa pyrkimyksenä on kehittää tietovarasto yrityksen datan pohjalta eikä liiketoiminnan vaatimusten tai erilaisten tietotarpeiden perusteella. Tässä lähestymistavassa tietotarpeiden ajatellaan syntyvän vasta, kun käyttäjä pääsee tutkimaan tietovarastoa. (List et al. 2002) Tavoitevetoisessa lähestymistavassa ajatellaan, että käyttäjät eivät pysty muodostamaan tarkkoja vaatimuksia tietovarastolle, vaan vaatimukset syntyvät analysoimalla liiketoimintavaatimuksia ja -prosesseja. (Malinowski & Zimányi 2008)

Käyttäjävetoisessa lähestymistavassa käyttäjät ovat keskeisessä roolissa, aivan kuten Reevesin (2009) optimaalisessa suunnitteluprosessissa ja Kimball et al. (2011) elinkaarimallissa. Vaatimusten määrittelyyn valitaan käyttäjiä yrityksen eri tasoilta, jotta saadaan muodostettua mahdollisimman kattava kuva liiketoiminnan tarpeista. (Malinowski & Zimányi 2008; Reeves 2009; Kimball et al. 2011) Liiketoiminnan edustajien avulla määritetään liiketoiminnan tavoitteet ja keskeisimmät kysymykset, kuten kuvassa 11. Näiden pohjalta muodostetaan tietovarastolle rakenne. (List et al. 2002)

Reeves (2009) jakaa liiketoiminnan vaatimukset neljään kategoriaan: liiketoiminnan kokonaiskuva, raportit ja laskukaavat, tietolähteet sekä strategiset vaatimukset. Kategoriat muodostavat pohjan tietovaraston vaatimusten määrittelylle. (Reeves 2009) Kuvassa 12 esitellään tietovaraston vaatimusten kerääminen prosessina ja kategoriat sisältöineen.

Kuva 12. Tietovaraston vaatimustenkeräysprosessi (mukaillen Reeves 2009)

Ensimmäisenä kuvassa 12 ovat strategiset vaatimukset. Niillä tarkoitetaan yrityksen visiota ja yleisiä tavoitteita liiketoiminnassa. Tavoitteena on saada esille yrityksen suurimmat tietotarpeet. (Williams 2016) Nämä vaatimukset sisältävät muun muassa tietoihin liittyvien ongelmien tunnistamisen sekä niiden liittämisen liiketoiminnan vaatimuksiin. Esimerkiksi epätarkat myyntiluvut voivat aiheuttaa ongelmia tilien tarkastuksessa. Strategiset vaatimukset ovat yleensä yrityksen ylimmän johdon asettamia. (Reeves 2009)

Toisena kuvassa 12 on liiketoiminnan yleiskuvan selvittäminen. Ennen kuin voidaan ruveta määrittämään yksittäisten raporttien ja analyysien sisältöjä, tulee olla selvillä laajemmin yrityksen liiketoiminnan kokonaiskuva. Tässä vaiheessa pyritään selvittämään yrityksen liiketoiminnan haasteita sekä tavoitteita erilaisten analyysien avulla. (Gendron 2014) Tietoja kerätään haastattelemalla liiketoiminnan eri toiminnoista vastaavia henkilöitä ja suorittamalla esimerkiksi projektin tarpeisiin kohdennettu yritysanalyysi. Yleiskuvan muodostamisen jälkeen määritellään yrityksen raportointi- ja analytiikkatarpeet. (Reeves 2009) Raportointitarpeita voidaan selvittää esimerkiksi tutustumalla jo ole-

massa oleviin raportteihin ja miettimällä ideoita niiden kehittämiseksi. Raporttien käyttäjiä haastattelemalla voidaan selvittää, mitkä raporteista ovat tarpeellisia ja mitä tärkeitä tietoja niistä mahdollisesti puuttuu. Käyttäjiltä voidaan kerätä myös kokemuksia raporttien luotettavuudesta, jotta tähän voidaan tarpeen vaatiessa kiinnittää huomiota uuden tietovaraston toteutuksessa. (Kimball et al. 2011)

Kun liiketoiminnan vaatimukset on ymmärretty, siirrytään tutkimaan lähdejärjestelmien tietoja. Liiketoiminnalla voi olla paljon toiveita ja visioita siitä, mitä tiedoilla halutaan tehdä, mutta aluksi on selvitettävä, mikä on mahdollista olemassa olevien tietojen pohjalta. Jotta tietoja voidaan hyödyntää liiketoiminnassa mahdollisimman tehokkaasti, täytyy ne olla jäsennettynä järkevästi tietovarastoon. (Gendron 2014) Tietojen tulee olla liiketoiminnan tarpeita vastaavassa muodossa ja järjestetty niin, että niiden saamiseksi tarvitaan ainoastaan yksinkertaisia kyselyjä. Tämä suunnittelu perustuu liiketoiminnan vaatimuksiin ja olemassa olevaan raakadataan. (Reeves 2009) Kimballin elinkaarimallin mukaisessa suunnittelussa projektin edellytyksenä on tietovaraston toteutettavuus. Mikäli tämä vaihe on toteutettu, on lähdejärjestelmien dataan tutustuttu jo aikaisemmin ja tässä vaiheessa voidaan keskittyä siihen, miten liiketoiminnan vaatimuksiin voidaan vastata parhaiten ja ovatko jotkin niistä jopa mahdottomia toteuttaa saatavilla olevalla datalla. (Kimball et al. 2011)

3.3.5 Suunnittelu ja toteutus

Kimballin elinkaarimallissa (kuva 10) tietovarastoprojektin suunnittelu- ja toteutusvaihe jaetaan kolmeen rinnakkaisprosessiin: teknologia-, data- ja liiketoimintatiedon hallintasovellusten rata (Kimball et al. 2011). Vaikka elinkaarimallissa vain projektin suunnittelun ja liiketoiminnan vaatimusten määrittelyn välillä on kaksisuuntainen nuoli, tapahtuu todellisuudessa muidenkin vaiheiden kohdalla palaamista aiempiin vaiheisiin, etenkin kun kehittämisessä noudatetaan iteratiivisia ketteriä ohjelmistokehityksen viitekehyksiä. (Malinowski & Zimányi 2008)

Ylimpänä kuvassa 10 kulkee teknologiarata. Sen tarkoituksena on suunnitella tietovarastossa käytettävä tekninen arkkitehtuuri sekä päättää ne teknologiat ja tuotteet, joilla valittu arkkitehtuuri voidaan toteuttaa. (Kimball et al. 2011) Teknologiaradan ensimmäinen vaihe on teknisen arkkitehtuurin suunnittelu. Se pitää sisällään kuvassa 4 esiteltyjen datan lastaus-, tiedon varastointi- ja informaation toimituskokonaisuuksien sisältämien komponenttien suunnittelun. (Ponniah 2010) Arkkitehtuurin suunnittelussa määritellään vaatimukset arkkitehtuurille ja luodaan korkean tason malli, tunnistetaan mahdolliset alijärjestelmät ja arkkitehtuurin toteutuksen vaiheet. Lopuksi vielä katselmoidaan ja viimeis-

tellään arkkitehtuurin määrittelyt. (Kimball et al. 2011) Tämän vaiheen aikana valitun arkkitehtuuritiimin tehtävänä on määritellä toiminnallisuudet kaikille arkkitehtuurissa määritellyille tietovaraston komponenteille. Tämä määrittely toimii eräänlaisena pohjapiirustuksena tietovarastolle. (Ponniah 2010)

Toinen vaihe teknologiaradalla on tuotteiden valinta ja asennus. Arkkitehtuurisuunnitelman pohjalta valitaan tuotteet, jotka tukevat arkkitehtuurin toiminnallisuutta, kuten laitteistot, tietokannanhallintajärjestelmä sekä ETL- ja raportointityökalut. Tuotteiden valinnassa käytetään apuna liiketoiminnan vaatimuksia, jotta voidaan muodostaa parhaiten niihin vastaava tietovarasto. (Ponniah 2010; Kimball et al. 2011)

Teknologioiden valinnassa on erityisen tärkeää kiinnittää huomiota tietokannanhallintajärjestelmän valintaan. Westermanin (2001) ja Silversin (2008) mukaan niitä tulee vertailla kolmen pääkriteerin avulla. Kriteerit ovat tietokannanhallinta- ja lähdejärjestelmän yhteensopivuus, ylläpito sekä lineaarisen kasvun mahdollistaminen. (Westerman 2001; Silvers 2008) Myös Inmonin (2005) mukaan yleisiä vaatimuksia tietokannanhallintajärjestelmille on niiden kyky hallita suurta datamassaa, monipuolisen indeksoinnin mahdollistaminen sekä datan helppo monitorointi. Lisäksi järjestelmän tulisi tarjota riittävät rajapinnat niin lähdejärjestelmille kuin raportointityökaluille. (Inmon 2005) Näiden lisäksi teknologiaradan toisessa vaiheessa on tarkoitus suorittaa markkinatutkimus, arvioida tuotteet, muodostaa prototyyppi sekä neuvotella tuotteiden toimittajien kanssa (Kimball & Ross 2013).

Kuvassa 10 keskimmäisenä kulkeva datarata koostuu kolmesta vaiheesta: dimensionaalinen mallinnus, fyysinen suunnittelu sekä datan lastauksen suunnittelu. Dimensionaalinen malli muodostetaan liiketoiminnan vaatimusten määrittelyn pohjalta, luvun 3.2.3 kuvaamalla tavalla. Elinkaarimalli pohjautuu väylällä integroitujen data marttien arkkitehtuuriin, minkä vuoksi käytössä on dimensionaalinen mallinnus. (Kimball et al. 2011) Tässä voidaan kuitenkin käyttää muitakin luvussa 3.2. esiteltyjä mallinnustapoja riippuen valitusta arkkitehtuurista. Dimensionaalisen mallinnuksen vaihe voidaan jakaa käsitteellisen ja loogisen mallinnuksen vaiheeksi. Nämä tietomallinnuksen tasot on esitelty luvussa 3.2.1. Tässä vaiheessa siis päätetään tietovaraston arkkitehtuuri ja käytettävä tietomalli (Silvers 2008).

Seuraavaksi muodostetaan fyysinen malli edellisessä vaiheessa muodostetun mallin pohjalta. Aikaisemmin luotu tietomalli muutetaan valitusta fyysisestä tietokannanhallintajärjestelmästä riippuvaiseksi malliksi. (Kimball et al. 2011) Tässä vaiheessa päätetään

muun muassa tietovarastoon tulevien taulujen sarakkeille nimet ja tietotyypit, määritellään pää- ja vierasavaimet sekä null-arvot. Lisäksi määritetään tietovaraston optimointia varten indeksit ja summataulut. (Kimball & Ross 2013)

Viimeinen vaihe dataradalla pitää sisällään ETL-prosessin toteutuksen (Kimball et al. 2011). ETL-prosessin toteuttaminen koostuu kahdesta vaiheesta. Ensin analysoidaan lähdedatan rakenne ja sisältö, jonka jälkeen lähdejärjestelmien data yhdistetään tietovaraston tietomalliin. Tuloksena tästä vaiheesta tulisi syntyä aiemmin muodostettua mallia tarkempi käsitteellinen malli lähdejärjestelmien datasta. (Vassiliadis et al. 2002) ETL-prosessin toteutusta pidetään usein hyvin työläänä vaiheena. Usein jopa 50–70 % koko tietovarastoprojektin ajasta kuluu juuri tähän vaiheeseen. Yleinen syy tämän vaiheen haastavuuteen on lähdejärjestelmien datojen väliset eroavaisuudet. Eroavaisuuksien vuoksi täytyy käydä suuri datamassa läpi ja muokata ne yhdenmukaisiksi tietovarastoon siirtoa varten. (Ponniah 2010)

Kirjallisuudesta löytyy eroavaisuuksia siinä, kannattaako ETL-toteutus tehdä itse vai ostaa valmiina ulkopuoliselta toimittajalta. Kimball et al. (2011) ovat sitä mieltä, että ETL-työkalu kannattaa hankkia ulkopuolelta, sillä ETL-prosessi luo pohjan tietovarastoinnille ja sen onnistumisesta riippuu usein koko projektin onnistuminen (Kimball et al. 2011). Vassiliadis et al. (2002) puolestaan ovat sitä mieltä, että ETL-toteutus voidaan toteuttaa yrityksen sisällä, mikäli heillä on riittävät edellytykset ja osaaminen sen suunnittelemiseen, toteuttamiseen ja mallintamiseen (Vassiliadis et al. 2002). Giorgini et al. (2005) mukaan ETL-prosessin toteutukseen kuluva aika ja resurssit ovat riippuvaisia tietovaraston vaatimusmäärittelyn lähestymistavasta. Mikäli on valittu datavetoinen lähestymistapa, on ETL-prosessin suunnittelu yksinkertaisempaa johtuen siitä, että käyttäjien tietotarpeet ovat sivuroolissa kehittäjien näkökulmasta. (Giorgini et al. 2005)

Alimpana elinkaarimallissa kulkee liiketoimintatiedon hallintasovellusten rata. Sen tavoitteena on suunnitella tietovaraston loppukäyttäjille sovellukset, joiden avulla he voivat hyödyntää tietovarastoon tallennettuja tietoja. Tietovaraston loppukäyttäjien ei ole järkevää tehdä hakuja suoraan tietovarastoon sen toiminnallisuuden ja rakenteen vuoksi. (Vitt et al. 2008) Usein heillä ei myöskään ole riittävää osaamista kyselyjen tekemiseen, joten on tehokkaampaa suunnitella valmiit sovellukset, joiden avulla he voivat hyödyntää tietovarastoa liiketoiminnan kehittämiseksi. Tietovaraston rakenne voi olla esimerkiksi normalisoitu, jolloin raportointiin tarvittavat kyselyt vaatisivat useita liitoksia. Tämän vuoksi on järkevämpää luoda tietojen hyödyntämiseen erillisiä data martteja, joita kutsutaan usein info marteiksi. (Oksanen et al. 2020) Nämä data martit voivat olla valitusta arkkitehtuurista riippuen itsenäisiä tai keskitettyyn tietovarastoon integroituja (Blazic et al. 2017).

3.4 Modernin tietovaraston suunnittelu

Tässä luvussa esitellään malli modernin tietovaraston suunnitteluperiaatteista. Tämä kokonaisuus perustuu aiemmin tässä työssä esiteltyihin tietovarastotyyppeihin, arkkitehtuureihin ja tietomalleihin tarjoten niiden käyttöön modernin näkökulman. Malli pohjautuu luvun 3.3.2 kuvassa 10 esiteltyyn Kimballin elinkaarimalliin. Malli keskittyy kertomaan suunnitteluperiaatteet, joiden avulla voidaan suunnitella yritykselle keskitetty tietovarasto. Luvun lopussa on yhteenveto modernin tietovaraston suunnitteluperiaatteista.

3.4.1 Projektin suunnittelu ja vaatimusten määrittely

Aluksi tietovarastoprojektille määritetään sponsori eli liiketoiminnan edustaja, jonka tehtävänä on luoda visio suunniteltavalle tietovarastolle ja tuoda projektin sidosryhmien tietoon syyt projektin taustalla. (Gucer et al. 2005; Kimball et al. 2011) Ennen projektin aloittamista tulee myös saada hyväksyntä tietovaraston rakentamiselle ja hyödyntämiseen liiketoiminnan päätöksenteossa. Lopuksi tulee tarkastella yrityksen käytössä olevaa dataa. Täytyy selvittää, onko yrityksen data saatavilla tietovarastoon ja onko se käyttökelpoista. Mikäli dataa ei tallenneta oikein, täytyy ennen tietovarastointia rakentaa toimiva infrastruktuuri datan keräämiselle operatiivisista järjestelmistä. (Kimball et al. 2011)

Koko yrityksen kattavan keskitetyn tietovaraston suunnittelussa ja toteuttamisessa on kyse pitkän aikavälin projektista. Kun edellytykset projektille on varmistettu edellä kuvatun mukaisesti, siirrytään suunnittelemaan projektin toteuttamista ja ensiksi määritellään projektin roolit. Jotta tietovarastoprojekti saadaan vietyä maaliin, tarvitaan useita rooleja sekä liiketoiminnan että IT:n puolelta. Roolit voidaan jakaa liiketoiminnan edustajiin, tietovaraston kehittäjiin sekä muihin sidosryhmiin, kuten konsultteihin. Projektiin osallistuvien tiimien on syytä olla monialaisia, sillä onnistunut tietovarasto vaatii laaja-alaista osaamista. (Ponniah 2010; Kimball et al. 2011)

Lopuksi projektille määritellään konkreettiset projekti- ja kommunikointisuunnitelmat. Niiden avulla määritellään riittävällä tarkkuudella projektin aikaiset tehtävät ja sovitaan käytännöt, kuinka kaikki sidosryhmät pysyvät tietoisina projektin etenemisestä koko projektin ajan. (Kimball et al. 2011) Tässä vaiheessa voidaan sopia esimerkiksi millä alustoilla viestitään ja mihin projekti dokumentoidaan. Myös muista projektin aikaisista pelisäännöistä on hyvä sopia tässä vaiheessa, jotta kaikki ovat tietoisia toimintavoista heti projektin alusta lähtien ja projektiin on tarvittaessa helppo tulla mukaan myöhemmässäkin vaiheessa, kun toimintatavat ovat kaikkien tiedossa.

Kun projekti on suunniteltu, voidaan siirtyä varsinaiseen tietovaraston suunnitteluun. Modernissa tietovarastoinnissa lähdetään liikkeelle liiketoiminnan tarpeista. Liiketoiminnan

tarpeita on hyvä kartoittaa eri tasoilla, jotta niistä voidaan muodostaa kokonaiskuva yrityksen tietotarpeisiin. Alkuvaiheessa määrittelyä ei kuitenkaan kannata tehdä liian tarkasti. Tietovarastoa varten tulee määrittää tietovaraston strategiset vaatimukset eli visio organisaation tiedon hyödyntämisestä, liiketoiminnan kokonaiskuva eli koko organisaation laajuiset tietotarpeet, raportointitarpeet ja niiden laskentakaavat, jotta raporteista saadaan yhdenmukaiset. Lopuksi määritetään tarvittavat tietolähteet. (Reeves 2009; Kimball et al. 2011) Liiketoiminnan vaatimusten keräämisessä ei alkuvaiheessa kannata keskittyä liian tarkasti yksityiskohtiin, sillä niitä voidaan tarkentaa projektin aikana. Tärkeämpää on muodostaa kokonaiskuva tarvittavista tiedoista ja hyödyntämiskohteista.

Liiketoiminnan eri edustajilta kerätään eri liiketoimintojen tarpeet muun muassa raportoinnista, analytiikasta ja koneoppimisesta. Lisäksi selvitetään, millaisia tarpeita eri palveluilla on tietojen suhteen, esimerkiksi millaista tietoa palveluissa halutaan esittää käyttäjille. Yrityksellä voi myös olla asiakkaita, joille he toimittavat dataa analysointia tai muuta käyttöä varten, jolloin myös heidän tietotarpeensa tulee selvittää. (Malinowski & Zimányi 2008; Reeves 2009; Kimball et al. 2011; Oksanen et al. 2020) Liiketoiminnan edustajilta voidaan kerätä vaatimuksia esimerkiksi haastatteluilla ja järjestämällä suunnittelutyöpajoja. Esimerkkikysymyksiä eri vaatimusten keräämiseksi on koottu kuvaan 13. Lisäksi heitä voidaan pyytää kertomaan olemassa olevien raporttien hyvät ja huonot ominaisuudet, jotka voidaan ottaa huomioon uusien suunnittelussa.

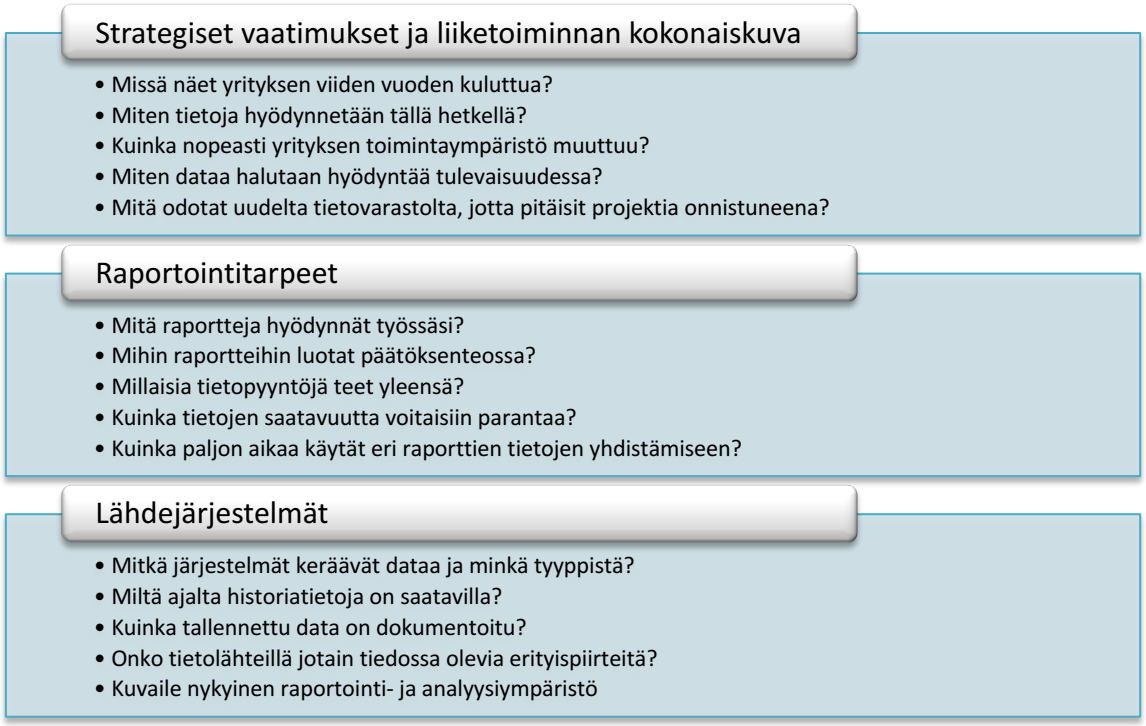

Kuva 13. Esimerkkikysymyksiä liiketoiminnan vaatimusten määrittelyyn (mukaillen Reeves 2009)

3.4.2 Tekninen suunnittelu

Liiketoiminnan vaatimusten pohjalta määritetään infrastruktuuri ja tietovaraston laajuus sekä rakenne. Nykyään tietovarastot rakennetaan usein pilvipohjaiselle palvelimelle fyysisessä konehuoneessa sijaitsevan palvelimen sijaan. Pilvipohjainen infrastruktuuri tarjoaa mahdollisuuden kasvattaa tietovarastoa tarpeiden mukaan eli voidaan rakentaa joustava tietovarasto, joka skaalautuu muuttuviin liiketoiminnan tarpeisiin. Pilvipohjaisissa infrastruktuureissa toimitaan usein ”pay-as-you-go” – logiikalla eli kustannuksia syntyy käytön mukaan. Tämän ansiosta tietovaraston lopullista kokoa ei tarvitse tietää vielä projektin alussa vaan sen laajuutta voidaan muuttaa iteratiivisesti. (Oksanen et al. 2020)

Tietovaraston rakenne määritetään valitsemalla arkkitehtuurimalli, joita esiteltiin luvussa 3.1.2. Näistä arkkitehtuurimalleista parhaiten yrityksen keskitetyn tietovaraston rakentamiseen soveltuvat ”Hub and spoke” – ja keskitetyn tietovaraston arkkitehtuurit. Molemmissa arkkitehtuureissa tiedot ladataan keskitettyyn tietovarastoon, mutta suurin eroavuus tulee siitä, kuinka tiedot tallennetaan hyödyntämistä varten. ”Hub and spoke” – arkkitehtuurissa tiedot ladataan erillisiin data martteihin, kun taas keskitetyn tietovaraston arkkitehtuurissa data martit ovat integroituja tietovarastoon. (Ariyachandra & Watson 2010; Yessad & Labiod 2016; Blazic et al. 2017)

Modernissa tietovarastossa käytetään latausaluetta tietojen lataamiseen lähdejärjestelmistä. Latausalueeksi sopii hyvin esimerkiksi data lake eli tietoallas, sillä se on edullinen ja hyvin skaalautuva, joten se sopeutuu muuttuviin liiketoiminnan tarpeisiin varsinkin, kun toimitaan pilvipohjaisessa infrastruktuurissa. Tietoaltaaseen voidaan ladata helposti ja edullisesti niin strukturoitua, puolistrukturoitua kuin strukturoimatontakin dataa. (Chawla & Khattar 2020) Tietoaltaan datasisällöstä tarvitaan oma dokumentaatio ja sen sisällön laadusta on huolehdittava. Kun tietoallas toteutetaan huolellisesti ja suunnitellusti, voidaan sen tietoja hyödyntää jopa suoraan analytiikassa ja raportoinnissa. (Oksanen et al. 2020) Kuvassa 14 on esitetty esimerkkikuvaus modernin tietovaraston arkkitehtuurista, jota voidaan käyttää uuden tietovaraston suunnittelun tukena.

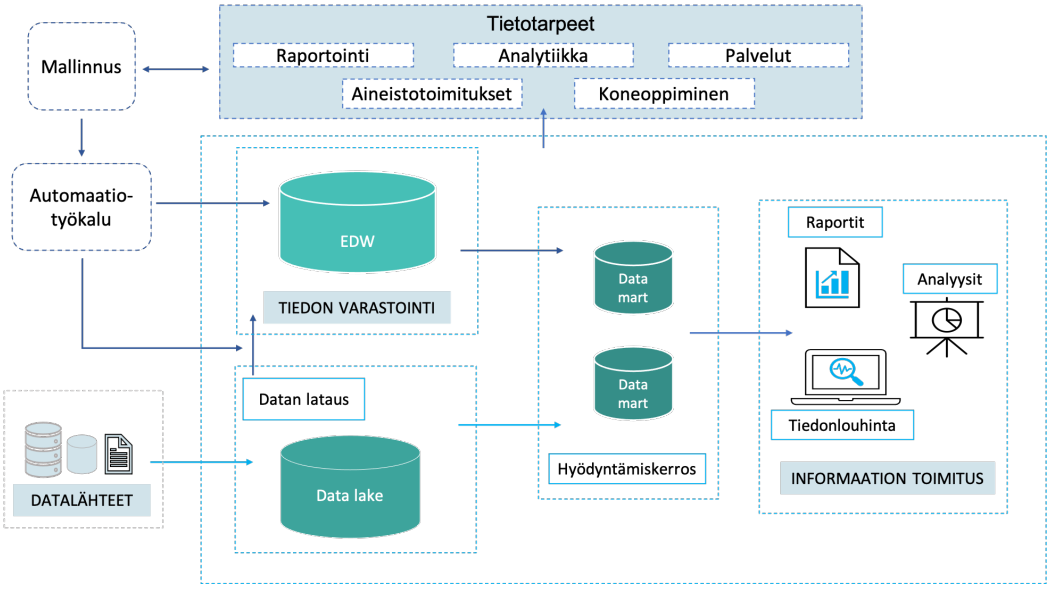

Kuva 14. Moderni tietovarasto (mukaillen Vaisman 2014; Chawla & Khattar 2020; Oksanen et al. 2020)

Kuvan 14 kaltainen moderni tietovarasto koostuu tietoaltaan ja keskitetyn tietovaraston lisäksi niiden päälle rakennetusta analytiikasta. Tämä kokonaisuus kaikkine osineen muodostaa modernin tietovaraston. (Chawla & Khattar 2020) Modernissa tietovarastossa tietotarpeiden määrittelyn jälkeen luodaan tietomalli, jonka pohjalta ladataan data tietovarastoon hyödyntäen automatisoituja prosesseja. Data voidaan ladata joko suoraan keskitettyyn tietovarastoon, mikäli data on valmiiksi hyödynnettävässä muodossa, tai erilliselle data lake – tyyppiselle latausalustalle. Latausalustalla oleva data muokataan tietovarastoon sopivaksi ja siirretään tiedon varastointikerrokselle odottamaan hyödyntämistä.

Tietovaraston tehokkaan hyödyntämisen näkökulmasta loppukäyttäjiä ei ole useinkaan järkevää päästää hakemaan tietoja suoraan tietovarastosta. Tietojen hakemista varten on hyvä luoda kuvan 14 mukaisesti omat data martit. Näihin data martteihin tiedot haetaan ja yhdistetään sopivalla tavalla esimerkiksi raportointia varten. Data martit on hyvä suunnitella vastaamaan aina yhden liiketoiminnan osa-alueen tarpeita. (Oksanen et al. 2020) Nämä data martit voivat olla integroituna tietovarastoon tai erillisiä kokonaisuuksia riippuen valitusta arkkitehtuurista. Data martteihin tallennettu tieto tuodaan loppukäyttäjien hyödynnettäväksi erilaisilla BI-sovelluksilla.

Arkkitehtuurin valinnan jälkeen valitaan tietovaraston toteutukseen käytettävät teknologiat. Valittavia työkaluja ovat tiedon mallinnukseen käytettävä ohjelmisto, tietovarastoinnin prosessien automatisoinnin ETL-teknologia sekä tiedon hyödyntämiseen käytettävät raportointi- ja analysointityökalut. Teknologioiden valinnassa tulee ottaa huomioon valittu

arkkitehtuuri sekä liiketoiminnan tarpeet, jotta saadaan toteutettua tarpeisiin sopiva tietovarasto. (Ponniah 2010; Kimball et al. 2011; Oksanen et al. 2020) Modernissa tietovarastoinnissa voidaan käyttää perinteisen ETL-prosessin sijaan ELT-prosessia. Se eroaa perinteisestä tietojen latausmallista siten, että tiedot ladataan esimerkiksi data lake -tyyppiselle tietojen latausalueelle ja muokataan vasta sen jälkeen tietovaraston tarpeisiin sopiviksi. (Oksanen et al. 2020)

Lisäksi tulee valita sopiva tietokannanhallintajärjestelmä. Sen valinnassa tulee kiinnittää erityisesti huomiota järjestelmän yhteensopivuuteen lähdejärjestelmien ja muiden käytettävien teknologioiden kanssa sekä ylläpidettävyyteen ja skaalautuvuuteen. (Westerman 2001; Inmon 2005; Silvers 2008) Tietomallinnusta varten voidaan valita myös jokin mallinnustyökalu. Tämän valinnassa tulee kiinnittää huomiota siihen, että mallinnustyökalu mahdollistaa myös metadatan lisäämisen malliin sekä laajentamisen mahdollista tietovaraston automatisointia varten. (Oksanen et al. 2020)

3.4.3 Tietomallin suunnittelu

Liiketoiminnalta kerättyjen vaatimusten pohjalta muodostetaan tietovarastolle tietomalli. Tietovarastolle valitaan arkkitehtuuriin sopiva tietomalli luvussa 3.2 esitellyistä yleisesti käytetyistä malleista. Moderniin liiketoimintalähtöiseen keskitettyyn tietovarastoon sopii tietomallinnustavaksi Data vault (Oksanen et al. 2020). Luvussa 3.2.4. esitelty Data vault on liiketoimintalähtöinen tietomalli, joka voidaan nähdä hybriditoteutuksena kolmannen normaalimuodon ja tähtimallin väliltä. Malli sisältää normalisoituja tauluja, jotka on linkitetty toisiinsa eri liiketoiminnan alueita tukevalla tavalla. (Olschimke & Linstedt 2016) Malli tarjoaa tietovarastolle normaalimuotoa ja dimensionaalista mallinnusta paremman skaalautuvuuden ja mukautuvuuden liiketoiminnan muuttuviin vaatimuksiin, mikä lisää myös tietovaraston tuottavuutta (Bojičić et al. 2016; Yessad & Labiod 2016).

Tietomallinnus voidaan tehdä mallinnustyökalulla, jonka valinta on tehty luvussa 3.4.2 esitetyllä tavalla. Aluksi liiketoiminnan vaatimuksista luodaan abstraktin tason käsitemalli, jonka tarkoituksena on kuvata tietovarastoon tallennettavia ja yritykselle merkityksellisiä kokonaisuuksia. Kokonaisuudet muodostuvat samoja ominaisuuksia sisältävistä objekteista ja mallissa kuvataan näiden kokonaisuuksien välisiä suhteita. (Haq 2016; Gordon 2017; Inmon et al. 2019) Käsitemallin pohjalta luodaan yksityiskohtaisempi looginen malli. Loogisessa mallissa jokaisesta käsitemallin objektista tunnistetaan loogiset entiteetit ja niille lisätään määrittelevät attribuutit, joita ovat esimerkiksi avaimet ja määritteet. (Haq 2016) Looginen malli järjestetään valitun tietomallinnustavan mukaan ja se kuvastaa jo hyvin selkeästi tulevan tietovaraston rakennetta.

Loogisen mallin pohjalta luodaan tietomallinnuksen tarkimman tason malli, valitusta tietokannanhallintajärjestelmästä riippuvainen fyysinen malli (Kimball et al. 2011). Fyysisessä mallinnuksessa jokainen loogisen mallin attribuutti kuvataan yksityiskohtaisesti. Fyysinen malli sisältää yksittäisten attribuuttien fyysisen rakenteen, eli tietotyypin, huomioiden lähdedatan fyysisen rakenteen. Fyysiseen tietomalliin määritetään taulujen sarakkeiden nimet, avaimet sekä mahdolliset indeksoinnit. Tässä vaiheessa malliin määritetään myös laskettavat attribuutit ja poistetaan lähdejärjestelmän datasta mahdolliset tarpeettomat entiteetit. (Kimball & Ross 2013; Haq 2016; Inmon et al. 2019) Fyysinen malli on siis tarkka kuvaus tulevan tietovaraston rakenteesta. Sen pohjalta tietovarastokehittäjien on helppo luoda tietovarasto, sillä siinä on kuvattuna yksityiskohtaisesti jokainen tietovarastoon tuleva taulu sarakkeineen ja näiden taulujen väliset suhteet.

3.4.4 Informaation toimituksen suunnittelu

Tietovaraston teknisen toteutuksen ja tietorakenteen suunnittelun lisäksi on tärkeää suunnitella tietovaraston hyödyntämistä varten BI-sovellukset. Hyödyntämiskerroksen data marteista tiedot toimitetaan käyttäjien saataville esimerkiksi erilaisilla raportointi- ja BI-työkaluilla. (Vitt et al. 2008) BI-työkalujen avulla käyttäjille voidaan tuottaa interaktiivisia raportteja, joiden avulla he voivat tarkastella tietoja eri rajauksilla yhden raportin avulla. (Reeves 2009; Vaisman 2014) Perinteisesti informaation toimittamiseen käytetyt työkalut on luokiteltu raportointi- ja analyysityökaluihin. Kuvassa 15 on esitelty esimerkkejä näiden kahden luokan työkaluista.

Kuva 15. Esimerkkejä tietovaraston informaation toimituskerroksen työkaluista (mukaillen van der Lans 2012)

Nykyaikaiset kaupalliset BI-työkalut voivat sisältää useiden eri raportointi- ja analyysityökalujen ominaisuuksia yhdessä paketissa ja niitä ei voida luokitella perinteisellä tavalla. Työkalujen valinnassa tulee kiinnittää huomiota loppukäyttäjien tarpeisiin. Heille ei ole merkityksellistä, kuinka tieto tulee raportille, vaan tietojen luotettavuus, ajantasaisuus ja

käytettävyys aina tarpeen vaatiessa. (van der Lans 2012) Työkalun on oltava myös teknisesti tietovarastokokonaisuuteen sopiva, jotta sen käyttäminen on tietovarastokehittäjien näkökulmasta mielekästä. Näiden vaatimusten pohjalta tulee arvioida, mikä tarjolla olevista vaihtoehdoista on oman yrityksen tarpeisiin sopiva. Huomiota kannattaa kiinnittää myös työkalun kustannustehokkuuteen. (Vitt et al. 2008)

Modernissa tietovarastossa on pyrittävä myös lähes reaaliaikaisen raportoinnin mahdollistamiseen. Tietojen tulisi päivittyä raporteille viiveettä tietovaraston päivittymisen jälkeen. (Oksanen et al. 2020) Tämä on otettava huomioon tietovaraston teknisessä suunnittelussa, jotta valittu infrastruktuuri ja tekniset työkalut tukevat raportoinnin reaaliaikaisuutta.

Modernin tietovaraston suunnitteluprosessi koostuu siis useasta kokonaisuudesta. Kyseessä on monivaiheinen prosessi, jossa jokainen vaihe on jollain tavalla riippuvainen muista vaiheista. Modernin tietovaraston suunnitteluperiaatteet on tiivistetty kuvaan 16. Suunnitteluperiaatteet on jaoteltu suunnitteluprosessin mukaisiin vaiheisiin ja jokaisen vaiheen alle on listattu kyseisen vaiheen tärkeimmät tehtävät.

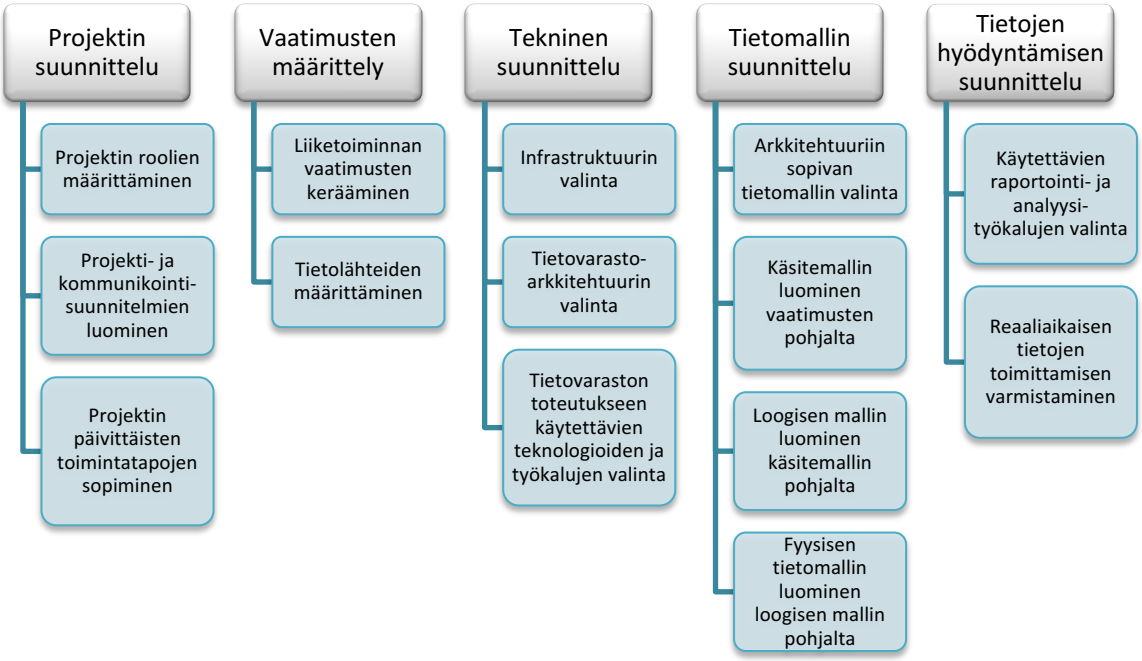

Kuva 16. Yhteenveto modernin tietovaraston suunnitteluperiaatteista

4. EMPIRIAN TOTEUTUS

Tutkimuksen kohdeyrityksenä toimii digitaalisia palveluita tuottava yritys. Yritys tarjoaa digitaalisia asumisen ja autoilun palveluita niin kuluttajille kuin ammattilaiskäyttöön. Yrityksen tuotevalikoimaan kuuluu alansa johtavia palveluita. Tässä luvussa kerrotaan, kuinka tutkimuksen empiirinen osuus toteutetaan. Ensiksi käydään läpi haastattelututkimuksen sekä haastattelujen toteutus ja lopuksi esitellään, kuinka haastatteluiden tulokset analysoidaan.

4.1 Haastattelututkimuksen toteutus

Tutkimuksen empiirinen osuus toteutetaan puolistrukturoituna teemahaastatteluna. Puolistrukturoitu haastattelu on kvalitatiivinen tiedonkeruumenetelmä, jolla voidaan selvittää vastaajien mielipiteitä, asenteita ja syitä näiden taustalla. Puolistrukturoidussa haastattelussa jotkin näkökulmat, joilla tutkittavaa aihetta lähestytään, on päätetty jo etukäteen, mutta haastattelu kuitenkin elää haastateltavien vastausten mukaan. (Hirsjärvi & Hurme 2008; Saunders et al. 2019) Haastattelumenetelmän vapaamuotoisuus antaa haastateltavalle mahdollisuuden kertoa oman näkemyksensä, eikä vastauksia ohjata liikaa kysymyksen asettelulla. Näin voidaan saada selville myös sellaisia asioita, joita haastattelun tekijä ei ole osannut itse ajatella. (Saunders et al. 2019) Haastattelutilanteen kuuluisi olla keskustelunomainen ja siksi haastattelu tallennetaan äänittämällä tai muistiinpanojen avulla. (Hirsjärvi & Hurme 2008; Saunders et al. 2019) Tässä tutkimuksessa haastattelut suoritetaan etäyhteyden välityksellä, joten haastattelut nauhoitetaan.

Puolistrukturoidusta haastattelusta voidaan eriyttää alatyyppinä teemahaastattelu. Teemahaastattelussa nähdään, että haastattelun keskeinen anti perustuu ihmisten tulkintoihin ja heidän asioillensa antamiin merkityksiin. Teemahaastattelussa haastateltavilta ei kysytä tarkkoja kysymyksiä tietyssä järjestyksessä, vaan haastattelu on hyvin vapaamuotoinen. (Hirsjärvi & Hurme 2008) Teemahaastattelu sopii tähän tutkimukseen hyvin, sillä tavoitteena on selvittää eri rooleissa toimivien henkilöiden näkemyksiä tietovaraston suunnitteluun liittyvistä periaatteista ja suunnitteluperiaatteiden mallin ensimmäisen version toimivuudesta kohdeyrityksessä.

Haastateltavat valitaan harkintaan pohjautuvaa otantaa hyödyntäen. Tässä menetelmässä haastateltavat valitaan asetettujen kriteerien mukaisesti, jotta saadaan valittua

parhaimmat mahdolliset haastateltavat tutkimuskysymyksen näkökulmasta. Valintakriteerinä voi toimia esimerkiksi mahdollisimman homo- tai heterogeeninen joukko haastateltavia, tyypillinen tapaus tai kriittinen tapaus. (Saunders et al. 2019)

Kohdeyrityksen yhteyshenkilön avulla kartoitetaan tutkimuksen kannalta tärkeimmät haastateltavat. Haastateltavat jaetaan kolmeen kategoriaan, joille on räätälöity heidän taustoilleen sopivat kysymykset. Ensimmäiseen kategoriaan kuuluvat liiketoiminnan edustajat, joiden haastattelussa keskitytään tietovaraston suunnitteluun liiketoiminnan näkökulmasta. Toinen kategoria koostuu tietovarastoasiantuntijoista, joiden haastattelussa kerätään tietoa tietovaraston suunnittelusta teknisemmästä näkökulmasta. Kolmanteen kategoriaan kuuluu tietovarastokehittäjät, jotka hyödyntävät suunnittelumallia eli pyritään selvittämään, mitä mallissa tulisi ottaa huomioon sen käyttäjän näkökulmasta. Haastateltavat tulevat olemaan pääsääntöisesti kohdeyrityksessä työskenteleviä, mutta lisäksi haastatellaan yhtä organisaation ulkopuolista tietovarastokehittäjää, jotta saadaan empiirisestä aineistosta kattavampi.

4.2 Haastattelujen toteutus

Haastateltavat valittiin yhdessä kohdeyrityksen yhteyshenkilön kanssa. Haastateltaviin otettiin yhteyttä ensiksi kohdeyrityksen viestintäkanavia käyttäen ja sovittiin haastattelusta. Tämän jälkeen haastateltaville toimitettiin sähköpostitse ensimmäinen versio suunnitteluperiaatteiden mallista (luku 3.4) sekä haastattelun kysymysrunko (LIITE A). Kaikki haastattelut pidettiin kahden viikon ajanjaksolla. Haastateltaville lähetettiin kysymykset etukäteen, jotta he pystyivät valmistautumaan haastatteluun. Näin saatiin laajempia vastauksia, sillä varsinkin liiketoiminnan edustajille tietovarastointi kokonaisuutena oli ennestään hieman tuntematon, joten oli hyvä, että he pystyivät pohtimaan vastauksia jo hieman valmiiksi. Haastattelukysymyksien toimittaminen etukäteen myös sujuvoitti haastattelutilannetta.

Haastattelut suoritettiin etäyhteyksin vallitsevan koronatilanteen vuoksi. Haastateltavilta kysyttiin haastattelun alussa lupa nauhoitukseen ja kaikki haastattelut tallennettiin myöhempää litterointia varten. Näin ollen haastattelutilanteessa pystyttiin keskittymään paremmin keskusteluun haastateltavan kanssa. Haastateltaville korostettiin sitä, että heidän toivotaan vastaavan kysymyksiin oman kokemuksen perusteella riippumatta siitä, kuinka asiat oppikirjojen mukaan kuuluisi tehdä. Näin teorian pohjalta luotuun malliin saadaan yhdistettyä käytännössä toimivia asioita.

Kaikki haastattelut pidettiin yksilöhaastatteluina ja yhteensä niitä pidettiin seitsemän, joista kolme haastattelua oli liiketoiminnan näkökulmasta ja neljä teknisemmästä näkökulmasta. Haastateltavat on esitelty tarkemmin taulukossa 3.

Taulukko 3. Haastateltavat

		Työnkuva	Kokemus tietovarastoista
Liiketoiminnan edustaja	**H1**	Kehityspäällikkö	Tietovarastossa olevan datan ja raporttien hyödyntämistä, raporttien määrittelyä
	H2	Data-analyytikko	Tietovarastossa olevan datan hyödyntämistä, raporttien määrittelyä
	H3	Markkinointi-päällikkö	Tietovarastossa olevan datan hyödyntämistä, raporttien määrittelyä
Tietovarasto-asiantuntija	**H4**	Senior cloud data engineer	Tietovarastoarkkitehdin ja pääkehittäjän tehtävät (4 vuotta) Tietovarastokehitys (3 vuotta)
	H5	Senior data engineer	Tietovarastoarkkitehtuurin suunnittelua ja kokonaisvaltaista tietovaraston kehitystä (3 vuotta)
Tietovarasto-kehittäjä	**H6**	Data scientist	Tietovarastokehitys (1 vuosi)
	H7	Ohjelmisto-kehittäjä	Tietovarastokehitys (12 vuotta)

Haastateltavat 1, 2 ja 3 osallistuivat haastatteluihin liiketoiminnan näkökulmasta. He toimivat kohdeyrityksessä erilaisissa rooleissa, mutta hyödyntävät kaikki dataa jokapäiväisessä työssään sekä ovat olleet tietovaraston kehitysprojektissa mukana liiketoiminnan edustajana. Haastateltavat 4 ja 5 ovat kohdeyrityksen ulkopuolisia konsultteja, joista haastateltava 4 työskentelee kohdeyrityksessä tietovarastoarkkitehdin sekä pääkehittäjän roolissa ja haastateltava 5 on kokonaan kohdeyrityksen ulkopuolinen tietovarastoasiantuntija, joka työskentelee samankaltaisissa tehtävissä. Heiltä pyrittiin saamaan malliin yleisempää näkökulmaa, sillä heiltä löytyy kokemusta tietovarastoista useista erilaisista liiketoimintaympäristöistä. Haastateltavat 6 ja 7 työskentelevät kohdeyrityksen tietovarastojen parissa ja heitä haastateltiin suunnitteluperiaatteiden mallin käyttäjän näkökulmasta.

4.3 Aineiston analysointi

Haastatteluaineisto analysoitiin temaattisella analyysillä. Temaattisen analyysin avulla aineistosta voidaan tunnistaa, analysoida ja raportoida säännönmukaisuuksia eli teemoja. (Braun & Clarke 2006) Temaattinen analyysi voidaan jaotella kirjallisuuden perusteella kuvan 17 mukaisiin vaiheisiin.

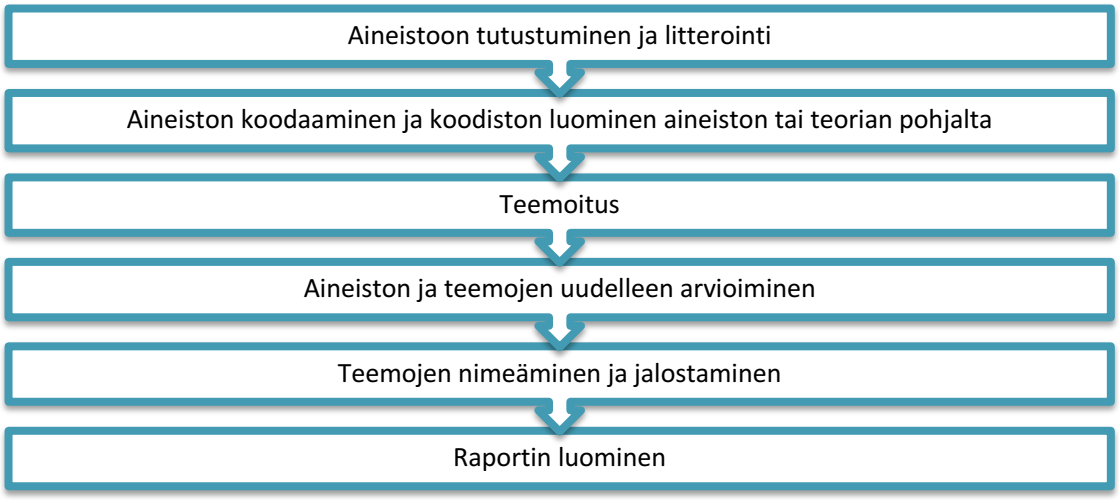

Kuva 17. Temaattisen analyysin vaiheet (mukaillen Braun & Clarke 2006; Vaismoradi et al. 2013; Nowell et al. 2017)

Haastattelut nauhoitettiin ja niiden aikana tehtiin muistiinpanoja haastattelun etenemisen kannalta olennaisista asioista, esimerkiksi jos tuli ilmi jotain seikkoja, joihin haluttiin tarkennuksia haastateltavalta. Haastattelut purettiin tallenteelta kirjoitettuun muotoon parin päivän kuluessa haastattelusta. Haastatteluista pyrittiin muodostamaan tiivistetty kuva haastateltavan vastauksista. Lisäksi joitain erityisen mielenkiintoisia ja hyvin sanoitettuja kohtia kirjoitettiin puhtaaksi sanatarkasti, jotta niitä voidaan hyödyntää tulosten esittelyn tukena.

Tutkimuksen empiirinen osuus muodostettiin abduktiivisesta näkökulmasta. Saunders et al. (2019) mukaan kvalitatiivisen aineiston analyysi sisältää usein sekä deduktiivisen että induktiivisen lähestymistavan. Teemahaastattelun runko pohjautui teoriasta esiin nousseisiin teemoihin. Näitä teemoja hyödynnettiin tulosten analysoimisessa ja ensin tulokset jaettiin näiden teemojen alle. Teoriaan pohjautuvan deduktiivisen lähestymistavan avulla voidaan muodostaa syvempi analyysi aineistosta kuin laajemmalla, mutta usein pintapuolisemmalla, datalähtöisellä käsittelyllä (Braun & Clarke 2006). Tämän lisäksi aineistosta pyrittiin tunnistamaan teemoja, joita ei osattu ennakoida teorian pohjalta. Näin pystyttiin muodostamaan tarkempi analyysi tuloksista.

Kun teorian pohjalta oli tunnistettu pääteemat ja teemat, käytiin aineisto läpi tiivistäen haastattelujen vastauksia ydinsisältö säilyttäen. Aineistosta löydetyt koodit sijoiteltiin teemojen alle. Aineistosta poimitut lainaukset jaoteltiin myös teemojen alle ikään kuin sitaattikokoelmiksi. Tämän jälkeen teemat koodeineen käytiin uudelleen läpi, mietittiin niiden mielekkyyttä ja tunnistettiin aineistosta uusia alateemoja. Tämän jälkeen koodit jaoteltiin uudelleen tarkennetun teemoituksen mukaisesti. Teorian ja aineiston pohjalta tunnistetut teemat on koottu taulukkoon 4. Pääteemat muodostuivat tutkimuskysymyksistä, teemat on tunnistettu teorian pohjalta ja alateemat empiirisestä aineistosta.

Taulukko 4. Teoriasta ja empiriasta tunnistetut teemat

Pääteema	Teema	Alateemat
Tietovarasto-projektin suunnittelu	Projektin suunnittelu	Projektin eteneminen
		Dokumentointi
	Liiketoiminnan vaatimusten kerääminen	Sisäisten vaatimusten kerääminen
		Asiakkaiden vaatimusten kerääminen
	Lähdedata	Lähdedatan ongelmat
		Luotettavuuden parantaminen
Tietovaraston rakenteellinen suunnittelu	Arkkitehtuuri	Arkkitehtuurin valinta
		Tietovaraston rakenteesta johtuvat ongelmat
	Teknologiat	Teknologian valinta
		Teknologian haasteet
	Tietojen mallinnus	Mallinnustavan valinta
		Mallinnustyökalun valinta
	Informaation toimitus	Työkalujen valinta
		Ongelmat
		Toiveet ja tarpeet

5. EMPIRIAN TULOKSET

Tässä luvussa esitellään haastattelujen tulokset. Luku on jaettu taulukon 4 mukaisten tunnistettujen teemojen mukaan. Ensin käydään läpi tietovarastoprojektin suunnitteluun liittyvät teemat ja sen jälkeen rakenteelliseen suunnitteluun liittyvät teemat.

5.1 Tietovarastoprojektin suunnittelu

Haastatteluissa lähestyttiin tietovaraston suunnittelua teorian pohjalta muodostetun mallin avulla ja pyrittiin selvittämään mallin toimivuutta asiantuntijoiden mielestä. Heiltä kysyttiin mallin vaiheiden järjestyksestä ja kriittisyydestä. Tämän avulla pyrittiin selvittämään, onko mallissa esitetty oikeita asioita ja ovatko ne oikeassa järjestyksessä suhteessa toisiinsa.

Haastateltavien mielestä heille esitetty malli modernin tietovaraston suunnitteluperiaatteista oli hyvä ylätason kuvaus tietovaraston suunnitteluprosessista ja vastasi heidän näkemystään. Malli koettiin kuitenkin melko lineaariseksi ja enemmän perinteisemmän vesiputousmallin kuin ketterän kehityksen periaatteiden mukaiseksi. Iteratiivisen ketterän kehittämisen koettiin sopivan paremmin moderniin tietovarastoprojektiin.

5.1.1 Projektin suunnittelu

Useissa haastatteluissa nousi esiin, että projektin suunnittelu ja liiketoiminnan vaatimusten kerääminen on kriittinen vaihe tietovaraston onnistumisen kannalta ja koko tietovarastoprojekti lähtee liikkeelle liiketoiminnalta tulevasta vaatimuksesta.

”Kokemus on sen todistanut, että ensimmäisenä pitää olla sitoutuminen tietovarastoon, että se tehdään niin kuin projektina. -- Alussa kauhean monella ei ollut kiinnostusta tietovarastohommista koska siihen tietovarastointiin ei panostettu niin paljon aikaa ja ajatuksia niin se näkyy nykyisissä toteutuksissa, että sinne on käyty tekemässä vähän jotain nopeasti ja siinä on hukkunut sellainen suunnitelmallisuus.”

- Kohdeyrityksen tietovarastokehittäjä (H7)

Tietovarastolle pitää tulla aito tarve liiketoiminnalta, jotta sitä kannattaa lähteä suunnittelemaan ja toteuttamaan. Yksi haastateltavista nosti esiin tapauksen, jossa tietovarastoa lähdettiin toteuttamaan ilman yhtäkään suunniteltua käyttötapausta eikä tietovarastoon mallinnettu ollenkaan julkaisukerrosta. Usein yrityksen tietotarpeet ovat niin aikariippuvaisia ja hetkessä syntyviä, ettei tiedon kerääminen tietovarastoon varmuuden vuoksi

ole järkevää. Tarpeen lisäksi liiketoiminnan ja muiden projektin osapuolien tulee sitoutua projektiin, jotta siinä voidaan onnistua. Yrityksessä täytyy olla myös riittävästi osaamista. Haastateltavien mukaan tämä tarkoittaa sitä, että tietovaraston kehittämiseen tulee varata henkilöitä, joilla on osaamista ja resursoida heille riittävästi työtunteja tietovaraston kehittämiseen.

Liiketoiminnan sitoutumisen lisäksi tietovarastoprojektin pitää olla suunnitelmallinen. Vaikka onkin hyvä noudattaa ketterän kehittämisen periaatteita, korostivat haastateltavat vastauksissaan sitä, että kehittämisen tulee edetä suunnitelmallisesti. Alussa on hyvä tehdä suuret linjaukset, joiden ohjaamana projektia viedään eteenpäin iteratiivisesti. Jos alussa tehdään huonoja valintoja, ne tulevat vastaan myöhemmässä vaiheessa.

”Alussa ei tehdä hirveää kasaa määrittelyjä, vaan aluksi otetaan sellaisia matalalla olevia omenoita ja todistetaan johdolle ja liiketoiminnalle sen digitaalisen ratkaisun arvo tekemällä teknisessä mielessä hyvin yksinkertaisia caseja, missä kuitenkin liiketoimintavaikutukset ovat suuret. Sitä kautta saadaan bisneksen usko, jotta voidaan ruveta taklaamaan myös haastavampia caseja.”

- Kohdeyrityksen ulkopuolinen konsultti (H5)

” Nykyään tehdään valmiiksi jokaisesta kerroksesta osa eli kehitys tapahtuu vertikaalisissa putkissa. Eli ensiksi tehdään pieni palanen yhdestä tasosta, sitten osa toisesta ja niin edelleen aina päällimmäiseen kerrokseen asti, jotta loppukäyttäjille saadaan mahdollisimman nopeasti dataa käyttöön.”

- Kohdeyrityksessä työskentelevä konsultti (H4)

Haastateltavien vastauksissa korostui projektin iteratiivisuus. Projektin edetessä tietovarastoa tulee rakentaa pienissä paloissa niin, että mahdollisimman aikaisessa vaiheessa saadaan valmiita tuotoksia loppukäyttäjille. Näin pystytään esittämään liiketoiminnalle tietovaraston konkreettisia hyötyjä ja synnyttämään ideoita uusiin tarpeisiin. Valmiin raportin tai muun datatuotteen näkeminen helpottaa usein liiketoiminnan edustajaa ymmärtämään tietovaraston mahdollisuuksia, minkä avulla heidän on helpompaa määrittää omia tarpeitaan. Haastateltavien kokemuksen mukaan iteratiivisuus mahdollistaa uusien ideoiden syntymisen ja toisaalta myös ongelmat huomataan aikaisemmassa vaiheessa, jolloin niihin voidaan puuttua ja estää niiden monistuminen tietovarastossa. Näin myös nähdään, mikä on mahdollista ja mikä ei, jolloin pystytään helpommin ymmärtämään, mitkä liiketoiminnan tarpeista pystytään toteuttamaan.

”Monesti on ollut kompastuskivenä se, että on tehty tietovarasto ja sitten kun se näyttää valmiilta niin sitten oletetaan, että se ei tarvitse henkilökuntaa katsomaan perään vaan se toimii kaiken aikaa.”

- Kohdeyrityksen tietovarastokehittäjä (H7)

Iteratiivisuuden lisäksi haastatteluissa nousi esiin ylläpidon ja palautteen merkitys. Liian usein vanhoissa tietovarastoratkaisuissa on unohdettu ylläpidon merkitys, ja tämän vuoksi ne ovat päässeet vanhenemaan käyttökelvottomiksi. Liiketoiminnan pitää olla mukana tietovaraston kehityksessä koko ajan, etenkin käyttöönotossa. Heidän pitää antaa hyväksyntä valmistuneille raporteille sekä palautetta raporttien toimivuudesta. Näin tietovarastoa pystytään kehittämään toimivammaksi. Haastateltavat näkivät, että yksittäisen liiketoiminnan edustajan roolin on hyvä olla sellainen, että hän on koko projektin ajan mukana vähintään sillä tasolla, että tietää missä mennään, mutta silloin kun hänen tarpeisiinsa tulevaa raporttia tai muuta datakokonaisuutta työstetään, on hän aktiivisemmin osallisena projektissa ja tukemassa tietovarastokehittäjien työtä.

5.1.2 Liiketoiminnan vaatimusten kerääminen

Haastatteluissa korostettiin liiketoiminnan vaatimusten keräämisen merkitystä tietovarastoprojektin onnistumisen kannalta. Kerätyt vaatimukset on tulkittava oikein, jotta niiden pohjalta pystytään luomaan tietovarasto, joka tarjoaa ratkaisun liiketoiminnan tarpeisiin. Vaatimusten kerääminen on syytä järjestää organisoidusti, mutta niitä ei ole tarpeen määritellä heti alussa kokonaan. On tärkeämpää, että saadaan kerättyä muutama eri tarve tarkalla tasolla, jolloin niitä voidaan lähteä tarkentamaan. Tarkkojen määrittelyjen lisäksi on kuitenkin hyvä olla korkeamman tason kokonaiskuva liiketoiminnan tarpeista ja tahtotilasta datan suhteen.

”Määrittelyssä olisi hyvä olla mukana myös niitä, jotka tuntevat lähdedatan, sillä usein liiketoiminnalla ei ole välttämättä käsitystä siitä, mitä kaikkea dataa on käytettävissä. Tällä pystytään heti sanomaan, onko vaatimuksia mahdollista toteuttaa ja onko tiedot hyödynnettävässä muodossa.”

- Kohdeyrityksessä työskentelevä konsultti (H4)

Usean haastateltavan, niin liiketoiminnan kuin teknisen puolen, vastauksesta kävi ilmi, että vaatimusten keräämiseen on syytä osallistua liiketoiminnan edustajien lisäksi lähdedatan asiantuntija sekä tietovaraston kehittäjä. Näiden yhteistyössä voidaan saavuttaa parempi ymmärrys datan mahdollisuuksista ja näin myös liiketoiminta pystyy sanoittamaan omat tarpeensa paremmin. Usein liiketoiminnalla voi olla liian optimistinen kuva datan laadusta ja heidän odotuksensa uuden tietovarastoratkaisun mahdollisuuksista

ovat epärealistisia. Myös liiketoiminnan edustajat kokivat, että mikäli heillä olisi parempi ymmärrys saatavilla olevasta datasta, heidän olisi helpompi sanoittaa omia tietotarpeitaan. Siksi on tärkeää, että heti alussa saadaan kaikille osapuolille yhteinen käsitys tarpeiden ja mahdollisuuksien kokonaiskuvasta. Usein on myös tarpeellista palata alussa kerättyihin vaatimuksiin myöhemmässä vaiheessa tietovaraston kehitystä, jotta saadaan selvyys siitä, mitä liiketoiminta oikeasti on halunnut ja onko se nykyisen tiedon valossa mahdollista.

Heti alussa olisi hyvä kerätä myös strukturoidumpia tarpeita, kuten erilaisia mittareita ja tunnuslukuja laskukaavoineen eli jalostetaan tietotarpeet heti strukturoituun muotoon. Raportointia ajatellen olisi hyvä selvittää myös muuttujat, joiden suhteen raporteilla halutaan tarkastella tietoja. Näiden osalta tietomallin suunnittelijan tulee miettiä, kuinka ne toteutetaan tietomalliin järkevästi. Liiketoiminnan tarpeet ja toiveet voivat olla osittain päällekkäisiä tai ristiriidassa keskenään, jolloin tietovarastokehittäjien tehtäväksi jää niiden yhteensovittaminen ja yhdistäminen.

Liiketoimintavaatimuksia on haastateltavien mukaan hyvä kerätä loppukäyttäjiltä sekä erilaisilta tuotepäälliköiltä tai -omistajilta. Kohdeyrityksellä on myös asiakkaita, joille tuotetaan raportteja. Yritysasiakkaiden osalta toimivia tapoja ovat olleet massakyselyt sekä pilottiasiakkaat, jotka pääsevät kertomaan tarkemmin tarpeitaan ja testaamaan raportteja ennen niiden vientiä laajempaan tuotantokäyttöön. Tarpeet tulee siis kerätä suoraan heiltä, jotka raportteja käyttävät ja heidän johdoltaan, koska he ovat ne henkilöt, jotka tietävät kuinka tietoja käytetään nyt ja mikä on tulevaisuuden tahtotila.

5.1.3 Lähdedata

Haastatteluista nousi esiin lähdedatan tutkimisen ja tuntemisen merkitys tietovarastoprojektissa. Sekä liiketoiminnan edustajat että tietovarastokehittäjät kokivat, että kohdeyrityksessä olisi parantamisen varaa lähdedatan ymmärtämisessä.

”Kukaan ei oikein tiedä miten järjestelmät toimii ja missä data sijaitsee. Eli meillä on lukuja mutta ei tiedetä mistä ne tulee. Tämä vaikeuttaa datan luotettavuutta, kun ei ole näkyvyyttä dataan.”

- Kohdeyrityksen kehityspäällikkö (H1)

Lähdedatan puutteellinen ymmärrys johti vastauksien mukaan raporttien epäluotettavuuteen. Kohdeyrityksessä ei ole riittävän selkeää dokumentaatiota siitä, miten data tallentuu operatiivisista järjestelmistä ja miten datat kytkeytyvät toisiinsa. Data on hyvin monimutkainen ja pirstoutunut kokonaisuus. Tämä aiheuttaa epäluotettavuutta raporttien lukuihin, kun ei ole varmuutta mistä data niihin tulee ja onko ne haettu oikeasta paikasta.

Liiketoiminnan näkökulmasta lähdedatan puutteellinen ymmärrys heikentää tietotarpeiden määrittelyä ja uusien ideoiden kehittelyä. Lähdedatan osaaminen on vain operatiivisten järjestelmien kehittäjillä, joten olisikin tärkeää saada heidät mukaan tietovaraston kehittämiseen ja siirtämään tietoaan tietovaraston kehittäjille. Myös lähdedatassa tapahtuvista muutoksista pitäisi vastaajien mielestä ilmoittaa tietovaraston kehittäjille, jotta he pystyisivät tekemään tarvittavat muutokset tietovaraston päässä.

Kohdeyrityksessä lähdedata koostuu suurilta osin heidän asiakkaiden palveluun syöttämistä tiedoista. Haastateltavat kokivat tämän haasteeksi datan laadulle, sillä usein datassa voi olla kirjoitusvirheitä tai tietoja on syötetty vääriin kenttiin. Lisäksi käyttäjillä on mahdollisuus muokata palveluun syöttämiään tietoja myöhemmin, jolloin kaikissa tapauksissa aiempaa tietoa ei tallenneta, vaan talteen jää pelkästään uusi, muokattu tieto.

Lähdedatan luotettavuuden parantamiseksi useissa vastauksissa mainittiin dokumentaatio ja sen parantaminen. Koettiin, että laadukkaasti tuotetulla dokumentaatiolla, joka on helposti saatavilla, voitaisiin lisätä kaikkien osapuolien ymmärrystä datasta ja näin ollen parantaa sekä raporttien luotettavuutta, että lisätä liiketoiminnan innovatiivisuutta datan hyödyntämiseen.

” Yksi tiimi vastaa tietystä osasta dataa, jolloin tietäisi keneltä kysyä ja kuka tietää asioista. Pitäisi olla jonkinlainen data manager, joka keskustelee liiketoiminnan ja tekniikan välillä ja osaisi priorisoida dataan liittyvät tarpeet ”

- Kohdeyrityksen kehityspäällikkö (H1)

Myös tuoteomistajuudella koettiin olevan positiivisia vaikutteita lähdedatan luotettavuuteen. Sen avulla olisi helpommin hahmotettavissa, kuka vastaa mistäkin osasta dataa ja kysymykset pystyttäisiin osoittamaan oikealle henkilölle. Myös tiedon kulkua saataisiin näin parannettua ja kaikkien osapuolien välillä kulkisi helpommin samat tiedot.

5.2 Tietovaraston rakenteellinen suunnittelu

5.2.1 Arkkitehtuuri

Arkkitehtuurin valinnassa haastateltavat keskittyivät kuvan 14 mukaisen arkkitehtuurin rakenteeseen ja siihen liittyviin haasteisiin. He kokivat, että kuvan 5 mukaiset arkkitehtuurimallit eivät ole nykyään teknisestä näkökulmasta kovin relevantteja valintoja, vaan on tärkeämpää pystyä muodostamaan yrityksen tarpeisiin vastaava toimiva kokonaisuus. Haastateltavien vastauksissa korostui raakadatan lataamisen ja tallentamisen tärkeys sekä eri lähdedatojen yhdistäminen samaan paikkaan. Lisäksi organisaation rakenteen merkitystä arkkitehtuurin valintaan pidettiin hyvin merkityksellisenä.

”Arkkitehtuuri muuttuu tekniikan kehittyessä, ennemminkin sanoisin, että ei sellasta kuin aikasemmin on ollut, että (kaikki data) ladataan yhteen tietovarastoon, joka on ollut palvelukohtainen vaan ennemminkin niin, että koko organisaation data on yhdessä data lakessa kaikkien saatavilla, jolloin data ei siiloudu vaan on kaikkien saatavilla.”

- Kohdeyrityksen tietovarastokehittäjä (H7)

Raakadatan lataaminen ilman mallintamista ja muokkaamista erilliseen kerrokseen eli raakatietovarastoon koettiin haastateltavien keskuudessa yhdeksi merkittävimmistä modernin ja perinteisemmän tietovaraston erottavista tekijöistä. Haastateltavat pitivät tärkeänä sitä, että raakadatan päälle rakennetut mallinnetut kerrokset olisivat tarvittaessa kokonaan uudestaan luotavissa raakatietovarastoon tallennetun raakadatan perusteella. Tällaisessa tilanteessa esimerkiksi tietomalliin tai muuhun tietovaraston rakenteeseen tehtävät muutokset eivät johda työläisiin muutosoperaatioihin eikä historiadataa kadoteta. Lisäksi se, että tietovaraston pohjana oleva lähdedata löytyy läheltä tietovarastoa, helpottaa tietovaraston kehittäjien työtä sekä mahdollisten ongelmien ratkaisemista.

Yrityksen eri tietolähteiden datan lataamisessa samaan paikkaan pitää haastateltavien mukaan kuitenkin muistaa käyttöoikeudet ja sensitiivisen datan tallentamiseen liittyvät ongelmallisuudet esimerkiksi yleisen tietosuoja-asetuksen näkökulmasta. Lisäksi arkkitehtuurin pitää mahdollistaa eri muodossa olevan datan lataaminen samaan raakatietovarastoon. Kohdeyrityksessä operatiivista dataa tallennetaan niin relaatio- kuin NoSQL-tietokantoihin ja kaikki tämä olisi tallennettava samaan raakatietovarastoon.

Valitun arkkitehtuurin tulee haastateltavien mukaan olla skaalautuva ja joustava. Datan määrä kasvaa koko ajan ja liiketoiminnan tarpeet muuttuvat, joten arkkitehtuuri, joka pystyy mukautumaan muuttuviin vaatimuksiin, toimii hyvin modernissa tietovarastossa. Arkkitehtuuriin pitää pystyä tulevaisuudessa lisäämään uusia rakenteita, kuten info martteja tai integroimaan uusia työkaluja, joiden avulla dataa käsitellään tai toimitetaan loppukäyttäjälle. Haastateltavien aiempien kokemuksien perusteella tietovarastojen monikerroksellisuus on aiheuttanut ongelmia, jotka ovat johtuneet tietovarastoon kohdistuvista muutoksista. Usein ongelmien taustalla ovat olleet puutteelliset ja toimimattomat testiympäristöt, joiden avulla ei ole pystytty testaamaan muutoksien vaikutuksia tietovarastoon. Tämä pitää ottaa huomioon uuden tietovaraston suunnittelussa, että käytetään tarpeeksi resursseja myös toimivien testiympäristöjen perustamiseen.

”Ennen yritettiin saada yhteen tietovarastoon samaan paikkaan ja samaan tietomalliin kaikki yrityksen data. -- Ja tästä vastasi yksi keskitetty tietovarastotiimi, joka muodosti pullonkaulan kehitykselle, kun kaikki tarpeet meni heidän kauttaan. Nykyään onneksi enemmän käytetään kyllä keskitettyä ympäristöä ja yhteiset asiat tehdään kerran, mutta kehitys on hajautettua eli liiketoimintaspesifit tiimit kehittävät omiin tarpeisiinsa tarvittavat datat.”

- Kohdeyrityksessä työskentelevä konsultti (H4)

Tietovaraston arkkitehtuuriin vaikuttaa haastateltavien mukaan myös yrityksen rakenne. Mikäli yrityksessä on keskitetty IT-tiimi, joka hoitaa myös tietovaraston kehittämisen, voi olla luontevaa rakentaa hyvin keskitetty arkkitehtuuri, jossa datat tallennetaan yhteen paikkaan, jotta kokonaisuuden ylläpito on helppoa keskitetysti. Tämä voi kuitenkin haastateltavien kokemusten perusteella aiheuttaa ongelmia, kun keskitetty tiimi muodostaa pullonkaulan kehitykselle. Moderniin tietovarastoon, jossa tavoitteena on rakentaa yrityksen kattava kokonaisuus, on järkevämpää käyttää keskitettyä ympäristöä, jossa kaikille liiketoiminnoille yhteiset asiat tehdään kerran, mutta tietovaraston kehitys on hajautettu liiketoimintojen omille tiimeille. Näin sama data voi olla mallinnettuna usealla eri tavalla, mutta kehitys on kuitenkin ketterää. Kehittäminen ei kuitenkaan saa olla haastateltavien mukaan liian hajautettua eli jokaiselle arkkitehtuurin vaiheelle olisi oma tiimi. Tämä ei toimi iteratiivisessa kehityksessä, vaan yhden tiimin tulee hallita koko putki lähdedatan lataamisesta julkaisukerrokseen saakka, jotta pullonkauloja ei syntyisi.

Haastateltavat kokivat tärkeäksi myös sen, että tietovarastoarkkitehtuuri mahdollistaa ohjelmistokehityksen periaatteet eli esimerkiksi versiohistorioinnin sekä koodikatselmoinnit. Kohdeyrityksen aiemmissa tietovarastoratkaisuissa näiden puuttuminen on aiheuttanut merkittäviä ongelmia muun muassa tietojen luotettavuuteen ja muutosten jäljitettävyyteen. Tietovaraston tauluihin on voitu tallentaa tietoja väärin, kun virheitä koodeissa ei ole huomattu, tai jokin muutos on rikkonut tietovaraston lataukset, eikä vanhaa, toimivaa versiota koodeista ole ollut tallessa versiohistoriassa.

Arkkitehtuurin suunnittelussa ja rakentamisessa pitää huomioida haastateltavien mukaan kehityksen iteratiivisuus. Jotta voidaan tehdä pieniä kokonaisuuksia valmiiksi iteroiden, ei voida heti alussa rakentaa kaiken kattavaa, täysin valmista arkkitehtuuria ja latausaluetta, vaan joudutaan hieman oikomaan mutkia. Näitä teknisempiä vaatimuksia voidaan sitten ratkoa myöhempien iteraatioiden aikana, kun tietovaraston tarpeellisuus ja toimivuus on todistettu liiketoiminnalle sekä johdolle. Tämänkaltainen toimintatapa

vaatii yleisen tason linjanvetoja projektin alkumetreillä. Täytyy miettiä, kuinka tietoja mallinnetaan, sopia yhteiset käytännöt, mihin automatisointi perustuu ja miten tietovaraston kehitystä ylipäätään organisoidaan.

5.2.2 Teknologiat

Haastateltavat korostivat vastauksissaan sitä, että niiden teknologioiden valinnat, joita on vaikea muuttaa jälkeenpäin, ovat kriittisimpiä ja kannattaa tehdä huolellisesti. Tällaisia ovat esimerkiksi tietokanta- ja alustateknologiat. Useiden haastateltavien mielestä hyvä lähtökohta teknologioiden valintaan on käydä läpi ne teknologiat, joita yrityksessä on jo käytössä. Valitsemalla jo käytössä oleva teknologia voidaan hyödyntää yrityksessä olevaa osaamista ja voidaan saavuttaa kustannushyötyjä esimerkiksi lisenssien kautta. Haastateltavat kuitenkin muistuttivat, ettei valintaa pidä tehdä pelkästään helppouden ja kustannushyötyjen takia, vaan on punnittava teknologian hyötyjä ja haittoja laajemmin.

Teknologian valintaan vaikuttaa haastateltavien mielestä eniten sen sopivuus yrityksen tarpeeseen. Teknologian pitää olla kustannusrakenteeltaan sellainen, että se sopii käyttötarkoitukseensa. Kustannuksia arvioidessa pitää muistaa pitkän aikavälin tekijät, eikä verrata pelkästään hankintahintaa teknologian aiheuttamiin jatkuviin kustannuksiin. Kallis hankintahinta voi tulla pitkällä aikavälillä edullisemmaksi kuin käytön mukaan laskutettava, esimerkiksi jos datamäärät kasvavat suuriksi. Kustannuksia täytyy miettiä myös kustannus-suorituskykysuhteen kautta eli saadaanko teknologialla järkevällä hinnalla tarvittua suorituskykyä. Haastateltavat myös kokivat, ettei ole välttämättä järkevää hankkia aloitushinnaltaan kallista teknologiaa, jota ei sitten voida kustannussyistä vaihtaa, mikäli myöhemmin todettaisiin, ettei se toimikaan yrityksen käyttötarpeisiin.

Myös teknologiaan löytyvä osaaminen on merkittävä tekijä sen valinnassa. Kohdeyrityksen aiemmissa tietovarastoratkaisuissa on käytetty teknologioita, joihin on myöhemmin ollut haastavaa löytää osaamista yrityksen sisältä tai ulkopuolisilta toimijoilta. Tämän vuoksi haastateltavat pitävät tärkeänä, että teknologian valinnassa otetaan huomioon myös se, kuinka hyvin osaajamarkkinoilta löytyy kyseisen teknologian osaamista ja tukeeko teknologia esimerkiksi useita yleisempiä koodikieliä. Näiden tekijöiden avulla voidaan varmistaa sitä, että myös tulevaisuudessa osaamista löytyy riittävästi yrityksen tarpeisiin.

Haastateltavien mukaan valittujen teknologioiden pitää olla keskenään yhteensopivia sekä tukea valittua arkkitehtuuria. Niiden pitää myös mahdollistaa jo aiemmassa luvussa mainitut ohjelmistokehityksen periaatteet sekä tietovaraston latausten automatisointi ja ajastus. Automatisoituihin ajoihin pitää olla näkyvyys ja automaattiset hälytysilmoitukset

koettiin tarpeellisiksi, jotta ajoissa tapahtuneet virheet huomataan mahdollisimman pian. Aiemmissa kohdeyrityksen ratkaisuissa on saattanut käydä niin, että ajojen epäonnistuminen on huomattu vasta jälkikäteen, kun loppukäyttäjä on ihmetellyt raporteilla näkyviä lukuja. Tämä voi heikentää raporttien luotettavuutta loppukäyttäjien näkökulmasta.

Haastateltavat korostivat vastauksissaan myös teknologian ylläpidettävyyden merkitystä. Valitun teknologian pitää olla ylläpidettävä ja sellainen, jota päivitetään myös tulevaisuudessa. Yleensä sellaiset teknologiat, joiden takana on iso toimittaja ja tuotteella on paljon käyttäjiä, on ylläpidettävyyden näkökulmasta parempi kuin pienen käyttäjäkunnan tuote. Täytyy myös miettiä, että teknologian päivitykset olisivat hoidettavissa niin, ettei niistä aiheudu loppukäyttäjille merkittäviä käyttökatkoksia.

5.2.3 Tietojen mallinnus

Tietojen mallinnukseen liittyvissä valinnoissa haastateltavilla oli hieman eri näkemyksiä. He myös korostivat vastauksissaan sitä, että usein tietojen mallinnus jakaa tietovarastokehittäjien mielipiteitä. Mallinnustavan valinnassakin he kuitenkin painottivat yrityksen tarpeisiin sopivuutta ja eri tapojen sopivuutta erilaisiin käyttötarkoituksiin. Haastateltavat kokivat, että on kaksi päätapaa mallintaa tietoja, tässäkin työssä aiemmin luvussa 3.2. esitellyt dimensionaalinen mallinnus sekä data vault.

Tietojen mallinnus koettiin vastaajien keskuudessa tärkeäksi ja hyödylliseksi. Kuitenkaan mallissa esitetyn kolmitasoisen tietojen mallinnuksen ylintä tasoa eli fyysistä mallinnusta ei nähty niin tarpeellisena, varsinkaan käytettäessä data vaultia, kuin looginen ja käsitteellinen mallinnus. Tietomalliin valmiiksi määritetyt ja lasketut luvut sekä mallin rakenteellinen yhdenmukaisuus liiketoiminnan rakenteeseen koettiin liiketoiminnan tavoitteiden saavuttamista tukevaksi. Tietovaraston näkyväksi mallintamisen koettiin helpottavan liiketoiminnan kanssa käytävää keskustelua, kun heille voidaan näyttää, millaista dataa on saatavilla ja miten data liittyy toisiinsa. Tässä pitää kuitenkin ottaa huomioon liiketoiminnan tekninen osaaminen ja tiedot pitäisikin mallintaa liiketoiminnan näkökulmasta mukaillen liiketoiminnan termistöä ja prosesseja. Tietojen mallinnus riittävällä tasolla koettiin tarpeelliseksi myös projektin suunnitelmallisuuden takia.

Haastateltavien mukaan eri mallinnustavat eivät ole suoraan verrattavissa toisiinsa ja niillä on erilaiset käyttökohteet. Yksittäisen mallin nimeämisen sijaan he kokivat tärkeämmäksi sen, että valitaan omiin tarpeisiin sopiva. Myös tietovaraston eri kerrokset voidaan mallintaa eri mallinnustavoilla. Pidettiin myös tärkeänä, että julkaisukerros mallinnetaan ennemmin liiketoiminnan tarpeisiin sopivaksi, kuin noudatetaan kirjaimellisesti esimerkiksi dimensionaalisen mallinnuksen periaatteita.

Data vaultia haastateltavat pitivät adaptiivisena mallinnustapana, joka pystyy vastaanottamaan kaiken datan riippumatta lähdedatan muutoksista. Esimerkiksi lähdedatan viittausavaimiin tehdyt muutokset eivät vaikuta mallin toimivuuteen. Kuitenkin data vaultin päälle joudutaan lähes aina haastateltavien kokemuksen mukaan rakentamaan dimensionaalinen tähtimalli, joka taas edellyttää viittausavaimien oletuksia ja niiden muutokset lähdedatassa aiheuttavat muutoksia myös tähtimalliin. Tästä näkökulmasta tarkastellen osa haastateltavista piti data vaultin hyötyjä hieman liioiteltuna, koska heidän kokemuksensa mukaan lähdedatan suuria muutoksia tapahtuu hyvin harvoin.

Dimensionaalisessa mallinnuksessa haastateltavat kokivat ongelmalliseksi sen rajoitukset tietynlaisissa tietorakenteissa, esimerkiksi monen suhde moneen vaatii hieman työtä, jotta ne saadaan sovitettua. Se toimii kuitenkin erityisen hyvin julkaisukerroksessa, sillä useat BI-työkalut on optimoitu toimimaan dimensionaalisesti mallinnettujen datarakenteiden kanssa. Data vaultin hyvinä puolina haastateltavat pitivät sen skaalautuvuutta ja sitä, ettei mallia tarvitse suunnitella paljoa etukäteen. Tämä on kuitenkin myös samalla mallin huono puoli, sillä laajentuessaan rakenteesta voi helposti tulla niin monimutkainen, ettei sitä enää pystytä hallitsemaan.

Mallinnustyökalun tarpeellisuus riippui haastateltavien mielestä kokonaisuuden monimutkaisuudesta sekä automatisoinnista. Monimutkaisissa kokonaisuuksissa mallinnustyökalu koettiin lähes välttämättömäksi ja pidettiin tärkeänä, että työkalun avulla voidaan määrittää tietovaraston rakennetta. Työkalussa olisi hyvä olla myös dokumentointimahdollisuus, eli mallinnettaville kentille voitaisiin lisätä dokumentaatiota ja muuta mahdollista metadataa. Lisäksi data vaultin mallintamiseen koettiin hyvin tarpeelliseksi käyttää työkalua. Data vaultin käyttö perustuu usein automatisointiin, jolloin sen tehokas hyödyntäminen vaatii mallinnus- ja automatisointityökalut. Automatisoinnin avulla voidaan haastateltavien kokemuksen mukaan vapauttaa tietovarastokehittäjien aikaa teknisestä tekemisestä arvon tuottamiseen liiketoiminnalle.

5.2.4 Informaation toimitus

”Tämänhetkistä raporttien hyödyntämistä kuvaa sana manuaalinen työ, josta haluaisinkin nyt siirtyä sitten automatiikkaa kohden”

- Kohdeyrityksen markkinointipäällikkö (H3)

Haastateltavien vastauksissa korostuivat merkittävästi nykyisen raportoinnin epäluotettavuudet sekä manuaalinen työ. Nykyisellään liiketoiminnan edustajat joutuvat keräämään tietoja useista lähteistä ja yhdistelemään eri raporttien tietoja saadakseen tarpei-

siinsa vastaavan raportin. Tämä vie liikaa työaikaa ja aiheuttaa epäluotettavuutta lukuihin, kun ei ole riittävää käsitystä lukujen taustalla olevasta datasta. Haastateltavien kokemuksen mukaan tähän liittyy myös kohonnut riski väärinymmärryksille ja tulkinnoille, kun monta tekijää tekee raportteja ja yhdistelee tietoja.

Manuaalisen yhdistelyn sijaan erityisesti liiketoiminnan edustajien vastauksissa korostui toivomus interaktiivisista ja reaaliaikaisista raporteista, joiden avulla he pystyisivät tarkastelemaan asioita eri tasoilla ja näkökulmista sekä tekemään itse suodatuksia dataan. Tällaisen raportin avulla voidaan tarkastella kokonaiskuvaa, mutta myös porautumaan tarkemmalle tasolle ja tekemään päätelmiä tarkempien tietojen avulla. Myös erilaiset koneoppimiseen ja tekoälyyn perustuvat ennustemallit nousivat esiin vastauksista. Näille koettiin tarvetta osana raporttia, niin että voitaisiin huomioida esimerkiksi vuodenajan vaikutuksia asiakkaiden käyttäytymiseen ja sitä kautta liiketoimintaan sekä ennustamaan koko vuoden tulosta. Myös automaattisille huomioille ja nostoille datasta koettiin tarvetta. Eli liiketoiminnan edustajien näkyville tulisi automaattisesti erilaisia huomioita, mitä algoritmien avulla pystyttäisiin tunnistamaan datasta.

Yhdeksi merkittävimmäksi haasteeksi raporttien luotettavuudelle haastateltavat kokivat käsitteiden epäyhtenäisyyden. Eri paikoissa, esimerkiksi eri raporteilla, samat termit voivatkin tarkoittaa eri asiaa, joka aiheuttaa epäselvyyttä ja väärintulkitsemista. Termien määrittelyyn ei ole kiinnitetty tarpeeksi huomiota raporttien määrittelyvaiheessa ja näiden korjaaminen jälkeenpäin on aiheuttanut lisätyötä. Haastateltavien mielestä termit olisi hyvä määrittää liiketoiminnan tasolla niin, että ne ovat kaikkien tiedossa ja niiden yhtenäiseen käyttöön kiinnitettäisiin erityistä huomiota. Myös lähdedatassa tapahtuneet muutokset ovat aiheuttaneet epäluotettavuutta raporteilla ja analysoitavassa datassa. Haastateltavien mielestä yksi ratkaisu näihin voisi olla ongelmien dokumentointi, mutta tässä nähtiin haasteena se, että miten dokumentaatio saadaan riittävän lähelle dataa, jotta sitä huomattaisiin lukea, kun dataa käytetään myöhemmin.

”Olisi hyvä, että olisi dokkari, josta voi katsoa mistä raporttien kenttiin data on kerätty. Voisi sitten vikaa etsiessä sen pohjalta hakea polun datan lähteelle ja tarkistaa, että kaikki on kunnossa. Aikoinaan raportteja epäiltiin ja oli aika työlästä lähteä selvittämään, että onhan kaikki kunnossa kun viikkopaliksessa joku lukuja taas epäili”

- Kohdeyrityksen tietovarastokehittäjä (H7)

Raporttien dokumentaatio koettiin puutteelliseksi. Ei enää muisteta, miksi jotain on tehty ja mitä on sovittu aiemmin. Tämä on aiheuttanut ongelmia, kun raporteilla on ilmennyt ongelmia tai käyttäjä on ihmetellyt raportin lukuja. Näissä tilanteissa on ollut jokseenkin työlästä selvittää, mistä luvut tulevat tai ongelma johtuu ja on myös mahdollista, että

tietämys raporteista on poistunut kokonaan kohdeyrityksestä, kun työntekijä on vaihtanut työpaikkaa. Vastauksista nousi tarve myös infokentille raportilla. Näiden avulla raporttien tekijät voisivat selventää raportin toimintaa sekä raportin lukujen taustalla olevaa dataa suoraan siellä, missä data esitetään käyttäjälle. Tällä pystyttäisiin myös pienentämään väärien tulkintojen mahdollisuutta.

Valmiiden raporttien lisäksi haastateltavilla oli tarve hyödyntää dataa pelkistetymmässä muodossa. Dataa toivottiin saataville helposti esimerkiksi erilaisten näkymien avulla. Näkymiin tietovarastokehittäjä voisi valmiiksi tuottaa analysointiin tarvittavan datan, jonka datan analysoija voi helposti yksinkertaisella kyselyllä hakea omaan käyttöönsä. Koettiin, että näkymissä on parempi olla enemmän tietoa kuin on kerrallaan tarve, sillä turhan datan suodattaminen on helpompaa ja nopeampaa, kuin datan lisääminen näkymään. Kuitenkin näkymien pitäisi olla sellaisia, että niihin voidaan tarpeen tullen lisätä dataa nopeallakin aikataululla, jottei datan saatavuus muodostu pullonkaulaksi.

Informaation toimitukseen käytettävin työkalujen valintaan haastateltavien mukaan pätee lähes samat kriteerit kuin muidenkin teknologioiden valintaan. Niiden pitää olla kustannuksiltaan sopivia ja pitää olla saatavilla riittävä osaaminen niiden käyttöön, mutta ennen kaikkea niiden pitää olla käyttötarpeeseen soveltuvia.

”Hyvä ominaisuus raportointityökalussa olisi niin sanottu self service eli liiketoimintakäyttäjät pystyisivät mallinnetun datan perusteella tekemään itse raportteja. Jotkut työkalut tarjoavat niin hyvän näkymän dataan, että ilman syvällistä teknologista osaamista oleva liiketoimintakäyttäjä voi luoda oman raportin.”

- Kohdeyrityksessä työskentelevä konsultti (H4)

Haastateltavien mielestä hyviä ominaisuuksia modernille raportointityökalulle olisi mobiilikäyttö, ”Self service” -raportointi eli mahdollisuus tehdä itse raportteja ennalta määritetyn datan pohjalta ilman suuria teknisiä taitoja, helppokäyttöisyys sekä visuaalisuus. Työkalujen pitää olla myös riittävän tehokkaita, jotta niitä on mielekästä käyttää. Tietojen pitää olla saatavilla raporteille tarpeeksi yksinkertaisessa muodossa ja haastateltavien mukaan on hyvä pitää mielessä, ettei datan polku lähdejärjestelmästä loppukäyttäjälle muodostu liian pitkäksi. Tällöin vaarana voi olla, että datan viive kasvaa liian suuri eikä esimerkiksi reaaliaikainen raportointi onnistu. Useat vaiheet polulla myös lisäävät virheiden mahdollisuutta.

6. MODERNIN TIETOVARASTON SUUNNITTELU-PERIAATTEET

Tässä luvussa esitellään modernin tietovaraston suunnitteluperiaatteet, jotka on tunnistettu tutkimuksessa. Empiriasta saadut tulokset yhdistetään teoriaan ja luvussa 3.4. esitettyyn modernin tietovaraston suunnitteluperiaatteiden malliin luoden synteesi tutkimuksen tuloksista. Luku etenee luvun 3.4 tietovaraston suunnitteluperiaatteiden mukaisesti vaiheittain alkaen projektin suunnittelusta edeten informaation toimituksen suunnitteluun.

6.1 Tietovarastoprojektin aloitus ja suunnittelu

Reevesin (2009) mukaan tietovarastoprojekti lähtee liikkeelle liiketoiminnalta tulevasta tarpeesta ja luvussa 3.4 esitetyn suunnitteluperiaatteiden mallin mukaan projektille tulee saada liiketoiminnan hyväksyntä ennen sen aloittamista (Kimball et al. 2011). Tätä näkemystä tukevat myös haastatteluista saadut tulokset. Empirian perusteella tarve uudelle tietovarastolle täytyy tulla liiketoiminnalta, jotta sen toteuttaminen on järkevää. Ilman liiketoiminnan tarvetta tietojen kerääminen tietovarastoon on resurssien tuhlaamista, sillä tietotarpeet ovat hetkessä syntyviä ja nopeasti muuttuvia. Yrityksen täytyy sitoutua projektiin ja varata sen toteuttamiseen riittävästi resursseja. Tämän toteuttaminen helpottuu, kun tarve tietovarastolle tulee liiketoiminnalta. Tällöin tietovaraston toteuttamiselle on jo valmiiksi liiketoiminnan hyväksyntä ja voidaan aloittaa projektin suunnittelu.

Suunnitteluperiaatteiden mallin mukaisesti projektin alussa on tärkeää määritellä niin liiketoiminnan kuin IT:n eri tiimien roolit vastuualueineen (Ponniah 2010; Kimball et al. 2011). Rooleja voidaan tarvittaessa muuttaa ja tarkentaa projektin aikana. Empirian perusteella projektin suunnittelu on tärkeää sen onnistumisen kannalta, vaikka kehittäminen tapahtuisikin ketterillä menetelmillä. Projektin alussa on syytä päättää suurista linjoista, esimerkiksi tietovarastoarkkitehtuurin ja teknologioiden osalta. Liian tarkkojen suunnitelmien tekeminen ei ole järkevää, jotta kehittämisestä saadaan aidosti ketterää ja iteratiivista. Myös projektin työskentelytavat ovat tarpeen määritellä suunnitteluperiaatteiden mallin mukaan heti projektin alussa, jotta kaikki osapuolet toimivat samoilla periaatteilla (Kimball et al. 2011). Projektin alussa tulisi suunnitella toimivat dokumentointikäytännöt, jotta varmistetaan riittävän kattava dokumentaatio tietovarastokokonai-

suudesta. Haastateltavien vastauksissa toistui useissa yhteyksissä puutteellinen dokumentaatio ja sen aiheuttamat ongelmat muun muassa datan luotettavuudelle, joten laadukas ja kattava dokumentaatio on tärkeä osa toimivaa tietovarastokokonaisuutta.

Kimball et al. (2011) elinkaarimalli, jota suunnitteluperiaatteiden malli mukaili, koettiin haastateltavien keskuudessa hyvin lineaariseksi ja sen vuoksi liian joustamattomaksi modernin tietovaraston suunnitteluun. Empiriassa korostettiin sen sijaan ketterän kehittämisen tärkeyttä tietovaraston suunnittelussa. Reevesin (2009) ja Kimball et al. (2011) mukaan projektin alussa tulisi muodostaa kokonaiskuva liiketoiminnan tarpeista, mutta haastateltavat kokivat mallista poiketen tärkeämmäksi kerätä muutamia tarpeita tarkalla tasolla ja lähteä toteuttamaan niitä, jotta mahdollisimman aikaisessa vaiheessa saadaan liiketoiminnan käyttöön valmis tietotuote. Tämän kaltainen vertikaalinen kehitys helpottaa tietovaraston tarpeellisuuden todistamista liiketoiminnalle sekä mahdollistaa uusien ideoiden syntymisen valmiiden tuotosten pohjalta. Myös mahdollisiin ongelmakohtiin päästään nopeammin käsiksi ja ne voidaan korjata mahdollisimman aikaisessa vaiheessa. Haastateltavat olivat kuitenkin mallin kanssa samaa mieltä siitä, että aluksi on hyvä kartoittaa kokonaiskuva liiketoiminnan tahtotilasta tietovaraston suhteesta yleisellä tasolla. Kokonaiskuvan muodostaminen auttaa viemään suunnittelua ja tietovaraston kehitystä oikeaan suuntaan.

Suunnitteluperiaatteiden mallissa ei korostettu haastattelujen perusteella riittävästi tietovaraston ylläpitoa ja palautteen keräämistä. Haastattelujen perusteella ylläpito tulee suunnitella jo projektin alkuvaiheessa, jottei tietovaraston valmistuessa sitä unohdeta. Ylläpidon unohtaminen voi pahimmillaan johtaa tietovaraston vanhenemiseen käyttökelvottomaksi. Liiketoiminnan edustajien tulee olla koko projektin ajan mukana ja heiltä on hyvä kerätä palautetta projektin eri vaiheissa, jotta voidaan puuttua mahdollisesti ilmeneviin puutteisiin tai ongelmakohtiin heti kun ne havaitaan. Myös Hughes (2016) painottaa jatkuvan palautteen merkitystä tietovarastoprojektin onnistumisen kannalta. Palautteen antaminen pitää tehdä riittävän helpoksi, jotta kaikki osapuolet pystyvät ilman suurta kynnystä vaikuttamaan projektin etenemiseen ja voidaan varmistaa projektin kulkevan toivottuun suuntaan. (Hughes 2016)

6.2 Liiketoiminnan tietotarpeiden määrittely ja lähdedata

Sekä luvun 3.4 suunnitteluperiaatteiden mallin, että haastattelujen perusteella liiketoiminnan tietotarpeiden määrittely on tärkeä vaihe tietovarastoprojektissa, sillä kaikki muut suunniteltavat asiat pohjautuvat niihin. Malinowskin ja Zimányin (2008) sekä Kimball et al. (2011) mukaan liiketoiminnan tarpeita on syytä kerätä liiketoiminnan edustajilta yri-

tyksen eri tasoilta, jotta saadaan riittävän kattava kuva tietotarpeista. Haastateltavat kokivat tärkeäksi, että tietotarpeiden määrittelyssä on liiketoiminnan edustajan lisäksi mukana henkilöitä, jotka tuntevat lähdedatan. Näin liiketoiminnalle saadaan jo tietotarpeita määriteltäessä parempi käsitys saatavilla olevasta datasta ja sen mahdollisuuksista. Parempi ymmärrys auttaa liiketoimintaa määrittämään omat tarpeensa helpommin sekä edesauttaa uusien, innovatiivisempien ideoiden kehittelyä.

Reevesin (2009) mukaan kerättyjen tietotarpeiden pohjalta muodostetaan yleiskuva ja vasta sen jälkeen tarkemmat raportointitarpeet. Haastatteluissa kuitenkin korostettiin mallista poiketen, ettei heti alussa ole tarpeen kerätä kaikkia tarpeita, vaan on tärkeämpää kerätä muutamia tarpeita tarkalla tasolla ja lähteä kehittämään niitä valmiiksi tietotuotteeksi. Määrittelyitä on myös syytä tarkastella liiketoiminnan kanssa kehityksen eri vaiheissa ja mahdollisesti tarkentaa niitä halutun lopputuloksen saavuttamiseksi. Tietotarpeita määriteltäessä olisi hyvä kerätä myös strukturoidumpia tarpeita, kuten raporteilla käytettävät mittarit laskukaavoineen sekä muuttujat, joiden suhteen tietoja halutaan tarkastella.

Mallin mukaan tapauksissa, joissa yrityksellä on ulkoisia sidosryhmiä, esimerkiksi asiakkaita, joille he toimittavat dataa tai raportteja, on heidän tietotarpeensa selvitettävä sisäisten tarpeiden lisäksi (Malinowski & Zimányi 2008; Reeves 2009; Kimball et al. 2011; Oksanen et al. 2020). Kohdeyrityksessä toimiviksi tavoiksi asiakkaiden tarpeiden keräämiseen on koettu massakyselyt sekä pilottiasiakkaiden hyödyntäminen. Pilottiasiakkaiden avulla voidaan kerätä tarkempia tietotarpeita sekä testata uusien tietotuotteiden toimivuutta ennen niiden laajempaa käyttöönottoa.

Suunnitteluperiaatteiden mallin mukaisesti liiketoiminnan vaatimusten määrittelyn ohella tulisi tutustua yrityksen lähdedataan. Kimball et al. (2011) mukaan lähdedataan tutustuminen on tärkeää, jotta tiedetään, mitä sen pohjalta on mahdollista toteuttaa tietovarastoon. Myös haastateltavat kokivat lähdedataan tutustumisen tärkeäksi osaksi tietovarastoprojektia, sillä usein puutteellinen tietämys voi aiheuttaa esimerkiksi raporttien epäluotettavuutta. Tietovarastokehittäjillä tulee olla riittävä ymmärrys lähdedatasta, jotta he pystyvät tuottamaan sen avulla arvoa liiketoiminnalle. Ymmärryksen luominen edellyttää kattavaa dokumentaatiota tai tiedon siirtämistä muilla keinoin lähdejärjestelmien kehittäjiltä tietovaraston kehittäjille.

6.3 Tietovarastoarkkitehtuurin suunnittelu

Luvussa 3.1.2 esiteltiin perinteisiä tietovarastoarkkitehtuureja kuten EDW ja itsenäiset data martit. Haastateltavien mielestä tämän kaltaisen tarkasti määritellyn arkkitehtuurimallin valitsemisen sijaan on tärkeämpää luoda yrityksen tarpeisiin sopiva tietovarastoarkkitehtuuri. Suunnitteluperiaatteiden mallissa esitelty modernin tietovaraston arkkitehtuuri (kuva 14) osoittautui haastattelujen perusteella toimivaksi yleisenä arkkitehtuurikuvauksena, mutta samalla korostettiin tilannekohtaista suunnittelua. Kuvaan 18 on koottu tutkimuksessa tunnistetut modernin tietovarastoarkkitehtuurin keskeisimmät tekijät.

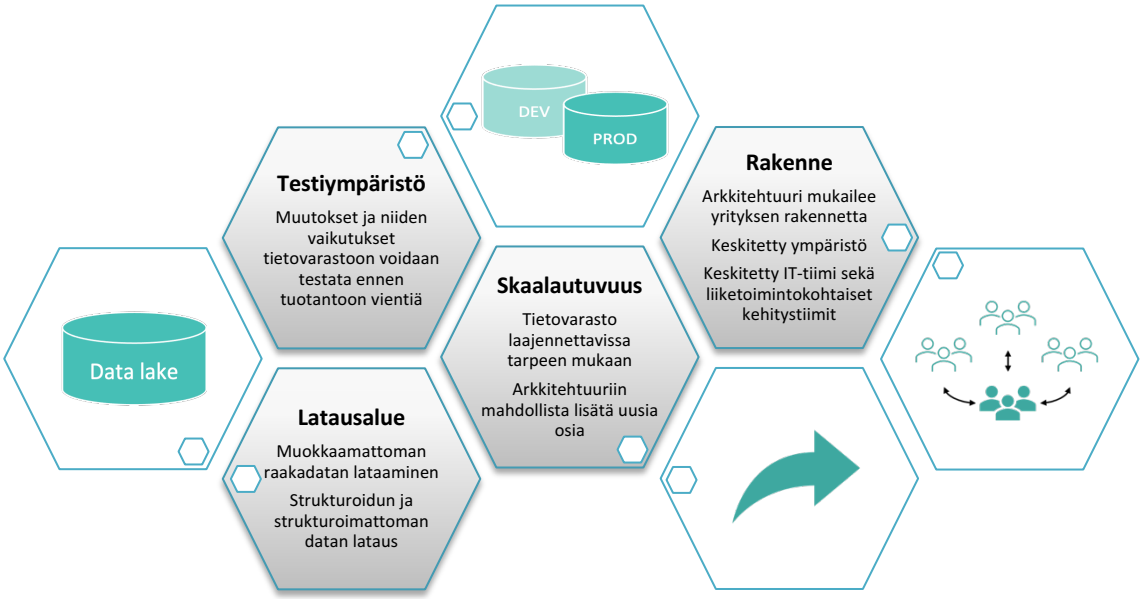

Kuva 18. Modernin tietovarastoarkkitehtuurin keskeiset ominaisuudet

Chawlan ja Khattarin (2020) mukaan modernissa tietovarastossa tiedot ladataan lähdejärjestelmistä latausalueelle, joka voi olla esimerkiksi luvussa 2.3.3 esitelty data lake. Haastateltavat pitivät mallin mukaisesti kaiken muotoisen raaka- eli muokkaamattoman datan lataamista samalle latausalueelle keskeisenä ominaisuutena modernissa tietovarastossa. Tietojen lataaminen eri lähteistä samalle latausalueelle mahdollistaa niiden yhdistämisen ja hyödyntämisen esimerkiksi raportilla. Aikaisemmin tietovarastoissa eri muodossa olevien datojen lataaminen samaan tietovarastoon on ollut haastavaa tai mahdotonta, joten tämä on merkittävä parannus perinteisiin tietovarastoihin verrattuna.

Latausalueen hyötynä empirian mukaan nähtiin myös se, että tietovaraston pohjana oleva lähdedata ei katoa. Tarvittaessa kaikki latausalueen datan päälle rakennettu pystytään luomaan kokonaan uusiksi ilman tietojen uudelleen lataamista tai historian kadottamista. Lisäksi pohjadatan sijaitseminen samassa kokonaisuudessa helpottaa virheiden

etsimistä ja korjaamista. Useiden eri lähteiden datojen lataamisessa samalle latausalueelle on kuitenkin hyvä pitää mielessä datan käyttöoikeuden ja sensitiivisen datan lataamiseen liittyvät tietosuoja-asetukset. Vaikka tiedot voidaan ladata latausalueelle muokkaamattomina, Oksanen et al. (2020) mukaan lataukset tulee toteuttaa huolellisesti ja suunnitellusti, jotta tietoja voidaan tarvittaessa osittain hyödyntää sellaisenaan raporteilla ja analytiikassa ilman erillistä tietovarastokerrosta.

Haastatteluissa korostettiin kuvan 18 mukaisesti tietovarastoarkkitehtuurin skaalautuvuutta ja joustavuutta. Oksanen et al. (2020) mukaan pilvipohjainen infrastruktuuri mahdollistaa tietovaraston kasvattamisen tarpeiden mukaan, joten tietovaraston lopullisen koon ei tarvitse olla tiedossa projektin alussa kuten mallissa esitettiin. Kehitettäessä tietovarastoa iteratiivisesti, lisääntyy tarvittavan datan määrä projektin edetessä. Sen arvioiminen tarkasti projektin alussa on hankalaa, joten skaalautuvuus on tärkeä ominaisuus infrastruktuurille. Lisäksi tietovarastoarkkitehtuuriin on pystyttävä tekemään muutoksia tarpeen vaatiessa ja lisäämään uusia komponentteja. Tämän vuoksi arkkitehtuuria ei tule suunnitella liian jäykäksi. Arkkitehtuurin suunnittelussa on haastattelujen perusteella syytä edetä iteratiivisesti. Koko arkkitehtuurin ei tarvitse olla valmiina heti projektin alussa, vaan on tärkeämpää saada valmiiksi vertikaalinen putki, joka mahdollistaa lähdedatan viemisen valmiille raportille. Arkkitehtuuria parannetaan ja täydennetään projektin edetessä.

Arkkitehtuurin suunnittelussa tulee haastateltavien kokemuksen mukaan muistaa toimivien testiympäristöjen suunnittelu, mitä ei oteta huomioon suunnitteluperiaatteiden mallissa. Puutteelliset testiympäristöt aiheuttavat ongelmia, kun muutoksien vaikutuksia ei pystytä testaamaan riittävällä tasolla ennen tuotantoon vientiä. On siis hyvä luoda erilliset testi- ja tuotantoympäristöt tietovarastoon. Lisäksi olisi hyvä kiinnittää huomiota siihen, että arkkitehtuurissa toteutuu muut ohjelmistokehityksen periaatteet eli varmistetaan versiohistoriointi sekä koodikatselmoinnit. Näin tehdyt muutokset jäävät talteen ja mahdolliset virheet huomataan helpommin ajoissa. Tämä helpottaa myös ongelmatilanteiden ratkaisua ja virheiden paikantamista.

Projektin suunnitteluvaiheessa on määritelty mallin mukaisesti eri tiimeille roolit (Ponniah 2010; Kimball et al. 2011), jotka on syytä ottaa huomioon myös tietovaraston arkkitehtuurin suunnittelussa kuvassa 18 esitetyllä tavalla. Mikäli päävastuu tietovarastosta on yrityksessä keskitetyllä IT-tiimillä, voi keskitetty arkkitehtuuri olla luonteva ratkaisu. Haastateltavien kokemuksen mukaan tämän kaltainen arkkitehtuuri kuitenkin aiheuttaa pullonkauloja kehitykselle. Moderniin tietovarastoon sopii paremmin arkkitehtuuri, jossa käytetään keskitettyä ympäristöä, mutta liiketoimintokohtainen tietovaraston kehitys tapahtuu omissa tiimeissä. Näin voidaan toimia ketterästi, mutta vältetään päällekkäinen

tekeminen liiketoimintojen yhteisten toimintojen osalta. Kehittäminen ei saa olla liian hajautettua, vaan liiketoimintojen tiimien tulee hallita itse tai yhteistyössä keskitetyn IT-tiimin kanssa koko tietovaraston kehitysputki lähdedatan latauksesta informaation toimitukseen saakka.

6.4 Teknologioiden valinta

Suunnitteluperiaatteiden mallin sekä haastateltavien mukaan teknologioiden valinnassa tulee huomioida arkkitehtuuri ja liiketoiminnan tarpeet (Ponniah 2010; Kimball et al. 2011). Lisäksi tutkimuksessa tunnistettiin keskeisiksi tekijöiksi teknologioiden valinnassa osaaminen, kustannusrakenne sekä teknologian ominaisuudet. Kuvaan 19 on koottu tutkimuksessa tunnistetut keskeisimmät teknologioiden valintaan vaikuttavat tekijät ja sitä voidaan käyttää valintojen tukena.

Kuva 19. Teknologian valintaan vaikuttavat tekijät

Haastateltavat painottivat, että teknologioihin, joita on vaikeaa muuttaa jälkeenpäin, on kiinnitettävä erityistä huomiota jo suunnitteluvaiheessa. Tällainen teknologia on esimerkiksi tietokannanhallintajärjestelmä, jonka päälle tietovarasto rakennetaan. Haastattelut

tukivat mallin mukaista näkemystä siitä, että teknologioiden valinnassa tulee kiinnittää huomiota niiden keskinäiseen yhteensopivuuteen, ylläpidettävyyteen sekä skaalautuvuuteen (Westerman 2001; Inmon 2005; Silvers 2008). Lisäksi teknologioiden tulee olla liiketoiminnan tarpeisiin sopivia sekä niitä tukevia.

Haastatteluiden perusteella teknologioiden valinta on hyvä aloittaa selvittämällä yrityksessä käytössä olevien teknologioiden tarjoamat mahdollisuudet. Valitsemalla käytössä oleva teknologia, voidaan hyödyntää yrityksessä olevaa osaamista sekä mahdollisesti saavutetaan kustannushyötyjä olemassa olevien lisenssien kautta. Valintaa ei kuitenkaan pidä tehdä pelkästään tämän perusteella, vaan on punnittava hyötyjä ja haittoja muista näkökulmista, kuten onko teknologian osaamista saatavilla riittävästi. Vaikka teknologia olisi sopiva yrityksen tarpeisiin, voi esimerkiksi pieni käyttäjäkunta enteillä, ettei teknologiaan löydy myöhemmin riittävästi osaamista esimerkiksi ulkopuolisilta toimijoilta. Tämä on syytä ottaa huomioon jo valintaa tehdessä, sillä osaajapula voi aiheuttaa suuriakin ongelmia myöhemmin.

Yksi tärkeä tekijä teknologioiden valinnassa on kustannukset. Haastateltavat korostivat, että kustannusten vertailussa pitää muistaa pitkän aikavälin tavoitteet. Suunnitteluperiaatteiden mallin mukaisesti nykyään käytetään usein pilvipohjaisia teknologioita, jotka Oksanen et al. (2020) mukaan perustuvat usein ”pay-as-you-go”-kustannuslogiikkaan eli kustannukset syntyvät käytön mukaan. Usein projektin alussa voidaan mieltää tällainen halvemmaksi kuin teknologia, jossa on kalliit aloituskustannukset, koska ei muisteta miettiä yrityksen tarpeita riittävän pitkälle. Käytön mukaan syntyvät kustannukset voivat kasvaa pitkällä aikavälillä suuria alkukustannuksia suuremmiksi, mikäli tietovaraston datamäärät kasvavat merkittävästi. On hyvä pitää mielessä, ettei valita alkukustannuksiltaan sellaista teknologiaa, jota ei voida kustannussyistä vaihtaa myöhemmin sen osoittautuessa toimimattomaksi. Tästä näkökulmasta käytön mukaan maksettavat teknologiat ovat turvallisempia valintoja.

Aiemmin mainittujen tekijöiden lisäksi valinnassa on hyvä ottaa huomioon ohjelmistokehityksen periaatteet, kuten jo arkkitehtuurin valintaa käsittelevässä luvussa 6.3 todettiin. Lisäksi suunnitteluperiaatteiden mallin mukaisesti moderniin tietovarastointiin kuuluu Oksanen et al. (2020) mukaan vahvasti automatisointi, mikä on hyvä ottaa huomioon teknologioita valittaessa. Haastateltavien mielestä teknologioiden pitää tarjota näkyvyys automaattisesti tapahtuviin ajoihin, jotta mahdollisten virhetilanteiden selvittäminen helpottuu. Automaattisissa ajoissa tapahtuvista virheistä tulee lähettää virheilmoitukset riittävän laajalle vastaanottajakunnalle, jotta virheet huomataan ajoissa eikä esimerkiksi loppukäyttäjän tarkastellessa raporttia. Näin voidaan samalla parantaa raporttien ja ylipäätään tietovaraston datan luotettavuutta.

6.5 Tietomallin suunnittelu

Inmon et al. (2019) mukaan tietovarastoon tulevat tiedot tulee mallintaa, jotta säilytetään ymmärrys siellä olevasta datasta ja kuinka tarvittavat datat saadaan tietovarastosta hyödynnettäväksi. Myös haastateltavat näkivät tietojen mallinnuksen tarpeelliseksi vaiheeksi modernin tietovaraston suunnittelussa. Tietojen mallintaminen liiketoimintalähtöisesti ja riittävän yksinkertaisella tasolla auttaa datan näkyväksi tekemisessä liiketoiminnan suuntaan. Tietomallin avulla voidaan siis auttaa liiketoimintaa ymmärtämään tietovaraston mahdollisuuksia, kunhan malli tehdään liiketoiminnan termeillä ja tekniselle osaamiselle sopivaksi.

Suunnitteluperiaatteiden mallissa esitettiin Oksanen et al. (2020) näkemys siitä, että moderniin tietovarastoon soveltuu parhaiten Data vaultin mukainen mallinnus, mutta tämä jakoi haastateltavien mielipiteitä. Data vaultissa on paljon hyviä piirteitä, mutta se ei kuitenkaan yksiselitteisesti toimi kaikissa tietovarastoissa. Tietomallin valinnassakin he painottivat tapauskohtaista valintaa eli valitaan liiketoiminnan tarpeita parhaiten tukeva mallinnustapa.

Tietovarastossa voidaan käyttää eri tietomalleja eri kerroksissa. Esimerkiksi mallissa esitetyn arkkitehtuurin (kuvan 14) mukainen EDW-kerros voidaan mallintaa Data vaultilla ja sen päälle rakennettavat data martit, esimerkiksi raportointia varten, dimensionaalisella mallilla. Eri mallinnustapojen käyttäminen tietovarastokokonaisuudessa auttaa hyödyntämään niiden parhaat puolet. Käytettäessä tilannekohtaisesti parhaiten toimivaa mallinnustapaa tietovarastolle ei aiheudu turhia rajoitteita.

Oksanen et al. (2020) mukaan tiedot kannattaa mallintaa mallinnustyökalulla, jotta tietovarastointia voidaan automatisoida. Hyvä mallinnustyökalu sisältää mahdollisuuden lisätä metadataa malliin sekä mahdollistaa laajentumisen myös automatisoinnin näkökulmasta (Oksanen et al. 2020). Haastateltavat kokivat mallin mukaisesti mallinnustyökalun tarpeelliseksi, etenkin jos kyseessä on monimutkainen kokonaisuus tai hyödynnetään automatisointia. Mallinnustyökalussa olisi hyvä olla mahdollisuus metadatan lisäämisen lisäksi myös dokumentaatiolle. Näin tarpeellinen dokumentaatio saadaan riittävän lähelle dataa.

Kimball et al. (2011) mukaan tietojen mallinnuksessa tulee luoda fyysinen malli, joka kertoo tietovarastoon tulevien taulujen tarkan rakenteen. Suunnitteluperiaatteiden mallista poiketen haastateltavat eivät kokeneet tätä tarpeelliseksi modernin tietovaraston suunnittelussa, etenkään jos tietovarastoinnissa käytetään automatisointia. Automatisoinnissa käytettävät teknologiat osaavat muodostaa fyysisen mallin loogisen mallin

pohjalta, joten liian tarkka mallintaminen vie resursseja muulta työltä. Automatisoinnilla voidaan vapauttaa tietovarastokehittäjien työaikaa enemmän arvon luomiseen datasta.

6.6 Informaation toimituskerroksen suunnittelu

Datan toimittaminen liiketoiminnan hyödynnettäväksi edellyttää suunnitteluperiaatteiden mallin mukaisesti tietovaraston informaation toimituskerroksen suunnittelua. Kuvassa 20 esitellään tutkimuksessa havaitut tärkeimmät ominaisuudet informaation toimitukselle loppukäyttäjien näkökulmasta.

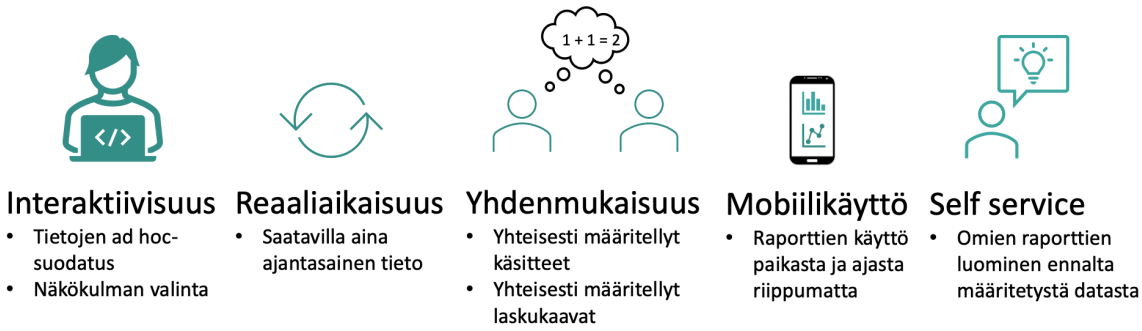

Kuva 20. Loppukäyttäjien vaatimukset informaation toimituskerrokselle

Oksanen et al. (2020) mukaan loppukäyttäjiä ei tule päästää tekemään hakuja suoraan tietovarastoon, vaan heille toimitetaan data halutussa muodossa, esimerkiksi BI-työkaluilla toteutetulla raportilla. Reevesin (2009) ja Vaismanin (2014) mukaan BI-työkaluilla voidaan tuottaa interaktiivisia raportteja loppukäyttäjille. Interaktiiviset raportit olivat haastateltavien mielestä tärkeä osa modernia tietovarastoa. Aiemmin raportit ovat olleet kohdeyrityksessä staattisia, sähköpostilla toimitettuja raportteja. Näiden tietoja on jouduttu yhdistelemään manuaalisesti, mikäli on tullut tarve tutkia jotain raportista poikkeavaa tietoa. Manuaalinen tietojen yhdistäminen eri raporteilta vie paljon työaikaa sekä lisää virheiden riskiä. Modernin tietovaraston avulla voidaan mallin mukaisesti tuottaa loppukäyttäjille eri lähteiden dataa yhdisteleviä interaktiivisia raportteja.

Interaktiivisten raporttien avulla käyttäjille voidaan tarjota mahdollisuus valita itse näkökulma datan tarkasteluun ja näin ollen yhdellä raportilla voidaan ratkaista useampia tarpeita. Lisäksi raporttien tulisi mahdollistaa sekä kokonaiskuvan tarkastelu nopealla vilkaisulla että tarkempi tietoihin porautuminen samassa näkymässä. Interaktiivisuuden lisäksi modernin tietovaraston informaation toimitukseen liittyy kuvan 20 mukaisesti toive reaaliaikaisuudesta. Myös van der Lans (2012) ja Oksanen et al. (2020) korostavat suunnitteluperiaatteiden mallissa reaaliaikaisen raportoinnin tärkeyttä. Nykyään liiketoiminta

on usein nopeatempoista ja jopa vuorokauden viive raporteilla voi olla liian pitkä. Haastateltavien mukaan tulee huolehtia, ettei datan polku lähdejärjestelmästä raportille muodostu liian pitkäksi, jotta reaaliaikaisen raportoinnin tarjoaminen on mahdollista.

Van der Lansin (2012) mukaan loppukäyttäjille on tärkeää, että tieto raporteilla on luotettavaa ja saatavilla aina tarvittaessa. Haastateltavien mukaan yksi suurimmista haasteista raporttien luotettavuudelle on käsitteiden epäjohdonmukainen käyttö. Termit tulee määritellä yhdessä liiketoiminnan kanssa osana tietotarpeiden määrittelyä. Lisäksi on syytä huolehtia, että yrityksen sisällä käytetään yhtenäisiä termejä. Käyttämällä yhteisesti sovittuja termejä varmistutaan siitä, että kaikki raportin käyttäjät tulkitsevat raportilla olevat luvut samalla tavalla. Lisäksi raporttien dokumentaatioon tulee kiinnittää huomiota, kuten jo luvussa 6.1 todettiin. Näin pystytään viestimään raporttien käyttäjille mahdollisista huomioista. Mikäli raporteilla huomataan myöhemmin kehitystarpeita, on niiden kehittämisen pariin helpompaa palata, kun dokumentaatiosta voidaan tarkastaa aiemmin sovitut ja tehdyt muutokset.

Informaation toimittamiseen valittaviin työkaluihin pätee luvussa 6.4. esitellyt kriteerit soveltuvin osin. Valittavien työkalujen tulee haastateltavien mielestä olla liiketoiminnan tarpeisiin soveltuvia sekä riittävän helppokäyttöisiä ja tehokkaita, jotta niiden hyödyntäminen on loppukäyttäjien näkökulmasta mielekästä. Lisäksi hyviä ominaisuuksia modernille raportointityökalulle on mobiilikäyttö ja niin sanottu Self service – raportointi, eli liiketoiminnan edustaja pystyy muodostamaan itse raportteja ennalta määrätystä datasta ilman syvällistä teknistä osaamista. Raportoinnin lisäksi on hyvä huomioida myös muut tietojen hyödyntämistarpeet. On hyvä miettiä valmiiksi ratkaisut, joiden avulla esimerkiksi data-analyytikot ja data scientistit pystyvät hakemaan tarvitsemansa datan tietovarastosta. Erilaiset valmiit datanäkymät tai rajapinnat ovat tähän toimiva ratkaisu. Myös näiden osalta tulee huolehtia joustavuudesta ja skaalautuvuudesta mahdollistaen nopeastikin muuttuviin vaatimuksiin vastaaminen.

7. YHTEENVETO

Tutkimuksen tavoitteena oli selvittää modernin tietovaraston suunnitteluperiaatteet ja muodostaa niistä malli kohdeyritykselle uuden tietovaraston suunnittelun tueksi. Tutkimuksen tavoitteen saavuttamiseksi asetettiin päätutkimuskysymys, johon pyrittiin löytämään vastaus kolmen alatutkimuskysymyksen avulla. Tutkimuksessa suoritettiin ensiksi kirjallisuuskatsaus, jossa tarkasteltiin tietovarastoa yleisesti ja keskeisimpiä eroja operatiivisiin järjestelmiin sekä tietovaraston suunnitteluprosessia. Näiden pohjalta koottiin modernin tietovaraston suunnitteluperiaatteiden malli, jonka toimivuutta testattiin empiriassa asiantuntijoita haastattelemalla. Nämä tulokset yhdistettiin teoriaan mallia tarkentaen. Tässä luvussa esitetään tutkimuksen tulosten yhteenveto, vastataan asetettuihin tutkimuskysymyksiin, arvioidaan tutkimus sekä tarkastellaan työn rajoitteita ja jatkotutkimusaiheita.

7.1 Tulosten yhteenveto

Tutkimuksen perusteella moderni tietovarasto on perinteistä tietovarastoa laajempi kokonaisuus sisältäen tietotarpeiden määrittelyn, raakadatan, mahdollisen automatisoinnin, tietojen latauksen ja varastoinnin sekä informaation toimittamisen työkaluineen. Erityisesti raakadatan tallentaminen raakatietovarastoon erottaa modernin tietovaraston perinteisemmästä tietovarastosta. Raakadatan avulla tietovarastoon tehdyt kerrokset voidaan tarvittaessa toteuttaa kokonaan uudelleen ilman, että hävitetään historiadataa. Moderni tietovarasto mahdollistaa datojen lataamisen samalle alustalle riippumatta sen rakenteesta, mikä mahdollistaa aiempaa laajemman tietojen hyödyntämisen liiketoiminnan päätöksenteossa ja kehittämisessä.

Kuvassa 21 on esitetty tutkimuksessa tunnistetut modernin tietovaraston suunnitteluperiaatteet sekä niiden kytkeytyminen toisiinsa. Kuvan mukaisesti tietovarastoprojekti lähtee liikkeelle liiketoiminnalta tulevasta tarpeesta, jonka jälkeen itse projekti suunnitellaan, tehdään suuret linjaukset esimerkiksi arkkitehtuurin suhteen ja päätetään käytännön toimintatavoista. Tämän jälkeen loput vaiheet suoritetaan iteratiivisesti vertikaalisia kehitysputkia hyödyntäen, jotta mahdollisimman nopeasti saadaan liiketoiminnan käyttöön esimerkiksi valmiita raportteja.

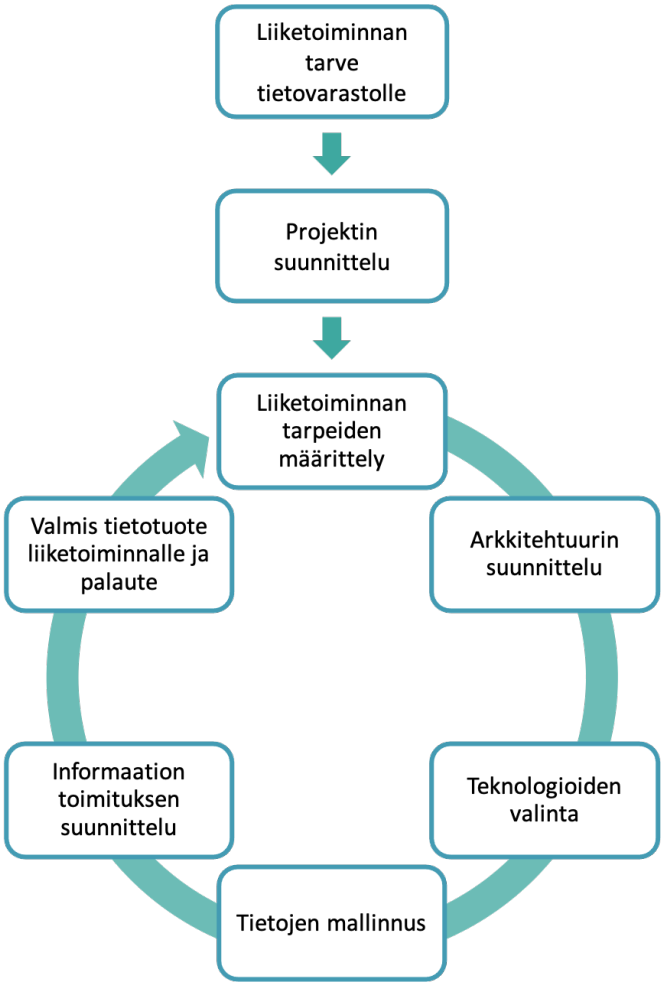

Kuva 21. Modernin tietovaraston suunnitteluperiaatteet prosessina

Modernin tietovaraston suunnittelussa liiketoiminnan vaatimusten keräämiseen ei lähdetä täydellisen kattavan kokonaiskuvan keräämisen näkökulmasta, vaan edetään pienemmissä kokonaisuuksissa iteroiden. Näin pystytään varmistamaan, että vastataan ajankohtaiseen tarpeeseen ja valmis tietotuote saadaan nopeammin liiketoiminnan käyttöön. Esimerkiksi valmiin raportin saaminen liiketoiminnan käyttöön voi auttaa liiketoiminnan edustajia miettimään ja tarkentamaan tulevia tarpeitaan, kun heille konkretisoituu tietovaraston mahdollisuudet ja sen tuottama hyöty.

Tietovarastoarkkitehtuurin, käytettävien teknologioiden sekä informaation toimituksen suunnittelussa tärkeimpiä tekijöitä ovat liiketoiminnan tarpeiden tukeminen, kustannukset sekä joustavuus. Moderniin tietovarastoon ei ole tarpeen määritellä tietynlaista rakennetta tai tietomallia, vaan ennen kaikkea tulee valita yrityksen tarpeisiin parhaiten soveltuvat. Myös kustannukset pitää ottaa huomioon, erityisesti pitkällä aikavälillä. Tietomallin suunnittelussa on tärkeää, että tiedot mallinnetaan liiketoiminnan tarpeita ja ra-

kennetta mukaillen ja käytetään yhdessä määriteltyjä termejä. Niiden avulla eri sidosryhmien on helpompaa kommunikoida keskenään ja voidaan parantaa sekä raporttien että tietovaraston datan luotettavuutta.

7.2 Tutkimuskysymyksiin vastaaminen

Tutkimuksen ensimmäinen alatutkimuskysymys oli *mikä on tietovarasto?* Tietovarasto tunnistettiin tutkimuksessa tietokannaksi, jonne voidaan tallentaa ja säilöä dataa useista lähdejärjestelmistä. Tietovarastossa on analysointia tukevaan muotoon tallennettua dataa, jota toimitetaan loppukäyttäjille erilaisten työkalujen avulla, kuten raportteina. (Ponniah 2010; Kimball & Ross 2013; Bojičić et al. 2016; Yessad & Labiod 2016) Eri lähdejärjestelmien data mallinnetaan tietovarastoon liiketoimintalähtöisesti yhtenäiseen muotoon, minkä ansiosta eri lähteiden dataa voidaan hyödyntää liiketoiminnalle toimitettavissa raporteissa ja analyyseissä. Tietovaraston tavoitteena on tukea liiketoiminnan päätöksentekoa sekä tarjota kokonaiskuva yrityksen nykytilasta ja historiasta riittävän yksinkertaisesti mallinnettuna. (Reeves 2009; Ponniah 2010; Kimball & Ross 2013; Bojičić et al. 2016; Santoso & Yulia 2017)

Toisen alatutkimuskysymyksen avulla selvitettiin, *millainen on tietovaraston rakenne?* Tutkimuksessa tunnistettiin tietovaraston koostuvan useista komponenteista, jotka voidaan yhdistää eri tavoin riippuen valitusta arkkitehtuurista sekä liiketoiminnan tarpeesta. Tietovarasto koostuu datalähteistä, tiedon lataus- ja varastointi- sekä informaation toimituskerroksesta (Ponniah 2010; Vaisman 2014). Riippuen valitusta arkkitehtuurista, etenkin tiedon varastointikerros voidaan organisoida usealla tavalla. Tiedot voidaan varastoida yhteen, koko yrityksen kattavaan EDW-rakenteeseen, useaan erilliseen liiketoimintakohtaiseen data marttiin tai näiden yhdistelmään (Sen & Sinha 2005; Ariyachandra & Watson 2010; Blazic et al. 2017).

Modernissa tietovarastoarkkitehtuurissa raakadata ladataan usein erilliselle tietoalustalle, esimerkiksi data lakeen, josta tiedot muokataan ja ladataan keskitettyyn EDW-rakenteeseen. Raakatietovarastosta tiedot toimitetaan hyödyntämiskerroksella sijaitsevien pienempien data marttien kautta informaation toimituskerrokselle eli esimerkiksi raporteille. (Vaisman 2014; Chawla & Khattar 2020; Oksanen et al. 2020)

Kolmannessa alatutkimuskysymyksessä selvitettiin, *kuinka tietovarasto suunnitellaan?* Tutkimuksessa tunnistettiin tietovaraston suunnitteluprosessin koostuvan kolmesta kokonaisuudesta: projektin suunnittelu, liiketoiminnan vaatimusten kerääminen sekä tietovaraston rakenteellinen suunnittelu. Viimeisenä mainittu jakautuu kolmeen alakokonai-

suuteen, joita ovat tekninen suunnittelu, tietojen mallinnuksen suunnittelu sekä informaation toimituksen suunnittelu. (Ponniah 2010; Kimball et al. 2011) Aluksi tietovarastoprojekti suunnitellaan projektinhallinnallisesta näkökulmasta eli määritetään sidosryhmille roolit, sovitaan käytännön työtavoista sekä päätetään tietovaraston suuret linjat.

Seuraavaksi kerätään liiketoiminnan vaatimuksia, joiden pohjalta tiedetään mitä dataa tietovarastoon tarvitaan ja millaista dataa sieltä saadaan ulos valmiin tietotuotteen muodossa. Aiemmin on koettu tärkeäksi kerätä mahdollisimman kattava kuva liiketoiminnan tarpeista heti projektin alussa (Malinowski & Zimányi 2008; Reeves 2009; Kimball et al. 2011), mutta empiria osoitti, että on tärkeämpää kerätä vaatimuksia pieninä kokonaisuuksina, jotta niille voidaan tuottaa vastine mahdollisimman pian. Valmiin tuotteen jälkeen voidaan taas määritellä uusia tarpeita, joita lähdetään työstämään. Näitä kokonaisuuksia voidaan työstää joustavasti myös rinnakkain.

Teknisessä suunnittelussa tietovarastolle määritellään arkkitehtuuri sekä valitaan käytettävät teknologiat. Näiden suunnittelussa on syytä ottaa huomioon, että ne tukevat toisiaan ja ovat skaalautuvia sekä joustavia. Näin ne pystyvät muuntumaan liiketoiminnan jatkuvasti muuttuviin tarpeisiin. (Westerman 2001; Inmon 2005; Silvers 2008) Empiria osoitti kustannusten sekä osaamisen olevan tärkeitä kriteereitä teknologioiden valinnassa. Tietomallin suunnittelussa valitaan liiketoiminnan tarpeisiin sopiva mallinnustapa, jonka avulla mahdollistetaan tietojen tehokas hyödyntäminen. Tietomallin avulla tiedetään, missä datat sijaitsevat tietovarastossa ja kuinka ne kytkeytyvät toisiinsa (Inmon et al. 2019).

Informaation toimituskerroksen suunnitteluvaiheessa suunnitellaan tavat, joilla tietoa voidaan toimittaa liiketoiminnan hyödynnettäväksi sekä analyytikoille analysoitavaksi. Tähän voidaan käyttää esimerkiksi BI-työkaluja, joiden avulla rakennetaan interaktiivisia raportteja (Reeves 2009; Vaisman 2014). Empiria osoitti, että myös informaation toimituksen suunnittelussa on tärkeää ottaa huomioon liiketoiminnan tarpeet ja kustannukset. Lisäksi on tärkeää, että valituilla työkaluilla pystytään toimittamaan luotettavaa, ajantasaista sekä aina käytössä olevaa tietoa loppukäyttäjille (van der Lans 2012).

Luvussa 1 tutkimukselle asetettiin päätutkimuskysymys *Millaiset ovat modernin tietovarastoinnin suunnitteluperiaatteet?* Alatutkimuskysymysten avulla selvitettiin, että tietovarasto on useista komponenteista koostuva kokonaisuus, jonka suunnitteluun kuuluu eri vaiheita. Kirjallisuuden pohjalta tunnistetut suunnitteluperiaatteet järjesteltiin Kimballin elinkaarimallin (kuva 10) mukaiseen järjestykseen, joka osoittautui empirian perusteella liian joustamattomaksi ja lineaariseksi modernin tietovaraston suunnitteluun. Modernin

tietovaraston suunnitteluun ja kehittämiseen sopii paremmin kuvan 21 mukaisesti iteratiivinen kehittäminen, minkä avulla tietovarastoa voidaan kehittää pienemmissä osissa, eikä heti projektin alussa tarvitse olla tiedossa kaikkia tulevia tarpeita. Iteratiivisella työskentelyllä voidaan puuttua ilmeneviin ongelmakohtiin heti, eivätkä ne pääse toistumaan tietovarastossa niin helposti, kuin lineaarisemmassa kehittämisessä.

Tutkimuksessa tunnistettiin kahdeksan modernin tietovaraston suunnitteluperiaatetta:

1) Liiketoiminnalta tuleva tarve tietovarastolle
2) Projektin suunnittelu
3) Liiketoiminnan tarpeiden määrittely
4) Arkkitehtuurin suunnittelu
5) Teknologioiden valinta
6) Tietojen mallinnus
7) Informaation toimituksen suunnittelu
8) Valmiin tietotuotteen toimittaminen liiketoiminnalle ja palautteen kerääminen.

Moderni tietovarastoprojekti alkaa, kun liiketoiminnalta tulee tarve uudelle tietovarastolle. Tämän jälkeen suoritetaan vaihe 2, jonka aikana suunnitellaan projektin käytännön asiat, eteneminen sekä tietovaraston suuret linjat. Kun projekti on suunniteltu projektinhallinnallisesta näkökulmasta, edetään varsinaisen tietovaraston suunnitteluun. Vaiheita 3–8 suoritetaan iteratiivisesti niin, että mahdollisimman varhaisessa vaiheessa saadaan toteutettua liiketoiminnalle ensimmäinen versio kehitettävästä tietotuotteesta, esimerkiksi raportista. Tietovarastoa suunnitellaan mahdollisimman pienissä paloissa eli toteutetaan eri kerroksista sen verran, että pystytään etenemään seuraavaan vaiheeseen. Vaiheita voidaan suorittaa myös kuvan 21 mukaisesta järjestyksestä poiketen, esimerkiksi rinnakkain. Tietovaraston kerrokset valmistuvat pala palalta valmiimmaksi kokonaisuudeksi ja liiketoiminta pääsee hyödyntämään tietovarastoa jo varhaisessa vaiheessa. Näin tietovarasto ei aiheuta alkuvaiheessa pelkästään kustannuksia vaan myös hyödyt konkretisoituvat.

7.3 Tutkimuksen arviointi

Tutkimuksen tekemiseen kuuluu osana sen arvioiminen. Tutkimusta arvioidaan määriteltyjen arviointikriteerien avulla. Arvioinnissa tarkastellaan tutkimuksen tulosten luotettavuutta, sovellettavuutta sekä tavoitteiden saavuttamista. (Saaranen-Kauppinen & Puusniekka 2009) Laadullista tapaustutkimusta voidaan arvioida esimerkiksi Guban

(1981) nelijaon mukaisesti, joka on yleisesti tunnustettu menetelmä laadullisen tutkimuksen arvioimiseen. (Guba & Lincoln 1994; Thomas & Magilvy 2011) Nelijaon mukaisesti tutkimusta arvioidaan tutkimuksen uskottavuuden, yleistettävyyden ja sovellettavuuden, varmuuden sekä vahvistettavuuden näkökulmista.

Tutkimuksen uskottavuutta tarkastellaan tutkimusmetodologian ja -tulosten oikeellisuuden sekä ristiriidattomuuden kautta. Tutkimuksen uskottavuutta voidaan parantaa toteuttamalla tutkimusprosessi ja kuvaamalla se selkeästi. Lisäksi metodologiset valinnat tulee olla perusteltuja. (Hirsjärvi et al. 2009) Aineistosta tehdyt tulkinnat täytyy perustella sekä kirjoittaa mahdollisuuksien mukaan auki (Saaranen-Kauppinen & Puusniekka 2009).

Tutkimusstrategiaksi valittiin luvun 1.3. mukaisesti tutkimusotteeltaan laadullinen tapaustutkimus, joka soveltui tutkimuksen kontekstissa tutkimuskohteen ymmärtämiseen ja kuvaamiseen. Tutkimuksessa selvitettiin tapaustutkimuksen kriteerien mukaisesti, miten suunnitellaan moderni tietovarasto kohdeyrityksen kontekstissa, joten tapaustutkimus oli sopiva valinta tähän tutkimukseen. Teemahaastattelun käyttäminen tiedonkeruumenetelmänä oli perusteltua, sillä sen avulla pystyttiin tuomaan esiin haastateltavien näkemyksiä sekä luomaan syvällisempi ymmärrys tutkimuksen aiheesta. Haastattelutilanteessa haastattelujen nauhoittamisella pystytään parantamaan tutkimuksen uskottavuutta (Saaranen-Kauppinen & Puusniekka 2009). Luvussa 4.3. esitetyn mukaisesti tutkimuksen aikana suoritetut haastattelut nauhoitettiin ja litteroitiin tulosten analysointia varten. Tämän jälkeen tulokset analysoitiin temaattisen analyysin avulla.

Tutkimuksen yleistettävyyttä ja sovellettavuutta arvioidaan sen avulla, kuinka hyvin tutkimuksen tulokset voidaan yleistää ja siirtää muihin tilanteisiin. Tapaustutkimuksessa pyritään tutkimaan tutkimusilmiötä syvällisesti valitussa kontekstissa, joten sen tavoitteena ei ole tulosten yleistettävyys. On kuitenkin mahdollista, että tapaustutkimus tarjoaa joissain tilanteissa myös kontekstin ylittävää tietoa ja mahdollisuuksia soveltaa tuloksia muihin konteksteihin. (Saaranen-Kauppinen & Puusniekka 2009)

Tutkimuksessa selvitettiin modernin tietovaraston suunnitteluperiaatteita digitaalisia palveluita tarjoavan yrityksen kontekstissa, jolla on useita eri lähdejärjestelmiä, joiden dataa halutaan varastoida yhteen paikkaan. Empiirinen aineisto rajautui lähes kokonaan kyseisen yrityksen asiantuntijoiden näkemyksiin, mutta sitä saatiin hieman laajennettua haastattelemalla yrityksen ulkopuolista asiantuntijaa, jolla on kokemusta tietovarastoinnista eri aloilla toimivissa yrityksissä. On mahdollista, että tutkimuksessa saatujen tulosten perusteella voidaan suunnitella toimiva moderni tietovarasto myös muun alan yrityksessä,

mikäli tavoitteena on suunnitella usean lähteen datan lataaminen yhteen paikkaan. Empiirisen aineiston havainnot tukivat kirjallisuuskatsauksessa saatuja tuloksia, mikä tukee myös siirrettävyyden mahdollisuutta muihin yrityksiin.

Näiden lisäksi yleistettävyyttä voidaan arvioida tarkoituksenmukaisen aineiston kokoamisella (Saaranen-Kauppinen & Puusniekka 2009). Aineisto voidaan osoittaa riittäväksi sen kyllääntyessä eli saavutettaessa saturaatio. Haastatteluaineisto kyllääntyy, kun se alkaa toistaa itseään eikä sen kerääminen enää tuota tutkimuskysymysten kannalta uutta tietoa. (Eskola & Suoranta 1998) Tässä tutkimuksessa saturaatio saavutettiin melko hyvin, sillä haastattelujen edetessä niissä saadut vastaukset alkoivat muistuttaa hyvin pitkälti toisiaan. On kuitenkin mahdollista, että kasvattamalla haastateltavien määrää olisi voitu saavuttaa uusia vastauksia tutkimuskysymyksiin. Teemahaastattelulle on kuitenkin tyypillistä, että otoskoko on pieni ja suuremmalla otoksella aineiston analysointi sekä havaintojen tekeminen olisi voinut vaikeutua.

Tutkimuksen varmuuden arvioimiseksi tarkastellaan tutkimuksen ja tutkijan ennakko-oletuksia. Laadullisessa tapaustutkimuksessa tunnistetaan tutkimukseen vaikuttavaksi tekijäksi tutkijan subjektiivisuus. Tutkimuksen tavoitteena on kuvailla tutkimuskohdetta huomioimatta tutkijan ennakko-oletuksia, minkä vuoksi tutkijan tulee tunnistaa omat ennakkoasenteensa tutkittavaa aihetta kohtaan ja toimia niin, ettei niillä ole vaikutusta tutkimuksen lopputulokseen. (Saaranen-Kauppinen & Puusniekka 2009) Tässä tutkimuksessa pyrittiin aktiivisesti pitämään tutkijan ennakko-oletukset erillään aineiston ja tulosten tulkitsemisesta. Tapaustutkimuksen luonne on kuitenkin subjektiivinen, joten on mahdollista, että toinen tutkija toteuttaessaan tämän tutkimuksen voi tulkita tuloksia joiltain osin eroavasti tämän tutkimuksen tuloksiin verrattuna.

Tutkimuksen vahvistuvuutta arvioidaan sen perusteella, saavatko tutkimuksen tulokset tukea aikaisemmista tutkimuksista (Guba & Lincoln 1994). Tutkimuksessa vertailtiin empiirisen aineiston tuloksia teoriaan johtopäätelmien muodostamiseksi. Tämä on esitelty luvussa 6. Tutkimuksen vahvistuvuutta tukee se, että empiirisen aineiston tulokset tukivat pääosin teoriaosuudessa esiteltyjä aihepiiristä tehtyjä aiempia tutkimuksia.

Tutkimuksen tavoitteena oli löytää suunnitteluperiaatteet, joiden avulla voidaan suunnitella moderni tietovarasto. Tutkimuksen yhtenä päämääränä oli tuottaa kohdeyritykselle malli, jonka avulla heille voidaan suunnitella uusi, moderni tietovarastokokonaisuus, jolla pystytään vastaamaan liiketoiminnan vaatimuksiin paremmin kuin aiemmalla tietovarastolla. Tämän tutkimuksen tulokset soveltuvatkin parhaiten kohdeyrityksen käyttöön ja muille yrityksille, joilla on samankaltaiset liiketoiminnan tarpeet. Tutkimuksessa saatiin

kirjallisuuskatsauksen ja tapaustutkimuksen avulla muodostettua vastaus tutkimuskysymyksiin sekä lisättiin ymmärrystä tietovarastosta ja sen suunnittelusta. Tutkimustulosten ja niistä tehtyjen johtopäätösten valossa voidaan todeta tutkimuksen saavuttaneen tavoitteensa.

7.4 Tutkimuksen rajoitteet ja jatkotutkimusaiheet

Tutkimuksen empiirinen aineisto rajoittui digitaalisen palveluliiketoiminnan parissa toimivan kohdeyrityksen asiantuntijoiden sekä yhden ulkopuolisen konsultointitehtävissä toimivan asiantuntijan haastatteluihin. Kohdeyrityksessä on jo olemassa olevaa osaamista tietovarastoinnista ja paljon moderneja teknologioita käytössä, joten jatkotutkimuksen kannalta olisi aiheellista tutkia modernin tietovaraston kehittämistä ympäristössä, jossa yrityksestä ei löydy valmiiksi teknistä osaamista tietovarastointiin. Erityisesti olisi mielenkiintoista tutkia, kuinka valmiin osaamisen puuttuminen vaikuttaisi suunnitteluperiaatteisiin.

Tutkimus rajoittui kohdeyrityksen kontekstiin ja käsitteli pitkälti usean lähdejärjestelmän datan lataamista yhteen tietovarastoon. On kuitenkin olemassa yrityksiä, joiden tarpeet ovat hyvin poikkeavia kohdeyrityksen tarpeista ja olisikin mielenkiintoista tutkia, kuinka lähdejärjestelmien organisoituminen sekä liiketoiminnan tarpeet vaikuttavat suunnitteluperiaatteisiin erilaisissa yrityksissä.

Tutkimuksen aikajänteen ja laajuuden vuoksi tutkimus rajoittui modernin tietovaraston suunnitteluperiaatteiden mallin luomiseen teorian pohjalta sekä sen toimivuuden testaamiseen haastatteluilla. Mallin toimivuutta ei päästy testaamaan todellisessa ympäristössä, joten sen toimivuus jäi teoriatasolle. Jatkotutkimuksessa voitaisiin testata mallin toimivuutta käytännössä suunnittelemalla sen avulla yritykselle uusi moderni tietovarasto ja keräämällä palautetta mallin toimivuudesta, sekä siitä, saavutetaanko mallin avulla liiketoiminnan tarpeisiin vastaava tietovarasto.

LÄHTEET

Adriano, M. (2013). Further in Agility with Data Vault.

Ariyachandra, T. & Watson, H. (2010). Key organizational factors in data warehouse architecture selection. Decision Support Systems. Vol. 49(2), s.200–212.

Bimonte, S., Ibtisam, F. I. & Boukhalfa, K. (2019). Logical and Physical Design of Spatial Non-Strict Hierarchies in Relational Spatial Data Warehouse. International Journal of Data Warehousing and Mining (IJDWM). Vol. 15(1), s.1–18.

Blazic, G., Poscic, P. & Jaksic, D. (2017). Data warehouse architecture classification. MIPRO. s.1491–1495.

Bojičić, I., Marjanović, Z., Turajlić, N., Petrović, M., Vučković, M. & Jovanović, V. (2016). A comparative analysis of data warehouse data models. 2016 6th International Conference on Computers Communications and Control (ICCCC). s.151–159.

Brackett, M. (2011). Data Resource Simplexity: How Organizations Choose Data Resource Success or Failure, 1st ed. Technics Publications, LLC.

Braun, V. & Clarke, V. (2006). Using thematic analysis in psychology. Qualitative research in psychology. Vol. 3(2), s.77–101.

Chaudhuri, S. & Dayal, U. (1997). An overview of data warehousing and OLAP technology. SIGMOD record. Vol. 26(1), s.65–74.

Chaudhuri, S., Dayal, U. & Narasayya, V. (2011). An overview of business intelligence technology. Communications of the ACM. Vol. 54(8), s.88–98.

Chawla, H. & Khattar, P. (2020). Data Lake Analytics on Microsoft Azure: A Practitioner's Guide to Big Data Engineering. Apress L. P. Berkeley, CA.

Chen, G., An, B. & Liu, Y. (2016). A novel agent-based parallel ETL system for massive data. 2016 Chinese Control and Decision Conference (CCDC). s.3942–3948.

Eriksson, P. & Kovalainen, A. (2016). Qualitative methods in business research, 2nd ed. Sage Publications. London.

Eskola, J. & Suoranta, J. (1998). Johdatus laadulliseen tutkimukseen. Vastapaino. Tampere.

Farquhar, J. D. (2012). Case study research for business. SAGE. Los Angeles, [Calif.]

Gardner, S. (1998). Building the data warehouse. Communications of the ACM. Vol. 41(9), s.52–60.

Gendron, M. S. (2014) Business intelligence and the cloud: strategic implementation guide. 1st ed. Wiley. Hoboken, New Jersey.

Giorgini, P., Rizzi, S. & Garzetti, M. (2005). Goal-oriented requirement analysis for data warehouse design. Data Warehousing and OLAP. s.47–56.

Gordon, K. (2017). Modelling business information: entity relationship and class modelling for business analysts, 1st ed. The Chartered Institute for IT. Swindon.

Guba, E. G. (1981). Criteria for assessing the trustworthiness of naturalistic inquiries. Educational Communication & Technology. Vol. 29(2), s.75–91.

Guba, E. G. & Lincoln, Y. S. (1994). Competing paradigms in qualitative research. Handbook of qualitative research. s.105–117.

Gucer, V., Bergbauer, W., Berkhout, M., Bodenheimer, T. & Mello, A. (2005). Tivoli Data Warehouse Version 1.3: Planning and Implementation, 1st ed. I B M. Durham.

Gupta, Saurabh. & Giri, Venkata. (2018). Practical Enterprise Data Lake Insights Handle Data-Driven Challenges in an Enterprise Big Data Lake, 1st ed. Apress. Berkeley, CA.

Haarbrandt, B., Wilschko, A. & Marschollek, M. (2016). Modelling of Operative Report Documents for Data Integration into an open EHR-Based Enterprise Data Warehouse. Studies in health technology and informatics. Vol. 228, s.407.

Hajmoosaei, A., Kashfi, M. & Kailasam, P. (2011). Comparison plan for data warehouse system architectures. The 3rd International Conference on Data Mining and Intelligent Information Technology Applications. s.290–293.

Hanlin, Q., Xianzhen, J. & Xianrong, Z. (2012). Research on Extract, Transform and Load (ETL) in Land and Resources Star Schema Data Warehouse. 2012 Fifth International Symposium on Computational Intelligence and Design. Vol. 1, s.120–123.

Haq, Q. M. R. U. (2016). Data mapping for data warehouse design. Morgan Kaufmann. Waltham, Massachusetts.

Harkal, S. (2019). Key differences between an OLTP system and a data warehouse. Saatavissa (viitattu 8.11.2020): https://etlpoint.com/key-differences-between-an-oltp-system-and-a-data-warehouse/.

Hirsjärvi, S. & Hurme, H. (2008). Tutkimushaastattelu: teemahaastattelun teoria ja käytäntö. Gaudeamus Helsinki University Press. Helsinki.

Hirsjärvi, S., Remes, P. & Sajavaara, P. (2009). Tutki ja kirjoita, 15th ed. Tammi. Helsinki.

Hossain, Md. M., Azim, T., Karim, Md. Y. & Hoque, A. S. M. L. (2009). Integrated data warehousing for telecommunication industries. 2009 12th International Conference on Computers and Information Technology. s.657–662.

Hovi, A. (2001). Tietovarastot liiketoiminnan tukena. Satku. Helsinki.

Hovi, A. (2005). Tietokantojen suunnittelu & indeksointi, 1th ed. Docendo. Jyväskylä.

Hovi, A. (2009). Tietovarastot ja Business Intelligence. WSOYpro. Jyväskylä.

Hovi, A. (2011). Data warehouse - kannan suunnittelu. Ari Hovi Oy.

How, M. (2020). The Modern Data Warehouse in Azure: Building with Speed and Agility on Microsoft's Cloud Platform, 1st ed. Apress L. P. Berkeley, CA.

Howson, C. (2008). Successful business intelligence secrets to making BI a killer app, 1st ed. McGraw-Hill. New York, NY.

Hughes, R. (2016). Agile data warehousing for the enterprise: a guide for solution architects and project leaders, 1st ed. Morgan Kaufmann. Amsterdam, Netherlands.

Hultgren, H. (2012). Data Vault modelling guide.

Imhoff, C., Galemmo, N. & Geiger, J. G. (2003). Mastering Data Warehouse Design: Relational and Dimensional Techniques, 1st ed. Wiley. Hoboken.

Inmon, W. H. (2005). Building the Data Warehouse, 4th ed. Wiley. Indianapolis, IN.

Inmon, W. H., Imhoff, C. & Sousa, R. (2002). Corporate Information Factory, 1st ed. Wiley. Hoboken.

Inmon, W. H., Linstedt, D. & Levins, M. (2019). Data Architecture: A Primer for the Data Scientist. Elsevier Science & Technology. San Diego.

John, T., Misra, P. & Benjamin, T. (2017). Data Lake for enterprises: leveraging Lambda architecture for building Enterprise Data Lake, 1st ed. Packt. Birmingham, England.

Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modelling. John Wiley & Sons, Incorporated. New York, United States.

Kimball, R., Ross, M., Thornthwaite, W., Mundy, J. & Becker, B. (2011). The Data Warehouse Lifecycle Toolkit, 1st ed. Wiley. Somerset.

Laurent, A., Laurent, D. & Madera, C. (2020). Data Lakes. John Wiley & Sons, Incorporated. Newark.

Lee Allen, S. (2005). Beginning Relational Data Modeling, 2nd ed. Apress. Berkeley, CA.

Li, Y., Yu, X. & Li, C. (2010). The Applied Research on the Statistic Data Warehouse Based on the Snowflake Mode. 2010 2nd International Workshop on Database Technology and Applications. s.1–4.

Linstedt, D. & Graziano, K. (2011a). Introduction to Data Vault Modeling.

Linstedt, D. & Graziano, K. (2011b). Super Charge Your Data Warehouse: Invaluable Data Modeling Rules to Implement Your Data Vault. CreateSpace Independent Publishing Platform.

List, B., Bruckner, R., Machaczek, K. & Schiefer, J. (2002). A comparison of data Warehouse development methodologies case study of the Process Warehouse. s.203–215.

Llave, M. R. (2018). Data lakes in business intelligence: reporting from the trenches. Procedia computer science. Vol. 138, s.516–524.

Malinowski, E. & Zimányi, E. (2008). Advanced Data Warehouse Design: From Conventional to Spatial and Temporal Applications, 1st ed. Springer-Verlag. Berlin, Heidelberg.

Marotta, A. & Ruggia, R. (2002). Data warehouse design: a schema-transformation approach. SCCC. s.153–161.

Munawar, M., Salim, N. & Ibrahim, R. (2011). Towards Data Quality into the Data Warehouse Development. dasc. s.1199–1206.

Mundy, J., Thornthwaite, W. & Kimball, R. (2011) The Microsoft® Data Warehouse Toolkit: With SQL Server 2008 R2 and the Microsoft® Business Intelligence Toolset, 1st ed. Wiley. Indianapolis.

Nowell, L. S., Norris, J. M., White, D. E. & Moules, N. J. (2017). Thematic Analysis: Striving to Meet the Trustworthiness Criteria. International journal of qualitative methods. Vol. 16(1).

O'Gorman, K. & MacIntosh, R. (2016). Research methods for business & management: a guide to writing your dissertation, 2nd ed. Goodfellow Publishers Ltd. Oxford, England.

Oksanen, M., Nyman, Y. & Johnsson, K. (2020). Moderni tietoalusta - ”Datan jalostamisen hybridiarkkitehtuuri”. Sytyke 3/2020. Vol. 8, s.14–18.

Olschimke, M. & Linstedt, D. (2016). Building a scalable data warehouse with data vault 2.0. Morgan Kaufmann. Amsterdam, Netherlands.

Ponniah, P. (2010). Data Warehousing Fundamentals for IT Professionals, 2nd ed. John Wiley & Sons, Incorporated. Hoboken.

Rahim, S. A., Chakraborty, B., Debnath, J. & Debnath, N. (2013). Design Graph Multi-Dimensional Data Model of a Data Warehouse and conversion of its equivalent Object - Oriented Schema. 2013 IEEE Symposium on Computers and Communications (ISCC). s.000079–000084.

Ramachandran, S., Rajeswari, S., Murty, S. A. V. S., Valsan, M., Dayal, R. K., Rao, R. V. S. & Raj, B. (2010). Design of a dimensional database for materials data. Trendz in Information Sciences & Computing (TISC2010). s.10–15.

Ranjan, J. (2008). Business justification with business intelligence. VINE. Very informal newsletter on library automation. Vol. 38(4), s.461–475.

Reeves, L. (2009). A Manager's Guide to Data Warehousing. John Wiley & Sons, Incorporated. Hoboken, United States.

Saaranen-Kauppinen, A. & Puusniekka, A. (2009). Menetelmäopetuksen tietovaranto KvaliMOTV: kvalitatiivisten menetelmien verkko-oppikirja, 2th ed. Yhteiskuntatieteellinen tietoarkisto Tampereen yliopisto. Tampere.

Santoso, L. W. & Yulia (2017). Data Warehouse with Big Data Technology for Higher Education. Procedia computer science. Vol. 124, s.93–99.

Saunders, M. N. K., Thornhill, A. & Lewis, P. (2019). Research Methods for Business Students. Pearson Education, Limited. Harlow, United Kingdom.

Sen, A. & Sinha, A. (2005). A comparison of data warehousing methodologies. Communications of the ACM. Vol. 48(3), s.79–84.

Silvers, F. (2008). Building and maintaining a data warehouse. CRC Press. Boca Raton.

Squire, M. (2015) Clean Data. 1st ed. Packt Publishing. Birmingham.

Strand, M., Wangler, B. & Olsson, M. (2003). Incorporating External Data into Data Warehouses: Characterizing and Categorizing Suppliers and Types of External Data. s.10.

Thomas, E. & Magilvy, J. K. (2011). Qualitative Rigor or Research Validity in Qualitative Research. Journal for specialists in pediatric nursing. Vol. 16(2), s.151–155.

Ţole, A. (2016). The Importance of Data Warehouses in the Development of Computerized Decision Support Solutions. A Comparison between Data Warehouses and Data Marts. Database systems journal. Vol. VI (4), s.18–26.

Vaisman, A. (2014). Data warehouse systems: design and implementation, 1st ed. Springer. Berlin.

Vaismoradi, M., Turunen, H. & Bondas, T. (2013). Content analysis and thematic analysis: Implications for conducting a qualitative descriptive study. Nursing & health sciences. Vol. 15(3), s.398–405.

van der Lans, R. F. (2012). Data virtualization for business intelligence architectures revolutionizing data integration for data warehouses, 1st ed. Elsevier/MK. Amsterdam.

Vassiliadis, P., Simitsis, A. & Skiadopoulos, S. (2002). Conceptual modelling for ETL processes. Data Warehousing and OLAP. s.14–21.

Vitt, E., Luckevich, M. & Misner, S. (2010) Business Intelligence. 1st ed. Microsoft Press. Sebastopol.

Walton, D. (2014). Abductive Reasoning. The University of Alabama Press.

Watson, H. J. (2002). Recent Developments in Data Warehousing. Communications of the Association for Information Systems. Vol. 8.

Westerman, P. (2001). Data warehousing: using the Wal-Mart model. Morgan Kaufmann. San Francisco.

Williams, S. (2016) Business intelligence strategy and big data analytics: a general management perspective. 1st ed. Morgan Kaufmann. Amsterdam, Netherlands.

Yessad, L. & Labiod, A. (2016). Comparative study of data warehouses modeling approaches: Inmon, Kimball and Data Vault. 2016 International Conference on System Reliability and Science (ICSRS). s.95–99.

Yin, R. K. (2014). Case study research: design and methods, 5th edition.th ed. SAGE. Los Angeles.

Zandi, F. (2014). A concurrent group decision-making framework for selection of business intelligence–based data warehouse architecture. Concurrent Engineering. Vol. 22(1), s.3–16.

LIITE A: HAASTATTELURUNKO

Taustakysymykset (yhteiset kaikille ryhmille)

1. Työnkuvasi/Roolisi organisaatiossa
2. Kokemuksesi tietovarastoista

Kysymysrunko 1. Liiketoiminnan edustajat

1. Millaisia raportteja hyödynnät tällä hetkellä?
    a. Miten ne on toteutettu?
    b. Onko niissä jotain ongelmia?
2. Kuinka olemassa olevia raportteja voitaisiin parantaa?
    a. Millaisia raportteja haluaisit tulevaisuudessa käyttää?
3. Osaisitko nykyisiä raportteja tai työtehtäviäsi analysoimalla määrittää, millaista dataa tarvitset työsi tueksi?
    a. Hyödynnätkö tällä hetkellä raporttien lisäksi dataa muussa muodossa?
    b. Olisiko jotain muita keinoja, joiden avulla voisit määrittää työhösi tarvitsemaa dataa?
    c. Miten tulevaisuudessa toivoisit hyödyntäväsi dataa?
4. Kuinka hyvin tunnet hyödyntämäsi tiedon lähteet?
    a. Tiedätkö mitä tietoa on saatavilla?
    b. Tiedätkö mistä tieto tulee?
    c. Kuinka luotettavaksi koet saamasi tiedot? Miten luotettavuutta voisi parantaa?
5. Minkälaisena koet roolisi tietovarastoprojektissa?
    a. Onko iteratiivinen työskentely mielestäsi toimiva liiketoiminnan vaatimusten keräämisessä?
    b. Haluatko olla koko projektin ajan mukana vai vain määrittelyssä?

Kysymysrunko 2. Tietovarastoasiantuntijat

1. Millaisia ongelmia olet kokenut nykyisissä tietovarastoratkaisuissa?
    a. Mistä nämä ongelmat mielestäsi johtuu?
2. Mitä vaiheita modernin tietovaraston suunnitteluun mielestäsi kuuluu? Mitkä ovat kriittisimmät vaiheet?
    a. Kuinka hyvin esitetty malli vastaa näkemykseesi modernin tietovaraston suunnitteluprosessista?
    b. Puuttuuko mallista jotain olennaista? Mitä?
    c. Onko mallissa jotain ylimääräistä? Mitä?
3. Onko mallissa esitetyt vaiheet loogisessa järjestyksessä? Tekisitkö itse jotain eri järjestyksessä?
4. Miten liiketoiminnan vaatimuksia kerätään?
    a. Keneltä vaatimuksia kerätään?
    b. Onko kerätty tieto hyödyllistä ja hyvälaatuista?
    c. Miten kerättyä tietoa hyödynnetään?
5. Mitä modernin tietovaraston arkkitehtuurin valinnassa pitää ottaa huomioon?
    a. Millainen arkkitehtuuri olisi mielestäsi toimiva? Millainen ei toimi?
    b. Miten arkkitehtuurin valinnassa otetaan huomioon liiketoiminnan vaatimukset?
6. Mitkä seikat ovat tärkeitä teknologioiden valinnassa?
    a. Vaikuttaako liiketoiminnan vaatimukset valittaviin teknologioihin? Miten?
7. Mihin tulee kiinnittää huomiota tietojen mallinnustavan valinnassa?
    a. Mikä/Mitkä toimii parhaiten modernissa tietovarastossa?
    b. Millaisilla työkaluilla tiedot tulisi mallintaa?
    c. Miten tietojen mallinnuksella voidaan tukea liiketoiminnan vaatimusten saavuttamista?
8. Mitä pitää ottaa huomioon informaation toimitus kerroksen suunnittelussa?
    a. Millaiset työkalut/teknologiat soveltuvat parhaiten modernin tietovaraston hyödyntämiseen?

b. Miten liiketoiminnan vaatimukset olisi hyvä ottaa huomioon teknologioita valitessa?

Kysymysrunko 3. Tietovarastokehittäjät

1. Kuinka hyvin tunnet yrityksesi eri tietolähteet?
    a. Onko näissä jotain haasteita mitä pitäisi ottaa huomioon tietovaraston suunnittelussa?
2. Kuinka tarpeellista mielestäsi on, että tietovaraston loppukäyttäjien tarpeet on tarkasti tiedossa heti tietovarastoprojektin alussa?
    a. Olisiko iteratiivinen lähestymistapa parempi?
3. Mitä vaiheita modernin tietovaraston suunnitteluun mielestäsi kuuluu? Mitkä ovat kriittisimmät vaiheet?
    a. Kuinka hyvin esitetty malli vastaa näkemykseesi modernin tietovaraston suunnitteluprosessista?
    b. Puuttuuko mallista jotain olennaista? Mitä?
    c. Onko mallissa jotain ylimääräistä? Mitä?
4. Miten liiketoiminnan vaatimuksia kerätään?
    a. Keneltä vaatimuksia kerätään?
    b. Onko kerätty tieto hyödyllistä ja hyvälaatuista?
    c. Miten kerättyä tietoa hyödynnetään?
5. Mitä modernin tietovaraston arkkitehtuurin valinnassa pitää ottaa huomioon?
    a. Millainen arkkitehtuuri olisi mielestäsi toimiva? Millainen ei toimi?
    b. Miten arkkitehtuurin valinnassa otetaan huomioon liiketoiminnan vaatimukset?
6. Millaiset teknologiat koet parhaaksi modernin tietovaraston kehittämiseen?
    a. Millaisia ominaisuuksia niillä pitää olla?
7. Mihin tulee kiinnittää huomiota tietojen mallinnustavan valinnassa?
    a. Mikä/Mitkä toimii parhaiten modernissa tietovarastossa?
    b. Millaisilla työkaluilla tiedot tulisi mallintaa?

8. Mitä pitää ottaa huomioon tietojen hyödyntämisen suunnittelussa?
    a. Millaiset työkalut/teknologiat soveltuvat parhaiten modernin tietovaraston hyödyntämiseen?